

합성 데이터 최종본 EDA

20,000명 · 12개월 · 50학교 — 1억 4,126만 행. 이 데이터를 분석에 써도 되는가

생성 2026-08-04 · synthetic-v2.yaml · seed 20260803 · 10분 16초

적재 로컬 pgtest · 2시간 57분 · 141,260,593행 · CSV 7.4GB

기간 2025-08-31 ~ 2026-07-23 (가압·세션 모두)

정합성 17종 전부 통과 (위반 0)

이전 판본 EDA-sample-1m-v{1,2,3} 는 500명·1개월 샘플이다. 이 문서는 대상이 다르다 — 규모·기간이 최종이라 처음 확인되는 항목이 있다

0. 요약 — 쓸 수 있다. 다만 세 가지를 알고 써야 한다

합격

정합성 17종 위반 0. 목표 지표 6종 중 4종이 목표 범위 안. 성장 곡선의 5국면이 설정과 $\pm 1\%$ p 안에서 재현됐다. 하트 경제가 구간별로 갈린다.

알고 써야 할 세 가지

- 인기도가 너무 쏠렸다 — 상위 10%가 지목의 64.2%를 가져간다(목표 45%). 인기도 분석의 결론이 과장될 수 있다.
- 민감 질문이 더 신고되지 않는다 — 외모 질문의 신고율이 다른 카테고리과 사실상 같다. 외모 카테
고리를 연 목적이 데이터에서는 달성되지 않았다.
- vote_session.status 를 믿으면 안 된다 — 1문항만 하고 나간 세션도 COMPLETED 로 기록된다. 완
료 여부는 item_count 로 판단할 것. 실제 완료율은 84.6%다.

목표 지표 6종

지표	목표	실측	판정
친구 5명 해금률	90~95%	92.7%	통과
힌트 구매 유저 비율	70~80%	73.7%	통과
세션 1회 이상	~96%	95.8%	통과
받은 투표 0건인 사람	소수 존재	1,425명 (7.1%)	통과
상위 10% 지목 점유	45%	64.2%	초과
세션 완료율 (item_count=10 기준)	78%	84.6%	이탈이 다소 적음

완료율은 `status` 가 아니라 `item_count` 로 재야 한다

같은 지표를 두 방법으로 재면 값이 전혀 다르다.

재는 방법	완료율	맞는가
<code>status = 'COMPLETED'</code>	98.6%	아니다 — 상태가 이탈을 반영하지 않는다
<code>item_count = 10</code>	84.6%	실제 행동

생성기 결함이다. 이탈은 제대로 구현되어 있어서 문항 수가 실제로 줄어드는데, `vote_session.status` 만 그것을 안 따라간다. 1문항짜리 세션도 `COMPLETED` 로 적힌다.

1. 데이터 개요

표	행	표	행
vote_candidate	78,811,628	post_like	377,018
heart_transaction	17,407,662	school_notice_read	253,611
vote_item	15,866,923	meal_menu_item	80,619
vote_received	15,280,311	post_comment	75,682
ad_impression	4,082,162	report	63,465
vote_shuffle	3,529,258	comment_like	47,768
vote_session	1,753,793	post	45,879
hint_purchase	1,603,483	app_user	20,000
friend_request	717,268	timetable	19,080
user_session	635,165	meal_plan	15,338
friendship	538,669	heart_purchase	14,286
그 밖에 rejected_friend_recommendations 9,085 · sanction 4,206 · user_withdrawal 2,138 · school_event 1,812 · school_notice 1,656 · block_record 1,342 · grade_class 636 · question_request 320 · question 240 · school 50 · region 40			

40개 표가 모두 채워졌다. 실서비스에서 비어 있는 8개 표 (block_record · question_request · sanction · timetable · school_notice 등)도 여기서는 값이 있다 — 합성 데이터를 만든 이유 중 하나가 이것이다.

2. 성장 곡선 — 이번에 처음 확인된 항목

설정의 growth 블록을 생성기가 읽지 않던 것을 이번에 고쳤다. 12개월을 돌려야만 검증되는 항목이라 지금까지 확인할 수 없었다.

월	가입	비중	세션	MAU	MAU 추이
2025-09	7,028	35.1%	101,599	6,645	
2025-10	1,067	5.3%	72,378	2,918	
2025-11	928	4.6%	41,548	1,424	
2025-12	1,081	5.4%	44,697	1,564	
2026-01	601	3.0%	41,105	1,165	저점
2026-02	1,395	7.0%	45,795	1,803	
2026-03	1,424	7.1%	55,806	2,048	
2026-04	1,478	7.4%	56,594	2,150	
2026-05	1,807	9.0%	63,061	2,501	
2026-06	1,804	9.0%	62,437	2,536	회복 정점

2026-07	1,387	6.9%	50,145	2,143	23일까지
---------	-------	------	--------	-------	-------------------

국면별 가입 비중 — 설정과 대조

국면	기간	목표	실측	차이
launch_spike	2025-09	35%	35.1%	+0.1
decline	2025-10~12	15%	15.3%	+0.3
trough	2026-01	3%	3.0%	0.0
recovery	2026-02~04	22%	21.5%	-0.5
growth	2026-05~07	25%	24.9%	-0.1

실패 → 저점 → 회복의 3국면이 그대로 나왔다. 코호트를 갈라볼 재료가 생겼다는 뜻이다 — 9월 코호트와 5월 코호트는 서로 다른 서비스를 경험했다.

저점 대비 회복 MAU 는 2.18배 — 목표 2.5배에 못 미친다

1월 1,165명 → 6월 2,536명. 2,000명 규모 시험에서는 2.51배가 나왔는데 최종 규모에서 2.18배로 낮아졌다. 곡선의 모양은 맞고 진폭이 작다.

계절성 — 설정보다 훨씬 약하다

구간	일평균 세션	평시 대비	설정값	판정
평시	2,080	100%	1.00	
시험기간	1,840	88%	0.40	훨씬 약함
겨울방학	1,365	66%	0.30	훨씬 약함

왜 계절 배수가 그대로 안 나오나 — 구조적 한계다

활동 배수는 세션의 개수를 줄이는 것이 아니라 놓이는 날짜를 옮긴다. 그런데 유저 대다수의 활동 창이 짧다 — 잔존 구간이 same_day_only (28.4%)나 within_week (35.5%)면 옮길 여지가 며칠뿐이다.

즉 방학에 활동을 줄이려 해도 옮겨 갈 곳이 없다. 배수를 강하게 걸면 걸수록 기각 표집이 물러서기 (fallback)만 찾아진다. 계절 효과를 제대로 내려면 세션 수 자체를 달력에 맞춰 정해야 하는데, 그러면 잔존 구간이 정한 활동량과 이중으로 곱해진다. 이번 판본은 그 절충을 택했다.

⚠ 계절성 분석에는 이 데이터를 쓰지 말 것. 방향(방학에 준다)은 맞지만 크기가 설정의 절반 이하다.

3. 코호트 잔존 — 12개월이라 처음 가능해진 분석

가입 월	코호트	M0	M1	M2	M3	M6
2025-09	6,945	95.2%	26.5%	3.9%	3.6%	2.5%
2025-10	1,065	95.2%	25.2%	3.5%	3.3%	2.3%
2025-11	932	95.0%	26.6%	5.4%	5.0%	4.2%
2025-12	1,072	95.1%	25.4%	4.0%	3.7%	2.8%
2026-01	623	92.6%	29.2%	6.1%	5.0%	2.7%
2026-02	1,386	94.3%	27.1%	3.4%	3.0%	—
2026-05	1,812	95.0%	26.1%	3.5%	—	—
2026-06	1,797	95.6%	27.1%	—	—	—

M1 → M2 사이가 절벽이다 (26% → 4%)

실제 서비스의 잔존 곡선은 완만하게 휘는데, 여기서는 두 달째에 뚝 떨어진다. 원인은 `retention` 설정이다 — `within_month` (27.8%)까지가 최대 29일이고 그 위는 `long_term` (4.2%)뿐이라, 한 달과 장기 사이에 중간이 없다.

⚠ 잔존 곡선의 모양 자체를 분석 대상으로 삼지 말 것. 코호트별 비교 (9월 코호트 vs 5월 코호트)는 유효하다 — 모든 코호트가 같은 왜곡을 겪기 때문이다.

4. 유저 구성

항목	값	설정 목표 / 비교
전체	20,000	
여성 비율	59.2%	설정 58.6% 일치
해금(친구 5명)	18,536 (92.7%)	목표 90~95% 통과
학급 수	636	학교 50개 · 학교당 평균 12.7반
평균 친구 수	50.8	중앙값 35 · 최대 647(허브)
평균 하트 잔액	1,972	중앙값 421 — 평균이 중앙값의 4.7배
운영자	5	<code>is_admin</code> (W17 이후 별도 표 없음)

하트 잔액의 **평균 1,972 vs 중앙값 421** 이 이 데이터의 성격을 보여준다 — 소수의 과금·헤비 유저가 평균을 끌어올린다. 하트 경제를 **평균 하나로 보면 안 된다**는 설계 의도가 데이터에 나타났다.

5. 친구 그래프

항목	값
----	---

친구 관계(행)	538,669
끊긴 관계(ended_at)	30,718 (5.7%)
친구 요청	717,268
유저당 친구 — 평균 / 중앙값	50.8 / 35
최소 / 최대	0 / 647

친구 0명인 유저가 존재하고(해금 못 함 7.3%), 647명짜리 허브도 있다. 고립과 허브가 공존해야 게이트 퍼널이 성립한다 — **해금률 100%면 퍼널이 사라진다.**

6. 투표

항목	값	비고
투표 세션	1,753,793	
출제 문항	15,866,923	세션당 평균 9.05
실제 투표	15,280,311	문항의 96.3%
서플	3,529,258	문항의 22.2%
후보 보충된 문항	1,903,395 (12.0%)	보충 후보 총 2,816,541명

스코프 분포

스코프	문항	비중	설정
SCHOOL	5,554,369	35.0%	35%
GLOBAL	5,269,281	33.2%	30%
CLASS	5,043,273	31.8%	35%

CLASS 가 설정(35%)보다 3.2%p 낮고 GLOBAL 이 그만큼 높다. 같은 반 친구가 4명이 안 되면 GLOBAL 로 물러서기 때문이다 — 의도된 동작이며 그 횟수가 여기 나타난다.

인기도 집중 — 목표를 크게 벗어났다

10분위	지목받은 수	점유율	
상위 10%	9,816,747	64.2%	
2	2,450,345	16.0%	
3	1,256,857	8.2%	
4	742,257	4.9%	
5	453,021	3.0%	
6~9	559,634	3.7%	
하위 10%	1,450	0.0%	

상위 10%가 64.2% — 목표는 45%였다

Zipf 가중치(`zipf_alpha 1.6`)가 12개월·20,000명 규모에서 예상보다 강하게 작동했다. 1개월 샘플에서 맞춰 둔 값이 규모가 커지자 벌어진 것으로 보인다.

영향 — "인기 있는 소수가 대부분의 지목을 받는다"는 결론 자체는 실제 서비스에서도 참일 가능성이 높지만, **이 데이터의 64%라는 숫자를 그대로 인용하면 안 된다**. 인기도 분석은 **순위·분포의 모양**까지만 쓰고 절대 수치는 피한다.

받은 투표가 0건인 사람이 1,425명(7.1%) 있는 것은 **의도대로**다 — "인기 없음"이라는 상태가 데이터에 존재한다.

세션 완료율 — 중도 이탈은 구현되어 있다

세션 하나에 질문이 10개 나온다(`items_per_session: 10`). 끝까지 채우면 완료, 중간에 나가면 이탈이다. 목표 78%는 설정 `session_abandon_rate: 0.22` 에서 온다 — **실측이 아니라 판단으로 정한 값**이다(같은 파일의 `complete_rate: 0.963` 에는 "실측" 표시가 있으나 이 항목에는 없다).

문항 수	세션	비중	해석
1	53,984	3.1%	초반 이탈 — 합 9.3%
2	53,679	3.1%	
3	54,195	3.1%	
4~9	107,495	6.1%	후반 이탈
10	1,484,440	84.6%	완료

이탈 15.4% 중 1~3문항이 **60.4%** — 설정 `abandon_early_share: 0.60` 과 정확히 맞는다. 이탈이 앞쪽에 몰린다는 설계가 재현됐다.

목표 78%에 비해 이탈이 다소 적은(15.4% vs 22%) 이유는, 생성기가 이탈 확률을 유저 성향(`vote_freq`)으로 조정하기 때문이다 — 자주 투표하는 사람은 덜 이탈한다. 집계하면 설정값보다 낮게 나온다.

⚠️ 다만 `status` 컬럼은 이것을 반영하지 않는다. 1문항짜리 세션도 **COMPLETED** 다(98.6%). 퍼널 분석은 `item_count` 로 해야 한다.

7. 하트 경제

유형	건수	하트 합계	건당 평균
VOTE_REWARD	15,658,433	+48,132,044	3.1
TOPUP (충전)	14,263	+20,095,765	1,408.9
SIGNUP_GRANT	20,000	+6,000,000	300.0
HINT_PURCHASE	1,357,305	-27,813,380	-20.5
VOTE_REPLY	356,260	-7,125,200	-20.0
EVENT_GRANT	984	+74,050	75.3
ADMIN_ADJUST	417	+68,400	164.0

투표 보상 평균이 정확히 3.1이다 — 생성기가 의도한 확률표(2하트 40% · 3하트 30% · 4하트 20% · 5~10하트 10%)가 그대로 재현됐다. ⚠️ 앱은 아직 5~15 균등(평균 10)이다. 앱을 생성기에 맞추기로 한 항목이며 미이행이다.

소비/적립 — 평균 하나로 보면 안 되는 이유

적립 5분위	인원	적립	소비	소비율
1 (최소)	4,000	1,541,327	242,180	15.7%
2	4,000	2,967,364	1,328,640	44.8%
3	4,000	5,822,151	2,835,060	48.7%
4	4,000	11,759,095	6,552,440	55.7%
5 (최대)	4,000	52,280,322	23,980,260	45.9%
전체	20,000	74,370,259	34,938,580	47.0%

1분위(15.7%)와 4분위(55.7%)가 3.5배 차이다. 전체 평균 47%만 보면 이 차이가 사라진다. 잔액 중앙값이 421인데 평균이 1,972인 것도 같은 이야기다.

8. 힌트

종류	구매	하트 소비	광고 무료
GENDER (성별)	445,079	3,978,020	246,178
CLASS (반)	288,298	5,765,960	0
INITIAL (초성)	287,735	5,754,700	0
FINAL (종성)	287,237	5,744,740	0
MEDIAL (중성)	286,793	5,735,860	0
FULL_NAME (이름)	8,341	834,100	0

구매자 **14,737명 (73.7%)** — 목표 70~80% 안. 요금이 정확하다(20하트 × 5종, 이름 100하트). **GENDER 만 광고로 무료 열기가 55.3%**인 것도 설계대로다(하루 1회).

이름(100하트)은 8,341건뿐 — 전체 힌트의 0.5%다. **비싼 힌트는 거의 안 팔린다**는 것이 데이터에 나타난다. 잔액 부족으로 무산된 구매가 생성 중 **297만 건** 있었다.

9. 받은 투표 · 답장

항목	값
받은 투표	15,280,311
열람	8,243,539 (53.9%)
열람 — 창 끝 3일 제외	8,062,219 / 14,524,406 (55.5%)
답장	740,128 (4.8%)

우측 절단 — 열람률을 낼 때는 창 끝 3일을 뺀다

받은 투표는 1~72시간 뒤에 열람된다. 기간 마지막 3일치는 **열람 시각이 관측 창을 넘어가** 미열람으로 기록된다. 보정하면 53.9% → **55.5%** 다.

1개월 샘플에서는 41.8% → 53.9% 로 **12%p** 차이가 났는데, 12개월에서는 1.6%p 로 줄었다. **관측 창이 길수록 절단의 영향이 작아진다는** 것이 수치로 확인됐다.

공개 상태

reveal_status	건수	비중
HIDDEN (힌트 없음)	14,137,698	92.5%
PARTIAL (힌트 일부)	1,142,613	7.5%

받은 투표의 92.5%는 힌트를 하나도 안 산 상태로 남는다. **힌트는 선택적 소비**라는 W14 의 설계가 데이터에 반영됐다.

10. 게시판

글	댓글	글 좋아요	댓글 좋아요	글쓴이
45,879	75,682	377,018	47,768	7,743

글쓴이가 7,743명 — 전체의 38.7%만 글을 쓴다. 글당 댓글 1.65개, 좋아요 8.2개.

11. 신고 · 제재 — 외모 질문을 컨 목적의 검증

신고 대상	건수	처리 상태	건수
USER	26,455	PENDING	27,388
POST	16,499	DISMISSED	26,875
COMMENT	14,144	ACTIONED	9,202
QUESTION	6,367	제재 4,206건	

카테고리별 질문 신고율 (출제 1,000건당)

카테고리	민감	출제	신고	1천건당
APPEARANCE	예	996,140	437	0.439
RELATIONSHIP	아니오	2,096,772	881	0.420
TALENT	아니오	1,899,617	791	0.416
SCHOOL_LIFE	아니오	2,548,645	1,037	0.407
FUTURE	아니오	2,061,082	815	0.395
TASTE	아니오	1,785,473	692	0.388
PERSONALITY	아니오	2,746,798	1,058	0.385
HUMOR	아니오	1,732,396	656	0.379

민감 질문이 더 신고되지 않는다 — 이 항목의 목적이 달성되지 않았다

외모 카테고리를 켜 이유는 "민감한 질문이 실제로 얼마나 신고되는지"를 재기 위해서였다. 그런데 APPEARANCE(0.439)와 최하위 HUMOR(0.379)의 차이가 16%에 불과하고, 8개 카테고리가 0.379~0.439 사이에 촘촘히 모여 있다.

원인 — 생성기가 신고를 만들 때 `is_sensitive` 를 보지 않는다. 질문 카테고리나 무관하게 같은 확률로 신고를 뿌린다. 순위 차이는 노이즈다.

결론 — `is_sensitive` 플래그의 유용성은 이 데이터로 검증할 수 없다. 카테고리는 열렸고 질문 16개도 생성됐지만, "민감해서 더 신고된다"는 신호가 데이터에 심어져 있지 않다. 실서비스에서 실측하거나, 생성기에 카테고리별 신고 성향을 넣어야 한다.

⚠ PENDING 27,388건 — 실서비스와 같은 구조적 문제다. 신고 처리 화면이 없어 신고가 고인다 (`sanction` 표는 있으나 운영 경로가 없다).

12. 학교 정보 — 합성에서 처음 채워진 표들

급식	급식 메뉴	시간표	학사일정	공지	공지 열람
15,338	80,619	19,080	1,812	1,656	253,611

실서비스에서는 `timetable` · `school_notice` · `school_notice_read` 가 모두 0행이다(화면이 없어서). 이 세 표를 쓰는 분석은 합성 데이터로만 가능하다.

13. 탈퇴

사유	인원	비중	설정
NO_FRIENDS	628	29.4%	30%
BORING_CONTENT	590	27.6%	27%
NOT_USING	435	20.3%	20%
OTHER	256	12.0%	12%
TOO_MANY_BUGS	137	6.4%	6%
PRIVACY	92	4.3%	5%

총 2,138명(10.7%) 탈퇴. 설정(10.5%)과 사유 분포 모두 **정확히 일치**한다. 탈퇴해도 행은 지우지 않으므로 분석에서 사라지지 않는다.

14. 질문

카테고리	질문	활성	민감
PERSONALITY	42	예	아니오
SCHOOL_LIFE	38	예	아니오
FUTURE / RELATIONSHIP	31 / 31	예	아니오
TALENT	30	예	아니오
TASTE	27	예	아니오
HUMOR	25	예	아니오
APPEARANCE	16	예	예

총 240개. 외모 6.7% — 설정(`appearance_ratio` 0.06)과 일치. ⚠ 실서비스(Supabase)의 질문은 **24개**이고 별개의 데이터베이스에 있다.

15. 알려진 한계 — 이 데이터로 하면 안 되는 것

하면 안 되는 것	이유
-----------	----

세션 퍼널 — <code>status</code> 로 재는 것	이탈은 구현돼 있으나 <code>status</code> 가 반영하지 않는다. <code>item_count</code> 로 재면 유효 (완료 84.6%)
계절 효과의 크기 추정	겨울방학 0.66배(설정 0.30). 방향만 맞고 크기가 절반 이하
인기도 집중의 절대 수치 인용	상위 10%가 64.2%(목표 45%). 순위·모양까지만 쓴다
민감 질문의 신고율	카테고리별 신고 성향이 심어져 있지 않다. 순위 차이는 노이즈
잔존 곡선의 모양	M1→M2 가 절벽(26%→4%). 코호트 간 비교는 유효
매출 분석	합성은 실결제지만 실서비스는 MVP-STUB- 스텝이다. 섞어 세면 안 된다

아직 구현 안 된 설정 항목

- `schools.adoption` — 학교별 순차 확산(S자 곡선). 값만 있고 읽는 쪽이 없다
- `retention.reactivation_rate` — 회복 국면에 돌아오는 휴면 유저. "복귀 코호트"라는 분석 재료가 아직 없다
- `vote_session.status` — 이탈한 세션도 `COMPLETED` 로 적힌다. 구현이 아니라 기록의 결함이다

앱과 어긋난 곳 (미이행)

항목	앱	생성기
투표 보상	5~15 균등 (평균 10)	2~10 확률표 (평균 3.1)
일일 적립 상한	없음	하루 100하트

앱을 생성기에 맞추기로 했고 아직 안 했다. 생성 시험이 끝난 지금이 그 시점이다.