

합성 데이터 확정 전 전면 감사

20,000명 · 12개월 · 50학교 · 1억 8,826만 행 — 이 데이터를 확정해도 되는가

생성 2026-08-04 · synthetic-v2.yaml · seed 20260803 · 17분 14초

적재 로컬 pgtest · 2시간 38분 · 188,255,748행 · CSV 15GB

범위 고친 항목만이 아니라 전 영역을 훑는다 — 무결성 · 분포 · 그래프 · 행동 · 경제 · 운영

이전 판본 EDA-final-12m-v1 (1억 4,126만 행) 대비 비교를 병기한다

0. 판정 — 조건부 확정 가능

통과한 것 (무결성·구조)

정합성 17종 위반 0 · 이상치 9종 전부 0 · 컬럼 커버리지 342개 중 340개 · 40표 전부 채워짐 ·
updated_at 불일치 0

이번 감사에서 새로 발견한 결함 3건

결함	규모	영향
① 시간대·요일 패턴 없음	완전 균등	0~23시가 전부 4.2%. "언제 쓰는가" 분석이 불가능
② 해금했는데 투표 0회	2,704명 (해금자 14.6%)	계절성 물량 모드의 부작용. 세션이 1개뿐인 유저가 숨여 0이 됨
③ 같은 반 친구 비율 미달	14.1% (설정 25%)	학급이 1,208개로 늘어 같은 반일 확률이 떨어짐

①이 가장 크다. 시간대 분석은 이 데이터로 아예 할 수 없다.

목표 지표

지표	목표	v1	v2	판정
친구 5명 해금률	90~95%	92.7%	92.9%	통과
힌트 구매 유저	70~80%	73.7%	78.0%	통과
접속 세션 1회 이상	~96%	95.8%	95.8%	통과
받은 투표 0건	소수	7.1%	6.6%	통과
상위 10% 지목 점유	49%	64.2%	48.1%	통과
세션 완료율 (두 측정 일치)	일치	14.0%p 차	0.4%p 차	통과
민감 질문 신고 배수	2배+	1.16배	3.4배	통과
투표 세션 1회 이상	~92%	—	79.3%	미달
계절성 (겨울방학)	0.30~0.45	0.66	0.58	부분

1. 무결성 — 전부 통과

정합성 검사 17종 (3분 56초)

하트 원장 누적합 · 음수 잔액 · 자기 자신 후보 · 가입 이전 활동 · 출제 이전 투표 · 친구 아닌 후보 · 게이트 위반 · CLASS/SCHOOL 스코프 위반 · 원장 없는 구매 등 전부 위반 0.

이상치 점검 9종

점검 항목	위반	점검 항목	위반
미래 시각 가입	0	투표 시각 < 출제 시각	0
음수 하트 잔액	0	세션 완료 < 시작	0
빈 닉네임	0	자기 자신과 친구	0
닉네임 중복	0	끊긴 시각 < 맺은 시각	0
초대 코드 중복	0		

컬럼 커버리지 — 342개 중 340개

항상 NULL 인 컬럼	정상인가
<code>app_user.auth_user_id</code>	정상 — Supabase 익명 계정 UUID. 합성 유저에게는 없는 것이 맞다
<code>heart_transaction.ad_impression_id</code>	정상 — 광고는 하트가 아니라 무료 힌트로 보상하므로 원장에 안 걸린다

v1 은 338개였다. 늘어난 2개는 `vote_session.status` 의 EXPIRED 값과 `updated_at` 계열이다.

`updated_at` 정합성

표	행	원본 시각과 불일치
<code>vote_item</code> (= <code>served_at</code>)	21,108,231	0
<code>user_session</code> (= <code>started_at</code>)	889,269	0
<code>heart_transaction</code> (= <code>created_at</code>)	23,804,440	0

생성기가 CSV 에 직접 실어 놓도록 바꾼 결과다. BigQuery 증분 적재의 워터마크가 각 행의 실제 시각을 정확히 가리킨다.

2. 규모와 구성

표	v2	v1	표	v2	v1
<code>vote_candidate</code>	105,135,168	78,811,628	<code>post_like</code>	374,112	377,018
<code>heart_transaction</code>	23,804,440	17,407,662	<code>school_notice_read</code>	290,350	253,611
<code>vote_item</code>	21,108,231	15,866,923	<code>report</code>	84,426	63,465
<code>vote_received</code>	20,325,937	15,280,311	<code>meal_menu_item</code>	78,680	80,619
<code>ad_impression</code>	5,520,429	4,082,162	<code>post_comment</code>	77,985	75,682

vote_shuffle	4,761,644	3,529,258	comment_like	49,382	47,768
vote_session	2,320,280	1,753,793	post	46,933	45,879
hint_purchase	2,269,104	1,603,483	timetable	36,270	19,080
user_session	889,269	635,165	app_user	20,000	20,000
friend_request	576,579	717,268	grade_class	1,208	636
friendship	433,011	538,669	school	50	50

항목	v2	v1	설정 / 판정
여성 비율	58.9%	59.2%	58.6% 일치
중학교 : 고등학교	28 : 22	—	middle_ratio 0.55 일치
학교당 평균 유저	중 650 · 고 722	—	계층 구조 반영
학급 수 / 학급당 인원	1,208 / 15명	636 / 31명	목표 14~22 정상화
해금률	92.9%	92.7%	90~95% 통과

복귀 코호트 — 636명

복귀 월	2월	3월	4월	5월	6월	7월
복귀자	64	252	106	90	45	75
비중	10.1%	39.6%	16.7%	14.2%	7.1%	11.8%

3월에 40%가 몰리되 다른 달에도 고루 있다. v1 에는 복귀 자체가 없었다.

6. 친구 그래프

항목	v2	설정	판정
친구 관계	433,011	—	
끊긴 관계	25,077 (5.8%)	6%	일치
유저당 평균 / 중앙값	40.8 / 32	중앙값 30	근접
최소 / 최대	0 / 358	허브 80~240	양방향 유입으로 초과
같은 학교 비율	70.8%	80% (실측 79.6%)	미달
같은 반 비율	14.1%	25% (실측 23.7%)	미달

친구 요청 상태	건수	비중	설정
ACCEPTED	433,011	75.1%	75.1%
PENDING	132,605	23.0%	23.0%
REJECTED	10,963	1.9%	1.9%

요청 상태 비율은 설정과 소수점까지 일치한다.

결함 ③ — 같은 반 친구가 14.1%뿐이다 (설정 25%)

학급 수를 정원에서 유도하도록 바꾸면서 학급이 636개 → **1,208개**가 됐다. 학급이 잘게 쪼개지니 "같은 반"일 확률이 자연히 떨어진다.

영향 — CLASS 스코프 투표에서 후보를 채우지 못해 GLOBAL 로 물러서는 일이 늘어난다(실제로 CLASS 비중이 설정 35% 대비 **30.6%**다). 같은 반 관계를 다루는 분석은 표본이 설정보다 적다.

친구 수 분포

0~4	10~19	20~29	30~39	40~49	50~59	60~79
7.1%	5.7%	30.7%	20.8%	12.3%	7.2%	7.6%

0~4명이 7.1% — 게이트를 못 넘는 고립 유저다. 이들이 있어야 해금 퍼널이 성립한다.

7. 투표

항목	값	비고
투표 세션	2,320,280	
출제 문항	21,108,231	세션당 평균 9.73
실제 투표	20,325,937	96.3% — 설정 <code>complete_rate 0.963</code> 정확
서플	4,761,644	문항당 평균 0.245회
후보 보충된 문항	2,491,459 (11.8%)	문항당 평균 0.175명

스코프	출제	비중	설정	투표율
-----	----	----	----	-----

SCHOOL	7,387,907	35.0%	35%	96.3%
GLOBAL	7,267,234	34.4%	30%	96.3%
CLASS	6,453,090	30.6%	35%	96.3%

CLASS 가 설정보다 4.4%p 낮고 GLOBAL 이 그만큼 높다 — 같은 반 후보가 4명이 안 되어 물러선 결과다 (결함 ③의 파생).

질문 사용의 균등성

240개 질문이 각각 **78,049~99,144회** 출제됐다(평균 87,951). 특정 질문에 쏠리지 않는다.

세션 완료율

상태	세션	비중	평균 문항
COMPLETED	1,972,465	85.0%	10.00
EXPIRED (중도 이탈)	337,817	14.6%	3.80
IN_PROGRESS	9,998	0.4%	10.00

`status` 기준 85.0% 와 `item_count=10` 기준 85.4% 가 **0.4%p 차이**로 일치한다. v1 은 14.0%p 벌어져 있었다.

8. 인기도

10분위	지목	v2	v1	
상위 10%	9,774,724	48.1%	64.2%	
2	3,721,150	18.3%	16.0%	
3	2,351,591	11.6%	8.2%	
4~5	2,715,114	13.4%	7.9%	
6~10	1,763,358	8.7%	3.7%	

지목 0회가 1,328명(6.6%) — "인기 없음"이라는 상태가 존재한다.

48%가 바닥이다 — 파라미터로 더 못 내린다

zipf_alpha 실측: 1.35 → 64.2% · 0.80 → 52.6% · 0.45 → 48.8% · 0.20 → 48.9%. 0.45 아래로는 효과가 없다.

바닥은 활동 불균형이다 — 투표를 하는 쪽 상위 10%가 전체 투표의 91.2%를 만들고, 그것이 친구 그 래프를 통해 퍼진 결과가 48%다. 인기도 집중과 활동 집중은 같은 현상의 두 얼굴이다.

9. 하트 경제

유형	건수	하트	건당
VOTE_REWARD	21,336,621	+65,581,813	3.1
TOPUP	14,498	+20,500,803	1,414.0
SIGNUP_GRANT	20,000	+6,000,000	300.0
HINT_PURCHASE	1,924,236	-39,439,440	-20.5
VOTE_REPLY	507,671	-10,153,420	-20.0
EVENT_GRANT / ADMIN_ADJUST	1,414	+141,950	—

적립 5분위	적립	소비	소비율
1 (최소)	2,200,048	777,620	35.3%
2	5,661,288	3,143,300	55.5%
3	10,463,301	6,225,940	59.5%
4	18,776,271	12,096,360	64.4%
5 (최대)	55,123,658	27,349,640	49.6%
전체	92,224,566	49,592,860	53.8%

1분위 35.3% ~ 4분위 64.4% 로 구간별로 갈린다. 전체 평균 53.8% 하나로 보면 이 차이가 사라진다. 잔액도 평균 2,132 vs 중앙값 462 로 4.6배 벌어져 있다.

충전 (실결제)

구매	구매자	비율	하트	매출	스텝
14,519	3,642	18.2%	20,533,865	54,070,100원	0

⚠ 합성은 실결제이고 실서비스는 MVP-STUB- 스텝이다. 매출을 셀 때 섞으면 안 된다. 합성 쪽 스텝은 0건으로 확인된다.

10. 힌트

종류	구매	하트	광고 무료
GENDER	626,683	5,636,300	344,868 (55.0%)
CLASS	408,990	8,179,800	0
MEDIAL / INITIAL / FINAL	1,221,497	24,429,940	0
FULL_NAME	11,934	1,193,400	0

구매 단계	1	2	3	4	5	6
비중	62.0%	23.2%	9.5%	3.9%	1.3%	0.1%

단계가 올라갈수록 급격히 줄어드는 감쇠 곡선이다. 받은 투표 하나에 힌트를 6개까지 산 경우는 **1,895건**뿐이다. 구매자는 **15,591명(78.0%)** — 목표 70~80% 안.

11. 받은 투표 · 답장 · 게시판

항목	v2	v1
받은 투표	20,325,937	15,280,311
열람률	54.9%	53.9%
— 창 끝 3일 제외 (우측 절단 보정)	55.7%	55.5%
답장률	5.2%	4.8%
HIDDEN (힌트 안 삼)	92.1%	92.5%

글	댓글	글 좋아요	글쓴이	글당 댓글	글당 좋아요
46,933	77,985	374,112	7,818 (39.1%)	1.66 (최대 22)	8.75 (최대 397)

50개 학교 전부에 글이 있고 학교당 평균 939개(9~2,597)다. 학교 규모 차이가 그대로 반영된다.

12. 신고 · 제재 · 차단

대상	건수	처리 상태	건수	제재	건수
USER	35,539	DISMISSED	37,214	WARNING	3,478
POST	22,016	PENDING	34,832	SUSPEND	1,713
COMMENT	18,444	ACTIONED	12,380	BAN	576
QUESTION	8,427	차단 1,417건 · 573명(2.87%) — 설정 3%			

민감 질문 신고율 — 목적 달성

카테고리	민감	출제	신고	1천건당	v1
APPEARANCE	예	1,383,204	1,650	1.193	0.439
TASTE / HUMOR	아니오	4,520,704	1,628	0.360	0.384

SCHOOL_LIFE / RELATIONSHIP	아니오	5,916,579	2,041	0.345	0.414
FUTURE / PERSONALITY / TALENT	아니오	9,287,744	3,108	0.335	0.370

민감 질문이 3.4배 더 신고된다. v1 은 최상위와 최하위 차이가 16%에 불과해 순위가 노이즈였다. 이제 is_sensitive 플래그를 데이터로 검증할 수 있다.

13. 학교 정보 · 탈퇴

표	행	학교/학급	비고
meal_plan	14,982	50교	메뉴 78,680건
timetable	36,270	1,209학급	실서비스는 0행
school_event	1,860	50교	
school_notice	1,848	50교	열람 290,350건. 실서비스는 0행

탈퇴 사유	인원	비중	설정
NO_FRIENDS	635	30.2%	30%
BORING_CONTENT	559	26.6%	27%
NOT_USING	436	20.7%	20%
OTHER / TOO_MANY_BUGS / PRIVACY	473	22.5%	23%

사유 분포가 설정과 1%p 안에서 일치한다. 탈퇴해도 행은 지우지 않으므로 분석에서 사라지지 않는다.

14. ⚠ 이번 감사에서 발견한 결함

① 시간대·요일 패턴이 아예 없다 — 가장 큰 결함

시간대	0~5시	6~11시	12~17시	18~23시
접속 비중	25.0%	25.1%	25.0%	24.9%

0시부터 23시까지 **전부 4.1~4.2%**(완전 균등 = 4.17%). 요일도 전부 14.1~14.4%(균등 = 14.3%)다.

원인 — 세션 시각을 `rand_dt` 로 균등 추출한다. 시간대·요일 가중치가 생성기에 존재하지 않는다.

영향 — "학생들이 언제 쓰는가", "새벽 사용자는 다른가", "주말 패턴" 같은 질문에 이 데이터로는 답할 수 없다. 방과 후 집중, 심야 이용, 주말 차이가 전부 사라져 있다.

② 해금했는데 투표를 한 번도 안 한 유저 2,704명 (해금자의 14.6%)

전체	해금	접속 세션 있음	투표 세션 있음
20,000	18,571	19,163 (95.8%)	15,867 (79.3%)

원인 — 이번에 넣은 **계절성 물량 모드**의 부작용이다. 세션을 확률로 속아내는데, 세션이 1개뿐인 유저(당일만·1주 내 구간)는 그 하나가 저점 구간에 걸리면 **0**이 된다.

영향 — "해금은 했지만 투표는 안 한 사람"이라는 상태 자체는 실제로도 있을 수 있으나, **의도한 것이 아니고** `sessions_per_month_by_tier` 의 의미를 흐린다. 최소 1개는 보장하도록 고쳐야 한다.

③ 같은 반 친구 비율 14.1% (설정 25%)

학급을 정원에서 유도하도록 바꾸며 학급이 636 → 1,208개가 됐고, 그만큼 "같은 반"일 확률이 떨어졌다. CLASS 스코프 비중도 설정 35% 대비 30.6% 다.

영향 — 같은 반 관계를 다루는 분석의 표본이 설정보다 적다. 치명적이지는 않으나 `same_class_ratio`를 올려 보정할 수 있다.

15. 이 데이터로 하면 안 되는 것

금지	이유
시간대 · 요일 사용 패턴 분석	완전 균등이다. 패턴이 존재하지 않는다(결함 ①)
계절 효과의 크기 추정	겨울방학 0.58배(설정 0.30). 방향만 맞고 크기가 절반
"투표 안 한 유저" 비율 인용	14.6%가 계절성 부작용이라 실제 의도와 다르다(결함 ②)
같은 반 관계 비율 인용	설정 25% 대비 14.1%(결함 ③)
인기도 집중의 절대 수치	48.1%는 활동 불균형이 만드는 구조적 값이다. 순위·모양은 유효
실서비스와 매출 혼용	합성은 실결제, 실서비스는 MVP-STUB-

쓸 수 있는 것

- 가능 코호트 잔존 비교 · 복귀 코호트 분석
- 가능 성장 곡선 · 학교별 진입 시점 분석
- 가능 세션 퍼널 (status 와 item_count 일치)
- 가능 민감 질문 신고율 · is_sensitive 검증
- 가능 하트 경제 (구간별 소비율 · 잔액 분포 · 결제 전환)
- 가능 힌트 구매 퍼널 · 받은 투표 열람/답장
- 가능 게시판 · 신고 · 제재 · 학교 정보 (실서비스에 없는 표)
- 가능 파이프라인 대량 적재 검증

16. 확정 판단

권고 — 결함 ①②를 고치고 한 번 더 생성

무결성은 완벽하고 대부분의 분석 축이 살아 있다. 다만 시간대 패턴이 통째로 없는 것은 소셜 앱 분석에서 큰 손실이다. "언제 쓰는가"는 가장 기본적인 질문 중 하나다.

고칠 것은 둘 다 작다 —

1. 시간대·요일 가중치를 세션 시각 추첨에 건다 (설정 항목 신설)
2. 계절성 숨아내기에 최소 1개 보장을 넣는다
3. (선택) same_class_ratio 를 올려 결함 ③ 보정

재생성 비용은 생성 17분 + 적재 약 2시간이다. 적재는 이번에 CSV 읽기를 바이너리로 바꿔 더 빨라질 것으로 본다.

비용 (BigQuery 적재 시)

항목	값	비고
BigQuery 논리 바이트	13.85 GiB	무료 한도 10 GiB
초과분	3.85 GiB	
월 저장 비용	약 \$0.096	약 135원

적재 비용	\$0	배치 로드 잡은 무료
쿼리 비용	\$0	일일 상한 30 GiB → 월 900 GiB < 무료 1 TiB

최대 표 `vote_candidate` 가 6.59 GiB 다. 파티션 없이 전체 스캔하면 무료 한도의 0.64% 를 쓰므로 월 155 회까지 가능하다.