

합성 데이터 12개월 v4 — 확정 검수

20,000명 · 11.7개월 · 50학교 · 1억 8,922만 행 — 이 데이터를 확정해도 되는가

생성 2026-08-05 · synthetic-v2.yaml · seed 20260803 · 16분 26초 · 189,218,543행 · CSV 15GB

적재 로컬 pgtest · 1시간 54분 · 정합성 17종 위반 0(1분 50초)

이 판본의 변경 접속 세션(user_session)에 하루 리듬과 계절성을 걸었다 — v3 에서 투표 세션에만 걸려 있던 것

이 문서의 범위 v4 판정에 더해 정밀 EDA 를 새로 돌렸다 — 인구·계층·경제·퍼널·분포형태 등 9개 축을 추가로 캐고, 정합성 검사 못 잡는 항목을 따로 뒤졌다(3장·11장·12장)

⚠ 문서 판본 ≠ 데이터 판본 이 문서가 네 번째 12개월 데이터다. 판본 이력은 아래 1장

0. 요약 — 무엇을 확정하고 무엇을 알고 써야 하는가

판정 — 확정한다

정합성 17종 위반 0 · 이상치 9종 전부 0 · 40표 전부 채워짐 · 목표 지표 10개 전부 달성. v1~v3 에서 지적된 결함이 모두 해소됐다. 파이프라인·분석 연습용으로 확정 가능하다.

다만 — 이번 정밀 EDA 에서 새로 드러난 한계 5가지가 있다

전부 결함이 아니라 경계다. 데이터를 못 쓰게 만들지 않지만, 모르고 쓰면 틀린 결론이 나온다. 재생성 없이 이번 판본으로 간다.

한계	무엇이 불가능해지나	본문
접속 세션과 투표 세션이 서로 독립	"앱 열기 → 투표 시작" 퍼널 분석 불가. 투표 세션의 3.8% 만 접속 세션 창 안에 있다	12장
시간 간격이 전부 균등분포	체류시간·응답속도·열람지연의 분포 형태 분석 불가. 평균만 유효	11장
탈퇴·정지가 활동을 멈추지 않는다	탈퇴자의 88.7% 가 탈퇴 후에도 하트를 쓴다. 코호트에서 걸러야 한다	3장
7개 축에 설계된 차이가 없다	요일·질문·슬롯·앱버전·게시판 카테고리 등은 균등. 가설검정의 귀무값으로만 쓴다	11장
reveal_status='REVEALED' 가 0 건	이름까지 공개한 12,103건이 PARTIAL 로 남아 구분되지 않는다	9장

1. 판본 이력과 목표 지표

판본	행	문서	무슨 일이 있었나
12m v1 8/4	1억 4,126만	-v1	성장 곡선 첫 구현. 결함 8건
12m v2 8/4	1억 8,826만	-v2	7건 해결. 전면 감사에서 새 결함 3건
12m v3 8/4	1억 8,918만	-v3	감사 3건 해결. 접속 세션 결함으로 폐기
12m v4 8/5	1억 8,922만	-v4	확정 — 정밀 EDA 로 경계 5건 문서화

목표 지표 — 10개 전부 통과

지표	목표	v2	v3	v4	판정
친구 5명 해금률	90~95%	92.9%	92.7%	92.7%	통과
힌트 구매 유저	70~80%	78.0%	78.0%	77.6%	통과

받은 투표 0건	소수	6.6%	6.3%	6.3%	통과
상위 10% 지목 점유	49%	48.1%	49.3%	49.3%	통과
완료율 두 측정 차	일치	0.4%p	0.4%p	0.4%p	통과
민감 질문 신고 배수	2배+	3.4배	3.2배	3.5배	통과
투표 세션 계절성	0.30~0.45	0.58	0.22	0.22	통과
접속 세션 계절성	0.30~0.45	균등	0.56	0.30	해결
접속 세션 시간대	리듬	균등	균등	5.3배	해결
같은 반 친구 0~3명	15% 미만	25.7%	15.9%	14.7%	통과

2. 데이터 범위와 인구

항목	값
기간	2025-09-01 ~ 2026-07-23 (356일 · 11.7개월)
첫 세션 / 마지막 세션	2025-09-01 01:42 / 2026-07-23 23:58 (KST)
유저 · 학교 · 학급 · 질문	20,000명 · 50교 · 834학급 · 240문항
표 · 행	40표 전부 채워짐 · 189,218,543행

인구 구성

축	분포	평균 친구
성별	F 11,792 (58.96%) · M 8,208 (41.04%)	37.4 / 37.6
학년	1학년 6,672 (33.4%) · 2학년 6,682 (33.4%) · 3학년 6,646 (33.2%)	37.8 / 37.7 / 36.9
학교 유형	고교 30곳 11,528명 · 중학 20곳 8,472명	37.1 / 37.9
상태	ACTIVE 18,011 (90.1%) · WITHDRAWN 1,989 (9.9%)	37.5 / 37.3

성별·학년·학교유형 어느 축으로 갈라도 평균 친구 수가 37 안팎으로 같다 — 인구 속성은 활동에 영향을 주지 않게 설계돼 있다. 활동 차이를 만드는 것은 페르소나다.


학교 규모 — 20명부터 1,062명까지

최소	p25	중앙값	p75	최대	평균
20	99	229	606	1,062	400

학교 계층별 진입 — 큰 학교가 먼저 들어온다

계층	학교	유저	학교당	진입 기간	해금률
1 (큰 학교)	17	13,668	804	2025-09 ~ 2026-02	92.7%
2 (중간)	17	5,177	305	2025-10 ~ 2026-05	93.0%
3 (작은 학교)	16	1,155	72	2026-03 ~ 2026-06	91.9%

학교가 처음 열린 달



막대 길이는 그 달에 처음 열린 학교 수. 평균 학교 규모가 959명 → 51명으로 단조 감소한다 — 계층 진입이 설계대로 작동한다.

3. 무결성

정합성 17종 · 이상치 9종 — 전부 0

정합성 (17종)	위반	이상치 (9종)	위반
하트 원장 누적합 · 잔액 일치	0	미래 시각 가입	0
음수 잔액 · 원장 없는 충전/구매	0	음수 하트 잔액	0
가입 이전 세션 · 활동	0	빈 닉네임 · 닉네임 중복	0
출제 이전 투표 · 자기 자신이 후보	0	초대 코드 중복	0
친구 아닌 후보 · 게이트 위반	0	투표 시각 < 출제 시각	0
CLASS/SCHOOL 스코프 위반	0	세션 완료 < 시작	0
후보 4명이 아닌 라운드	0	자기 자신과 친구 · 끊긴 시각 역전	0

추가로 확인했다 — 투표한 문항 20,391,049건과 `vote_received` 행 수가 정확히 일치하고, 원장 없는 `vote_received` 는 0건이다.

⚠️ 검사 26종이 못 잡는 것 — 이번에 따로 뒤졌다

정합성 검사는 쓰인 시점의 세계를 안다. 탈퇴·제재는 나중에 붙은 개념이라 검사가 묻지 않는다. 아래는 전부 실제로 데이터에 있다.

묻지 않는 것	행	유저	뜻
탈퇴 후 하트 거래	1,282,199	1,765	탈퇴자의 88.7%. 평균 88.8일 뒤까지, 최대 321.6일
정지(BAN) 후 투표 세션	13,273	58	BAN 550건 중 58명이 계속 투표한다
탈퇴 후 게시물	3,702	—	글쓴이가 이미 탈퇴한 글
탈퇴 후 투표 세션	3,049	619	탈퇴자의 31%
탈퇴 후 결제	1,055	—	매출 집계가 들어진다
탈퇴 후 접속 세션	727	232	탈퇴자의 12%
차단한 사람이 후보로 나옴	0	0	막혀 있다 — 확인함


이것이 뜻하는 것 — 탈퇴는 라벨일 뿐이다

생성기는 `user_withdrawal` 행을 따로 만들고, 활동 생성은 그것을 보지 않는다. 그래서 탈퇴자와 잔존자의 활동이 통계적으로 같다 — 친구 37.3 vs 37.5, 투표 세션 119.4 vs 115.6(탈퇴자가 오히려 많다), 하트 1,956 vs 2,133.
쓰는 쪽에서 할 일: 이탈·탈퇴 코호트를 만들 때 `created_at <= (탈퇴 시각)` 으로 반드시 자른다. 자르지 않으면 "탈퇴자가 더 활발하다"는 결론이 나온다.
이탈 예측 모델링에는 쓸 수 없다 — 라벨과 피처가 독립이라 어떤 모델도 학습되지 않는다. 이것은 4장의 수명(lifespan)으로 대신한다.

4. 하루 리듬 · 요일 · 계절

시간대 — 이번 판본의 핵심 (KST, 전체 접속 세션)

v3 까지는 투표 세션에만 시간대가 걸려 있었다. 접속 세션 (user_session)은 하루 중 아무 분이나 균등하게 뿜고 있었다 — "언제 앱을 여는가"를 묻는 가장 자연스러운 표가 그것이다.



봉우리 셋 — 점심(12~13시) · 하교 후(17~19시) · 밤(21~23시). 최고 22시 7.51% ÷ 최저 4시 1.42% = 5.3배. 전원이 같은 곡선을 따르지 않는다 — 페르소나별로 봉우리가 이동한다.

평일과 주말

시간대	평일	주말
0~5	13.4%	13.6%
6~11	17.6%	18.2%
12~16	21.5%	25.3%
17~21	33.2%	30.1%
22~23	14.4%	12.8%

■ 평일 ■ 주말

주말은 낮(12~16시)이 21.5% → 25.3%로 살아나고 밤 봉우리가 완만해진다 — 학교에 안 가기 때문이다. 모양은 다르다.

⚠ 요일별 총량은 차이가 없다

모양은 평일/주말이 갈리지만 양은 갈리지 않는다 — 요일별 접속량 변동계수 **0.024**, 투표량 **0.025**(사실상 균등).

요일	월	화	수	목	금	토	일
접속 세션	147,472	150,357	141,879	142,383	141,762	142,994	147,043
투표 세션	329,906	335,885	327,710	336,872	315,986	332,706	341,060

원인을 찾았다 — `synthetic-v2.yaml` 의 `sessions.weekend_multiplier: 0.55` 와 `sessions.hour_weights` 를 생성기가 읽지 않는다. 시간대 리듬은 `behavior.hourly` (페르소나 크로노타입)가 담당하고, 그쪽엔 주말 모양만 있고 물량 배수가 없다.

⚠ CLAUDE.md 가 경고한 "설정에 값이 있어도 코드가 안 읽으면 없는 것" 함정의 8번째·9번째 사례다. 데이터는 멀쩡하고 오류도 안 난다.

⚠ 분석할 때 반드시 KST 로 변환한다

시각은 UTC 로 저장된다(Q27). 그대로 집계하면 봉우리가 9시간 밀려 22시가 13시로 보인다. Q27 이 이렇게 경고했다 — "Looker에서 '점심에 투표가 몰린다'가 새벽 3시로 보인다."

이 감사에서도 처음엔 UTC 로 집계해 이상하게 보였다. `SET TIME ZONE 'Asia/Seoul'` 또는 `AT TIME ZONE` 을 쓴다.

계절성

구간	접속 일평균	평시 대비	v3	설정
평시	4,034	100%	100%	1.00
시험기간	1,196	30%	92%	0.40
겨울방학	711	18%	56%	국면 0.18

겨울방학이 18%인 것은 **trough 국면(1~2월 저점)**이 담당하기 때문이며 의도된 값이다. 방학 배수는 국면이 안 덮는 12월 말만 맞는다.

5. 성장 · 코호트 · 수명 · 탈퇴

성장 국면 — 목표 대비 실측

국면	기간	목표	실측	오차
launch_spike	2025-09	35%	34.9%	-0.1%p
decline	2025-10~12	15%	14.5%	-0.5%p
trough	2026-01~02	5%	5.1%	+0.1%p
spring_spike	2026-03	20%	20.0%	0.0%p
slow_fade_1	2026-04~05	15%	15.2%	+0.2%p
slow_fade_2	2026-06~07	10%	10.2%	+0.2%p

월별 지표 — 신규 · MAU · DAU/MAU · 탈퇴

월	신규	MAU	투표자	평균 DAU	DAU/MAU	접속 세션	투표 세션	탈퇴
2025-09	6,976	6,688	5,434	1,584	23.7%	260,203	263,249	388
2025-10	961	3,114	2,974	1,182	38.0%	88,102	148,587	267
2025-11	945	1,954	1,722	886	45.4%	73,620	156,173	117
2025-12	996	1,688	1,535	564	33.4%	36,688	90,385	129
2026-01	525	1,132	1,030	406	35.9%	20,311	56,527	52
2026-02	497	979	982	367	37.5%	16,575	46,644	52
2026-03	4,003	4,383	3,928	1,335	30.5%	184,713	366,615	262
2026-04	1,477	2,997	2,935	1,228	41.0%	110,767	288,959	208
2026-05	1,562	2,692	2,492	1,145	42.5%	118,602	375,767	181
2026-06	1,169	2,128	2,051	847	39.8%	61,326	249,800	133
2026-07 (23일)	889	1,708	1,624	764	44.7%	42,983	277,419	200

MAU 진폭 최고 6,688(9월) → 최저 979(2월) → 회복 4,383(3월). 접속 세션 기준 저점 대비 회복은 4.5배(국면 평균으로는 1,056→4,383 = 4.2배, 투표 세션 기준으로는 982→3,928 = 4.0배) — 어느 기준으로 재도 Q4 목표 2.5배를 넘는다. ⚠️ v4 문서가 적어 둔 "2.2배"는 산출 기준이 명시돼 있지 않고 위 세 방식 중 어느 것으로도 재현되지 않는다 — 기준을 명시한 이 값으로 대체한다.

DAU/MAU 는 23.7%~45.4% 로 움직인다. 스파이크 직후(9월~3월)에 낮고 안정기에 높다 — 신규 유입이 많을수록 1회성 방문이 섞이기 때문이다. 실서비스에서 흔히 보는 모양이라 대시보드 연습에 쓸 만하다.

코호트 잔존 — 11개 코호트 전부

가입 월	인원	M0	M1	M2	M3	M4	M5	M6	M9
2025-09	6,976	95.9	32.3	11.4	6.0	3.6	3.1	2.6	1.4
2025-10	961	89.7	29.8	11.4	6.8	4.2	3.6	3.3	1.9
2025-11	945	92.1	30.5	9.9	5.7	4.6	4.0	3.8	—
2025-12	996	87.1	28.9	10.0	5.9	3.4	3.1	2.6	—
2026-01	525	83.2	33.7	15.6	8.2	4.4	4.2	3.8	—
2026-02	497	79.5	30.4	11.3	5.8	2.8	2.4	—	—
2026-03	4,003	95.7	32.0	11.4	6.1	3.8	—	—	—
2026-04	1,477	91.8	32.1	11.9	5.9	—	—	—	—
2026-05	1,562	94.6	30.6	10.5	—	—	—	—	—
2026-06	1,169	86.8	27.5	—	—	—	—	—	—
2026-07	889	91.8	—	—	—	—	—	—	—

단위 %. M1→M2 낙차가 2.8배다(v1 은 6.8배 절벽이었다). M3 이후는 3~6%대에서 완만하게 늡는다 — 코호트 히트맵을 그리면 모양이 나온다. 겨울 코호트(1월)가 가장 잘 남는다: M2 15.6%로 유일하게 두 자릿수를 지킨다.

유저 수명 — 첫 세션에서 마지막 세션까지

평균	중앙값	p90	최대	하루짜리
18.2일	4.6일	51.2일	324.6일	5,314명 (28.4%)



긴 꼬리가 살아 있다 — 300일 넘게 쓴 유저 46명은 평균 741회 접속했다. 수명은 탈퇴 라벨과 달리 활동에서 파생되므로, 이탈 분석은 이 측으로 한다.

복귀 코호트 — 736명

복귀 월	2월	3월	4월	5월	6월	7월
복귀자	63	254	144	134	71	69

3월에 34%가 몰리되 다른 달에도 고루 있다. "복귀 = 3월"이 되면 갈라볼 것이 없어지므로 의도한 분포다.

⚠ 복귀는 vote_session 으로만 측정된다

user_session 으로 재면 복귀자가 0명으로 나온다 — 접속 세션의 최대 공백이 11일 19시간이라 30일은커녕 14일 공백도 없다. 같은 데이터를 vote_session 으로 재면 최대 공백 319일, 30일 이상 공백 736명이다.

기준 표	7일+ 공백	14일+	30일+	최대 공백
user_session (접속)	57명	0명	0명	11일 20시간
vote_session (투표)	1,342명	—	736명	319일

12장의 두 표가 독립이라는 사실에서 나오는 결과다. 복귀·휴면 정의는 반드시 vote_session 기준으로 쓴다.

탈퇴

사유	인원	비중	
BORING_CONTENT 재미없음	577	29.0%	
NO_FRIENDS 친구가 없음	574	28.9%	
NOT_USING 안 씀	403	20.3%	
OTHER	242	12.2%	
TOO_MANY_BUGS	104	5.2%	
PRIVACY	89	4.5%	

탈퇴 1,989명(9.9%), 설정과 1%p 안에서 일치한다. 가입~탈퇴 생존기간은 중앙값 7일(p25 3.5일 · p75 20일 · 최대 308일)로 초기 이탈에 몰려 있다.

6. 친구 그래프

항목	v4	설정	비고
친구 관계 (살아 있는)	374,514	—	전체 397,658 중 23,144 끊김
같은 학교 비율	68.5%	80%	학교가 커져 GLOBAL 유입이 는다
같은 반 비율	23.1%	42%	비율보다 수가 기준이다(아래)
유저당 평균 친구	37.5	중앙값 30	최대 386명
해금률	92.7%	90~95%	통과

친구 요청 퍼널

상태	건수	비중	
ACCEPTED	397,658	75.1%	
PENDING 무응답	121,800	23.0%	
REJECTED	10,046	1.9%	


요청 529,504건. 응답까지 걸린 시간은 평균 24.3시간(중앙값 24.1 · 최대 72). 거절보다 무응답이 12배 많다 — 실서비스에서도 이 모양이 흔하다.

관계의 출처와 끊김

출처	요청	성사	끊김	끊김률	뜻
INVITE_CODE	344,551	278,269	16,288	5.85%	초대 코드 — 주 경로
RECOMMEND	144,977	79,413	4,538	5.71%	같은 학교 추천(W10)
SEARCH	39,976	39,976	2,318	5.80%	수락률 100% — 아래

끊김률이 출처와 무관하게 5.7~5.9% 로 같다(설정 unfriend_rate: 0.06). 끊긴 관계는 평균 86.2일(중앙값 62일) 유지되다 끊긴다 — ended_at 이 찍히고 행은 남으므로 "통틀어 몇 명과 친구였나"를 물을 수 있다.
⚠ SEARCH 는 요청 수와 성사 수가 정확히 같다 — 검색으로 보낸 요청은 100% 수락된다. 출처별 수락률을 비교하는 분석에는 쓸 수 없다.

친구 수 분포



같은 반 친구 — CLASS 스코프의 전제

0명	1~3명	4~5명	6~9명	10명+
2.5%	12.2%	12.7%	33.0%	39.6%

CLASS 투표는 같은 반 친구가 4명 있어야 성립한다. 불가(0~3명)가 14.7% 로 목표(15% 미만)를 통과했다(v2 는 25.7% 였다). CLASS 스코프 비중도 30.6% → 32.7% 로 올라왔다.

해금하고도 투표 안 하는 유저 — 의도된 기울기

친구 수	인원	투표 0회	비율	
5명 미만 (미해금)	1,452	1,452	100%	
정확히 5명	314	169	53.8%	
6~9명	1,138	381	33.5%	
10~19명	1,027	211	20.5%	
20~39명	9,649	885	9.2%	
40명 이상	6,420	234	3.6%	

친구가 적을수록 안 한다. 다만 **40명 이상인데 안 하는 사람도 234명** 있다 — 0이 아니어야 "친구 수가 곧 활동"이라는
동어반복을 피한다. 한 번도 투표하지 않은 유저는 전체 **3,344명**이다.

추천 거절 (실서비스 0행인 표)

거절 사유	건수	비중
SAME_SCHOOL	5,436	59.6%
SAME_CLASS	2,308	25.3%
MUTUAL_FRIEND	1,383	15.2%

7. 투표

항목	값	비고
투표 세션	2,320,125	
출제 문항	21,174,376	세션당 9.13
실제 투표	20,391,049	96.3% — 설정 정확
후보 행	105,568,896	문항당 4명 × 셔플 회차
셔플	4,800,272	문항의 22.7%
후보 보충 문항	2,571,943 (12.1%)	padded_count > 0

세션 퍼널

세션 상태	건수	비중	평균 문항	
COMPLETED	1,983,007	85.5%	10.00	
EXPIRED 중도 이탈	326,930	14.1%	3.80	
IN_PROGRESS	10,188	0.4%	10.00	

status 와 item_count 가 일치한다 — 두 방식으로 잰 완료율의 차가 0.4%p 다.

문항 위치별 — 어디서 빠지나

위치	1	2	3	4	5	6	7	8	9	10
출제(천)	2,320	2,255	2,189	2,124	2,102	2,080	2,059	2,037	2,015	1,993
투표율	96.29	96.29	96.29	96.31	96.30	96.30	96.31	96.30	96.30	96.32

이탈은 세션 단위로 일어난다 — 출제 수가 2,320천 → 1,993천 으로 14% 줄어든다. 반면 한 문항을 건너뛸 확률은 위치와 무관하게 96.3%로 일정하다(변동계수 0.0001). "뒤로 갈수록 대충 찍는다" 같은 위치 효과는 이 데이터에 없다(11장).

스코프

스코프	문항	비중	설정	보충 발생	평균 셔플
SCHOOL	7,364,345	34.78%	35%	18.00%	0.246
CLASS	6,934,214	32.75%	35%	17.97%	0.245
GLOBAL	6,875,817	32.47%	30%	0.00%	0.247

후보 보충(padded_count)은 CLASS·SCHOOL 에서만 일어난다 — GLOBAL 은 친구 전체가 후보라 모자랄 일이 없다. 설계대로다.

질문 — 240문항

카테고리	문항	출제	비중	문항 수 비중	민감
PERSONALITY	41	3,653,004	17.25%	17.08%	아니오
SCHOOL_LIFE	35	3,072,817	14.51%	14.58%	아니오
TALENT	34	3,005,095	14.19%	14.17%	아니오
FUTURE	32	2,873,475	13.57%	13.33%	아니오
RELATIONSHIP	31	2,701,631	12.76%	12.92%	아니오
TASTE	26	2,272,573	10.73%	10.83%	아니오
HUMOR	25	2,186,412	10.33%	10.42%	아니오
APPEARANCE	16	1,409,369	6.66%	6.67%	예

출제 비중이 문항 수 비중과 소수점까지 일치한다 — 질문은 카테고리과 무관하게 균등하게 뽑힌다. 질문별 출제량도 83,160~94,527 로 거의 균등하다(변동계수 0.045). "인기 질문"이라는 것이 이 데이터에는 없다.

민감 질문 신고율 — 이 데이터의 가장 확실한 가설검정

카테고리	민감	출제	신고	1천건당
APPEARANCE	예	1,409,369	1,709	1.213
HUMOR · FUTURE · RELATIONSHIP	아니오	7,761,518	2,669	0.344

민감 질문이 3.5배 더 신고된다. `is_sensitive` 플래그를 데이터로 검증할 수 있다. 비교군은 v2 부터 써 온 세 카테고리 그대로다 — 판본 간 비교를 위해 바꾸지 않았다.

⚠ 카테고리 비중은 문항 수에 정확히 비례한다($41/240 = 17.1\%$ vs 출제 17.25%). 질문별 출제량도 83,160~94,527 로 거의 균등하다(변동계수 0.045). "인기 질문"이라는 것이 이 데이터에는 없다.

후보 슬롯 · 성별

슬롯	1번	2번	3번	4번
선택률	18.14%	18.14%	18.16%	18.13%

슬롯 위치 편향이 없다(변동계수 0.0008). 실제 UI에서는 첫 칸이 더 뽑히는데, 이 데이터에는 그 효과가 없다 — "위치 편향이 있다"를 검정하면 반드시 기각된다.

지목	건수	비중	투표자 성별 안에서	인구 비중
F → F	7,479,776	36.68%	58.1%	F 58.96%
M → F	4,375,826	21.46%	58.3%	
F → M	5,403,243	26.50%	41.9%	M 41.04%
M → M	3,132,204	15.36%	41.7%	

여자가 지목한 상대의 58.1%, 남자가 지목한 상대의 58.3% 가 여자다 — 인구 비중(58.96%)과 같다. 즉 동성 선호가 없다. 지목은 성별에 대해 무작위다. 성별 상호작용 분석은 이 데이터로 할 수 없다.

인기도 — 누가 지목받나

평균	p10	중앙값	p90	p99	최대	0건
1,089	54	499	2,597	8,645	48,019	1,268명 (6.3%)

집중도	상위 1%	상위 10%	상위 20%	상위 50%	지니
받은 투표 점유	12.4%	49.3%	65.9%	90.8%	0.657
한 투표 점유	—	89.5%	—	—	0.936

⚠ 인기도 49.3% 를 "인기 쏠림"으로 읽으면 안 된다

투표하는 쪽의 지니가 0.936 이다 — 투표자 상위 10%가 전체 투표의 89.5% 를 던진다. 받는 쪽 집중(49.3%)의 대부분은 활동 불균형이 만드는 구조적 값이지 매력도 차이가 아니다.

받는 쪽 지니 0.657 은 받은 투표가 완전 균등(0)도 완전 독점(1)도 아닌 중간이라는 뜻이다. 순위·모양은 유효하고, 절대 수치는 인용하지 않는다.

받은 투표 이후 — 열람 · 공개 · 답장

단계	건수	비율	비고
받은	20,391,049	100%	
열람	11,115,000	54.5%	창 끝 3일 제외 시 55.4%(우측 절단 보정)
일부 공개 PARTIAL	1,585,605	7.78%	힌트를 산 것
완전 공개 REVEALED	0	0%	9장 — 쓰이지 않는 enum

답장 PUBLIC	1,833,444	8.99%	
답장 PRIVATE	133,075	0.65%	

열람까지 걸린 시간은 평균 **36.3시간**(중앙값 36 · 최대 72). ⚠ 이 값은 **1~72시간** **균등분포**다 — 11장 참조.

8. 하트 경제 · 결제 · 광고

원장 — 7종 거래

유형	건수	건당	총 증감	뜻
VOTE_REWARD	21,679,341	+3.07	+66,624,198	투표 보상 — 적립의 78%
HINT_PURCHASE	1,925,960	-20.50	-39,487,440	힌트 — 소비의 79%
VOTE_REPLY	513,040	-20.00	-10,260,800	답장
SIGNUP_GRANT	20,000	+300.00	+6,000,000	가입 지급 (전원 1회)
TOPUP	13,845	+1,394	+19,299,690	결제 충전
EVENT_GRANT	989	+75.18	+74,350	이벤트
ADMIN_ADJUST	399	+162.91	+65,000	관리자 보정

적립 92,063,238 · 소비 49,748,240 — 소비율 54.0%. 누적합과 heart_balance 가 전 유저에서 일치한다(정합성 1번).

일일 적립 상한이 실제로 작동한다

평균	중앙값	p99	최대	상한 도달
26	12	100	100	238,103 유저-일 (9.3%)

daily_earn_cap: 100 이 버는 쪽에만 걸려 있다 — 250만 유저-일 중 9.3% 가 상한에 부딪힌다. 충전(TOPUP)은 상한을 받지 않는다. ⚠ 이 상한은 앱에 없다 — 14장의 미이행 항목.

하트 잔액 — 심하게 치우쳐 있다

최소	p10	중앙값	p90	p99	최대	평균	잔액 0
0	12	445	4,436	30,447	113,979	2,116	116명

평균 2,116 이 중앙값 445 의 4.8배다 — 소수가 평균을 끌어올린다. 하트 지표는 평균이 아니라 분위수로 봐야 한다.

결제

지표	값	비고
결제 유저	3,556명 (17.8%)	설정 topup_rate: 0.18
결제 건수	13,845건	결제자당 3.89건
총 매출	50,819,500원	
ARPU	2,541원	전체 20,000명 기준
ARPPU	14,291원	중앙값 3,800원 · 최대 299,000원
실패율	0.12%	17건 — 실서비스보다 훨씬 낮다

상품	하트	가격	건수	비중	
소	200	900원	4,755	34.3%	
중	777	1,900원	2,970	21.5%	
대	1,000	2,900원	2,813	20.3%	
특대	4,000	9,900원	3,307	23.9%	

매출 집중	상위 1%	상위 10%
결제자 중 점유	16.8%	72.4%

고래 구조가 있다 — 결제자의 상위 10%가 매출의 72.4%를 낸다. LTV·세그먼트 연습에 쓸 수 있다.

결제자와 비결제자는 실제로 다르다

집단	인원	평균 친구	투표 세션	힌트 구매	하트 잔액
결제자	3,556	39.1	163.6	145.3	6,177
비결제자	16,444	37.1	105.7	105.8	1,237
배수	—	1.05×	1.55×	1.37×	5.0×

탈퇴 라벨과 달리 결제는 활동과 상관이 있다(3장 대조). 결제 전환 예측은 이 데이터로 연습할 수 있다.

광고

지면	상태	건수	비중	뜻
VOTE_SHUFFLE	COMPLETED	4,800,272	86.5%	셔플하려면 본다
VOTE_SHUFFLE	ABANDONED	417,576	7.5%	이탈률 8.0%
HINT_UNLOCK	COMPLETED	330,687	6.0%	이탈 0건 — 비대칭

네트워크는 admob 하나뿐이라 네트워크 비교는 불가하다. STARTED · FAILED 상태는 한 건도 없다. 시청 시간은 20~60초 균등(평균 39.5초) — 실제 리워드 광고는 15초/30초 고정이다.

9. 힌트 — 하트의 주 소비처

유형	건수	비중	평균 비용	광고 무료	뜻
GENDER	612,215	27.1%	9.20	330,687	성별 — 유일하게 광고로 열린다
INITIAL	408,890	18.1%	20.00	0	초성
CLASS	408,241	18.1%	20.00	0	반
FINAL	407,775	18.1%	20.00	0	종성
MEDIAL	407,423	18.1%	20.00	0	중성
FULL_NAME	12,103	0.5%	100.00	0	이름 전체 — 기본 3개 이상 연 뒤에만

단계별 — 살수록 비싸진다

단계	건수	비중	평균 비용	최대	광고 무료	
1	1,396,507	61.9%	17.40	20	181,550	
2	525,772	23.3%	16.68	20	87,148	
3	214,026	9.5%	16.25	20	40,148	
4	88,387	3.9%	22.10	100	16,318	
5	29,927	1.3%	26.13	100	5,523	
6	2,028	0.1%	100.00	100	0	

단계마다 2.5배씩 줄어든다 — 전형적인 이탈 곡선이다. 구매자는 15,520명(77.6%), 1인당 평균 145.4개(중앙값 78 · p90 359 · 최대 3,630개), 평균 지출 2,544 하트.

 `reveal_status = 'REVEALED'` 가 한 건도 없다

이름 전체를 산 12,103건이 전부 PARTIAL 로 남아 있다. 힌트를 하나라도 산 vote_received 중 HIDDEN 은 0건이니 상태 전이 자체는 일어난다 — 다만 마지막 단계로 넘어가지 않는다.

영향: "이름까지 알아낸 건"과 "초성만 산 건"을 reveal_status 로 구분할 수 없다. 구분이 필요하다면 `hint_purchase.hint_type = 'FULL_NAME'` 으로 조인한다.

고칠 것인가: 스키마가 아니라 생성기의 문제이고, 값 하나를 바꾸려고 1억 8,922만 행을 다시 만들 이유는 없다. 다음 판본으로 미룬다 — 우회로가 있다.

10. 게시판 · 신고 · 제재 · 학교 정보

게시판

글	댓글	글 좋아요	댓글 좋아요	삭제된 글
46,707	76,785	367,516	47,367	1,386 (3.0%)

참여 단계	인원	전체 대비	
좋아요를 누름	19,180	95.9%	
댓글을 씀	13,482	67.4%	
글을 씀	7,739	38.7%	

전형적인 90-9-1 참여 피라미드와는 모양이 다르다 — 실제 커뮤니티라면 좋아요 참여가 10~20% 대다. 여기서는 96%가 좋아요를 누른다. 참여율의 절대 수준은 인용하지 않는다. 글쓴이 안에서는 집중이 있다 — 상위 10%가 글의 36.3%(최대 89개, 평균 6.04개).

카테고리	글	비중	평균 좋아요	평균 댓글	평균 조회
COUNSEL	9,391	20.1%	7.95	1.64	134.1
FREE	9,373	20.1%	8.23	1.66	138.2
LOVE	9,360	20.0%	7.41	1.68	128.3
CAREER	9,304	19.9%	8.11	1.60	140.1
HOBBY	9,279	19.9%	7.64	1.64	131.2

다섯 카테고리가 완전히 균등하다(변동계수 0.005) — 글 수도, 좋아요도, 댓글도, 조회도. 카테고리별 차이 분석은 불가능하다.

신고 · 제재

신고 대상	건수	비중	신고 상태	건수	비중
USER	35,614	42.1%	DISMISSED	37,242	44.0%
POST	22,111	26.1%	PENDING	35,013	41.3%
COMMENT	18,582	21.9%	ACTIONED	12,436	14.7%
QUESTION	8,384	9.9%	신고 84,691건 중 제재로 이어진 것 6.75%		

PENDING 41.3% 는 실서비스의 상태를 그대로 재현한다 — 신고 처리 화면이 없어 sanction 이 고이는 그 문제다. 운영 지표(처리 대기 큐) 대시보드 연습에 쓸 수 있다.

제재	건수	비중	현재 유효	뜻
WARNING	3,438	60.1%	3,438	기간 없음
SUSPEND	1,730	30.3%	173	90%가 만료됐다 — 기간이 있다
BAN	550	9.6%	550	이 중 58명이 이후에도 투표한다(3장)

차단 1,516건 — 사유 5종이 18.1~22.4% 로 고르게 퍼져 있다. 신고 사유는 12종이며 대상 유형 안에서 균등하다(U_ * 각 10.5% · P_ * 각 8.7% · Q_ * 각 2.5%).

학교 정보 — 50개교 전부 커버

급식	급식 메뉴	시간표	학사일정	공지	공지 열람
15,752	82,750	25,020	1,800	1,716	260,217

급식	점심	저녁	아침	학사일정	시험	행사	휴일	체험	기타
건수	12,407	2,591	754	건수	481	423	363	270	263

공지 1건당 평균 **151.6회** 열람, 열람자 19,180명. 급식·시간표·학사일정·공지 모두 **50개교 전부**에 있다 — 실서비스에서
비어 있는 `timetable`·`school_notice` 를 합성으로 채워 화면을 미리 설계할 수 있다.

질문 요청 320건 — REJECTED 172 · APPROVED 82 · PENDING 66.

11. ⚠️ 균등분포 점검 — 이번 EDA 의 핵심 발견

합성 데이터에서 가장 위험한 것은 틀린 값이 아니라 차이가 없는 축이다. 오류가 안 나고, 정합성 검사도 통과하고, 분석을 다 하고 나서야 "아무 패턴도 안 나온다"로 드러난다. 그래서 전 축을 변동계수(CV)로 훑었다.

축별 변동계수 — 0 에 가까우면 설계된 차이가 없다

축	CV		판정
문항 위치별 투표율	0.0001		균등 — 차이 없음
후보 슬롯별 선택률	0.0008		균등 — 차이 없음
앱 버전 비중	0.0029		균등 — 차이 없음
게시판 카테고리	0.0051		균등 — 차이 없음
요일별 접속량	0.0236		균등 — 차이 없음
요일별 투표량	0.0246		균등 — 차이 없음
질문별 출제량	0.0454		균등 — 차이 없음
시간대별 접속량	0.4544	■	뚜렷한 차이
접속 세션 길이	0.5128	■	뚜렷한 차이
받은 투표 수 (유저별)	1.7259	■	뚜렷한 차이
한 투표 수 (유저별)	7.2324	■	뚜렷한 차이

시간 간격은 전부 균등분포다

"실측 stddev ÷ 같은 범위 균등분포의 stddev" 를 잰다. 1.0 이면 완전한 균등분포다.

간격	범위	평균	균등도	판정
투표 세션 길이	2~20분	11.0분	1.054	완전 균등
문항 응답 시간	3~25초	14.0초	1.045	완전 균등
접속 세션 길이	2~25분	13.5분	1.042	완전 균등
받은 투표 열람 지연	1~72시간	36.3시간	1.014	완전 균등
광고 시청 시간	20~60초	39.5초	1.006	완전 균등
친구 요청 응답 지연	0~72시간	24.3시간	0.683	약간 앞쪽으로 쏠림

왜 이렇게 됐나 — 그리고 왜 고치지 않나

생성기가 전부 `rng.randint(lo, hi)` 를 쓴다. 예를 들어 `sessions.duration_minutes: [2, 25]` 는 2~25분을 같은 확률로 뽑는다. 실제 체류시간은 로그정규에 가깝다 — 짧은 것이 압도적으로 많고 긴 꼬리가 붙는다.

쓰는 쪽에서 할 일:

- 평균·합계는 유효하다. "평균 체류 13.5분", "평균 열람 지연 36시간"은 그대로 쓴다
 - 분포 형태·분위수·꼬리는 인용하지 않는다. p90 이 의미를 갖지 않는다
 - "세션이 길수록 투표를 많이 한다" 같은 가설은 검증되지 않는다 — 길이가 무작위라 어떤 것과도 상관이 없다
- 고치지 않는 이유: 이 축들을 로그정규로 바꾸면 전면 재생성이다(16분 생성 + 1시간 54분 적재 + 검수). 얻는 것은 "분포 형태 분석"인데, 이 프로젝트의 목표는 파이프라인과 대시보드지 분포 추정이 아니다. 다음 판본(v5)의 1순위 항목으로 남긴다.

부수 발견 — 앱 버전과 기기

`app_version` 은 **1.0.0/1.1.0/1.2.0** 이 매달 33%씩이다. 버전이 시간에 따라 돌아옴되지 않는다 — 버전별 비교·릴리스 영향 분석 불가.


`device_id` 는 유저당 1개인데 `platform` 은 유저당 3개인 사람이 10,651명이다. 같은 기기가 WEB/IOS/ANDROID를 오간다 — 플랫폼은 세션마다 새로 뽑히기 때문이다. 플랫폼·기기 단위 분석 불가.

12. ⚠️ 접속 세션과 투표 세션은 서로 독립이다

`user_session` (앱을 열었다)과 `vote_session` (투표를 시작했다)은 각각 따로 생성된다. 시간축에서 서로를 모른다.

측정	값	뜻
투표 세션이 접속 세션 창 안에 있는 비율	3.84%	96%는 "앱을 안 연 채" 투표한 셈
접속 세션 최대 공백	11일 20시간	휴면이 없다
투표 세션 최대 공백	319일	휴면이 있다

비율이 시간에 따라 드리프트한다



막대 = 접속 세션 1회당 투표 세션 수. 첫 달은 1.01 로 그럴듯한데 마지막 달은 6.45 다 — 한 번 앱을 열고 여섯 번 투표를 시작한 셈. 접속 세션은 계절성이 강하게 걸려 줄어드는데(4장) 투표 세션은 덜 줄기 때문이다.

쓰는 쪽에서 할 일

- "앱 열기 → 투표 시작 → 완료" 퍼널을 만들지 않는다. 두 표를 잇는 순간 숫자가 무의미해진다
- 접속 세션은 볼륨·시간대 지표로만 쓴다 — DAU/MAU, 시간대 히트맵, 계절성
- 휴면·복귀는 `vote_session` 으로 잰다(5장). 접속으로 재면 0명이다
- 세션 내 행동 분석은 `vote_session` → `vote_item` 한 갈래 안에서만 한다. 이쪽은 `session_id` 로 실제 연결돼 있다

왜 안 고치나: 두 표를 묶으려면 세션 생성 전체를 다시 짜야 한다 — 11장의 균등분포 문제와 함께 v5 에서 한 번에 하는 것이 맞다.

13. 이 데이터로 할 수 있는 것 / 없는 것

할 수 있다

분석	근거
시간대 히트맵	접속·투표 두 표 모두 5.3배/4.6배 리듬. KST 변환 필수
계절 효과 (방학 · 시험기간)	접속 평시 대비 30% · 18%
코호트 잔존 히트맵	11개 코호트 × M0~M9. M1→M2 낙차 2.8배
MAU · DAU/MAU 추이	979~6,688 진폭, stickiness 23.7~45.4%
유저 수명 분포 · 생존곡선	중앙값 4.6일 · 최대 324.6일. 이탈 분석은 이 축으로
휴면 · 복귀 코호트	736명. vote_session 기준으로만
성장 곡선 · 학교 계층 진입	6국면 전부 오차 0.5%p 안. 학교 규모 959→51명 순차
투표 세션 퍼널	status · item_count 일치. 완료 85.5%
민감 질문 신고율 검정	3.5배 — 이 데이터의 가장 확실한 가설검정
하트 경제 수치	7종 원장 · 적립 9,206만 · 소비율 54.0% · 일일 상한 작동
결제 전환 · LTV · 고래 분석	17.8% 전환 · ARPPU 14,291원 · 상위 10%가 매출 72.4%
결제자 세그먼트 · 전환 예측	결제자가 투표 1.55× · 힌트 1.37× — 상관이 실재한다
힌트 단계 이탈 곡선	단계마다 2.5배씩 감소, 6단계까지
친구 요청 퍼널 · 그래프 성장	수락 75.1% · 무응답 23.0% · 끊김 5.8%
인기도 집중 (순위 · 모양)	지니 0.657. 절대 수치는 인용 금지
신고 처리 큐 운영 지표	PENDING 41.3% — 실서비스 병목을 그대로 재현
학교 정보 화면 설계	급식·시간표·학사일정·공지 50개교 전부

주의해야 한다

함정	이유
UTC 그대로 시간 집계	봉우리가 9시간 밀린다
인기도 집중의 절대 수치 인용	49.3%는 활동 불균형(투표자 지니 0.936)이 만드는 구조적 값이다
같은 반/학교 비율 인용	설정(42%/80%)과 실측(23%/69%)이 다르다. 수로 보면 목표 안
게시판 참여율의 절대 수준	96%가 좋아요를 누른다 — 실제 커뮤니티와 다르다
결제 실패율	0.12% — 실서비스보다 훨씬 낮다
실서비스와 매출 혼용	합성은 실결제, 실서비스는 MVP-STUB- 접두어
탈퇴 코호트를 시각으로 안 자름	탈퇴자의 88.7% 가 탈퇴 후 활동이 있다 — "탈퇴자가 더 활발"해진다

할 수 없다

분석	이유
앱 열기 → 투표 퍼널	두 세션 표가 독립. 겹침 3.84% (12장)
체류시간 · 응답속도 분포	전부 균등분포. 평균만 유효 (11장)
이탈(탈퇴) 예측 모델	라벨과 피처가 독립. 수명으로 대체 (3장)
요일 효과	총량 CV 0.024. weekend_multiplier 가 안 읽힌다
질문별 인기 · A/B	출제량 CV 0.045. "인기 질문"이 없다
후보 슬롯 위치 편향	CV 0.0008. 검정하면 반드시 기각된다
문항 위치별 응답 품질 저하	CV 0.0001
성별 상호작용 (동성 선호)	지목이 성별에 무작위 — 인구 비중과 일치

게시판 카테고리별 차이	다섯 카테고리 CV 0.005
앱 버전 · 릴리스 영향	매달 33%씩 고정
플랫폼 · 기기 단위 분석	기기 1개가 플랫폼 3개를 오간다
광고 네트워크 비교	admob 하나뿐
힌트 완전 공개 구분	REVEALED 0건 (9장)
친구 요청 출처별 수락률	SEARCH 는 수락률 100%

14. 남은 미이행과 다음 판본

항목	출처	상태
2차 증분 배치	Q28	미실시. 증분 적재의 함정 4개(_source 없는 조인 · 컬럼 추가 후 워터마크 정지 · 지운 행의 유령 · 과거 시각 백필)를 실제로 재현해 볼 유일한 방법. 이제 가장 큰 미이행이다
앱을 생성기에 맞추기	—	투표 보상(앱 5~15 vs 생성기 2~10) · 일일 적립 상한(생성기 100/일 작동 확인 · 앱 없음). 생성이 확정된 지금이 그 시점이다
BigQuery 적재	P4	아직 합성을 안 올렸다. 예상 13.9 GiB · 월 약 135원. 쿼리 하드캡 30 GiB/일은 이미 걸려 있다
3국면 MAU 진폭	Q4	해소. 저점(979) 대비 회복(4,383) 4.5배 — 목표 2.5배 초과. v4 문서의 "2.2배"는 기준 미상이라 재현되지 않았다(5장)

v5 를 만든다면 — 이번 EDA 가 남긴 순서

순위	고칠 것	비용	얻는 것
1	시간 간격을 로그정규로	생성기 6줄	체류시간·응답속도·열람지연의 분포 분석이 열린다
2	투표 세션을 접속 세션 안에 넣는다	세션 생성 재설계	퍼널 분석이 열린다. 휴면 정의가 하나로 통일된다
3	탈퇴·BAN 이후 활동을 끊는다	생성기 조건 1개	이탈 예측이 가능해진다. 검사 2종을 추가할 수 있다
4	weekend_multiplier 를 읽는다	1줄	요일 효과가 생긴다
5	질문·슬롯·카테고리에 인기 편차를 준다	가중치 3곳	A/B·위치편향 연습 소재가 생긴다
6	REVEALED 전이 · 앱 버전 롤아웃 · 플랫폼 고정	각 1~3줄	자잘한 축이 살아난다

지금은 v4 로 간다. 1·2번은 전면 재생성(2시간 20분)이 필요하고, 얻는 것이 이 프로젝트의 목표(파이프라인·대시보드)가 아니다. P5 품질 검증과 P6 stg/mart 를 먼저 하고, 막히는 것이 나오면 그때 v5 를 만든다.

ping-v2 · 12개월 v4 (확정) · 2026-08-05 · 로컬 pgtest 실측 · seed 20260803 으로 재현 가능 · 정밀 EDA 9개 축 추가 · 판본별 결정 근거는 synthetic-data-decision-history.pdf