

합성 데이터 12개월 v5 — 확정 검수

20,000명 · 11.7개월 · 50학교 · 1억 2,370만 행 — v4 의 결함 1건과 경계 5건을 고쳤다

생성 2026-08-05 · synthetic-v2.yaml · seed 20260803 · 123,696,643행 · CSV 11GB

적재 로컬 pgtest · 정합성 17종 위반 0 · 이상치 9종 위반 0

이 판본의 목적 v4 EDA 가 찾아낸 결함 1건 + 경계 5건을 닫고, 작업자가 지정한 요구사항 7가지를 구현한다

이 문서의 범위 v4 리포트(27쪽)와 같은 축을 그대로 다시 재서 직접 비교가 되게 했다. 여기에 v5 에서 새로 생긴 축(세션 구조 · 분포 형태)을 더했다

⚠ 문서 판본 = 데이터 판본 12개월 데이터로는 다섯 번째다

0. 요약

판정 — 확정한다

요구사항 7가지 전부 충족 · 정합성 17종 0 · 이상치 9종 0 · 40표 전부 채워짐 · 목표 지표 전부 달성.

v4 의 유일한 결함(하루 406.8시간 투표)이 사라졌고, v4 에서 "할 수 없다"로 분류했던 15종 중 9종이 열렸다.

요구사항 7가지 — 전부 충족

#	요구	v4	v5	측정
1	시간 간격에 균등분포를 두지 않는다	1.01~1.05	0.15~0.54	균등도(1.0 = 완전 균등). 5종 측정
2	요일 패턴 — 구 서비스를 따라 간다	CV 0.024	CV 0.18~0.24	순위 7개 전부 일치
3	행동은 접속 세션 안에서만	3.84%	99.99%	투표 세션이 접속 세션 창 안에 있는 비율
4	세션 로그에 노이즈를 섞는다	없음	0.399%	중복 행 3,944건 · 늦은 종료
5	탈퇴 후 로그 금지	9종 전부 발생	9종 전부 0	v4 는 하트 거래만 128만 건
6	투표 시간의 일관성	19.50% 어긋남	0.00%	상관 0.0007 → 0.7005
7	좋아요 유저 비율 60%	95.9%	59.6%	활성 18,001명 기준 (전체 기준 53.6%)

물리적 불가능 — 해소

측정	v4	v5	비고
하루 투표 시간 최대	406.8시간	7.9시간	하루는 24시간이다
하루 투표 세션 최대	2,243회	51회	개수가 아니라 시간으로 제약한다
24시간 초과 유저-일	1,251일 (67명)	0일	
하루 앱 체류 최대	—	22.3시간	중복 로그 제거 시 19.0시간. 24시간 초과 0

개수 상한은 쓰지 않았다. 처음엔 하루 12회로 잘라 봤는데 헤비유저가 통째로 사라져 행이 반토막(9,509만) 나고 지목 쓸림이 39% 로 주저 않았다 — 결함이 아니라 분포를 죽인 것이었다. 사람이 하루에 낼 수 있는 시간만 제약하고 그 안에서는 내버려 두는 방식으로 바꿨다.

남은 것 — 이번에 못 닫은 3가지

항목	v4	v5	왜 남았나
BAN 제재 후 활동	13,273	2,693 (34명)	요구사항은 탈퇴였다. 제재는 범위 밖이라 손대지 않았다 — 부수 효과로 80% 줄었을 뿐이다
광고 시청 시간이 균등	1.006	1.005	빠뜨렸다. 시간 간격 7곳을 로그정규로 바꾸면서 ad_impression 한 곳을 놓쳤다
차단 후 후보 노출	0	2	차단이 세션 안으로 들어오며 시각이 당겨져 생긴 2건. 무시 가능

1. 판본 이력

판본	행	문서	무슨 일이 있었나
12m v1 8/4	1억 4,126만	-v1	성장 곡선 첫 구현. 결함 8건
12m v2 8/4	1억 8,826만	-v2	7건 해결. 전면 감사에서 새 결함 3건
12m v3 8/4	1억 8,918만	-v3	감사 3건 해결. 접속 세션 결함으로 폐기
12m v4 8/5	1억 8,922만	-v4	확정했으나 정밀 EDA 에서 결함 1 · 경계 5 발견
12m v5 8/5	1억 2,370만	-v5	확정. 결함 1 · 경계 5 를 닫고 요구사항 7가지 구현

행이 v4 보다 35% 적다. 하루 시간 예산이 불가능한 꼬리를 잘라냈기 때문이다 — 줄어든 것이 아니라 없어야 했던 것이 빠졌다.

목표 지표

지표	목표	v4	v5	판정
친구 5명 해금률	90~95%	92.7%	92.6%	통과
힌트 구매 유저	70~80%	77.6%	76.1%	통과
받은 투표 0건	소수	6.3%	6.6%	통과
상위 10% 지목 점유	49%	49.3%	49.8%	통과
완료율 두 측정 차	일치	0.4%p	0.4%p	통과
민감 질문 신고 배수	2배+	3.5배	3.8배	통과
접속 세션 시간대	리듬	5.3배	3.1배	약해짐
같은 반 친구 0~3명	15% 미만	14.7%	14.7%	통과

⚠ 시간대 대비가 5.3배 → 3.1배로 약해졌다. 세션 병합의 부작용이다 — 30분 안에 이어지는 행동을 한 세션으로 묶으니, v4 에서 저녁에 5 개로 세지던 것이 1개가 된다. 봉우리 시각(21시)과 모양은 그대로다. 자세한 것은 4장.

2. 데이터 범위와 인구

항목	값
기간	2025-09-01 ~ 2026-07-23 (356일)
유저 · 학교 · 학급 · 질문	20,000명 · 50교 · 834학급 · 240문항
표 · 행	40표 전부 채워짐 · 123,696,643행 · CSV 11GB

측	분포	평균 친구
성별	F 11,792 (59.0%) · M 8,208 (41.0%)	37.4 / 37.6
학년	1학년 6,672 · 2학년 6,682 · 3학년 6,646 (각 33%)	37.8 / 37.7 / 36.9
학교 유형	고교 30곳 11,528명 · 중학 20곳 8,472명	37.1 / 37.9
상태	ACTIVE 18,001 (90.0%) · WITHDRAWN 1,999 (10.0%)	37.3 / 38.4

학교가 처음 열린 달 — 계층 진입



막대 = 그 달에 처음 열린 학교 수. 평균 정원이 1,013명 → 51명으로 단조 감소한다 — 큰 학교부터 순차로 열리는 설계가 작동한다.

학교 계층 — 큰 학교가 먼저 열린다

계층	학교	유저	학교당	진입 기간	해금률
1 (큰 학교)	17	13,668	804	2025-09 ~ 2026-02	92.7%
2 (중간)	17	5,177	305	2025-10 ~ 2026-05	92.9%
3 (작은 학교)	16	1,155	72	2026-03 ~ 2026-06	91.9%

학교당 평균 규모가 959명 → 51명으로 단조 감소한다. 계층 진입이 설계대로다.

3. 무결성

정합성 17종 — 전부 0 (qa/checks/integrity.sql)

#	검사	심각도	위반	무엇을 막는가
1	하트 원장 vs 잔액 불일치	HIGH	0	구 시스템의 가장 큰 결함
2	원장 누적합 오류 (balance_after)	HIGH	0	잔액 재구성 불가
3	음수 잔액 발생	HIGH	0	
4	원장 없는 유료 힌트 구매	HIGH	0	광고 무료 힌트는 제외한다
5	원장 없는 충전	HIGH	0	
6	가입 이전 활동	HIGH	0	
7	가입 이전 세션	HIGH	0	세션을 재설계했으므로 이번에 특히 중요
8	출제 이전 투표	HIGH	0	

9	선택 없는 완료 투표	HIGH	0	
10	후보 4명이 아닌 라운드	MEDIUM	0	
11	광고 미완료 셔플	HIGH	0	셔플하려면 광고를 끝까지 봐야 한다
12	친구 아닌 후보	HIGH	0	"투표 당시 친구였는가"를 묻는다
13	CLASS 스코프에 설명 안 되는 타반 후보	HIGH	0	<code>padded_count</code> 로 설명돼야 한다
14	SCHOOL 스코프에 설명 안 되는 타고 후보	HIGH	0	
15	자기 자신이 후보	HIGH	0	
16	게이트 위반 (5명 맺어본 적 없는데 해금)	HIGH	0	"통틀어 5명"을 묻는다
17	<code>friend_count</code> 불일치	MEDIUM	0	<code>ended_at</code> IS NULL 만 센다

이상치 9종 — 전부 0

#	검사	위반	#	검사	위반
1	미래 시각 가입	0	6	투표 시각 < 출제 시각	0
2	음수 하트 잔액	0	7	세션 완료 < 시작	0
3	빈 닉네임	0	8	자기 자신과 친구	0
4	닉네임 중복	0	9	끊긴 시각 역전	0
5	초대 코드 중복	0	+	접속 세션 종료 < 시작	0

⚠ 이상치 9종은 파일로 존재하지 않는다. `qa/checks/` 에는 `integrity.sql` 하나뿐이고 9종은 판본마다 손으로 다시 친다. 이름만 리포트에 남아 있어 검사가 판본 간에 표류할 위험이 있다 — `qa/checks/outliers.sql` 로 고정하는 것이 좋다.

검사가 못 잡는 것 — v4 대비

묻지 않는 것	v4	v5	판정
탈퇴 후 하트 거래	1,282,199	0	단힘
탈퇴 후 투표 세션	3,049	0	단힘
탈퇴 후 게시글	3,702	0	단힘
탈퇴 후 결제	1,055	0	단힘
탈퇴 후 접속 세션 · 댓글 · 좋아요 · 신고 · 공지열람	발생	0	단힘
BAN 제재 후 투표	13,273	2,693	남음 — 34명 · 평균 48.3일 뒤
차단 후 후보 노출	0	2	무시 가능
하루 24시간 초과 활동	1,251	0	단힘

⚠ BAN 은 왜 안 단혔나

작업자의 요구는 탈퇴였다. 제재(`sanction`)는 범위 밖이라 손대지 않았고, 2,693건은 탈퇴 규칙의 **부수 효과**로 줄어든 것이다.

구조적으로는 같은 문제다 — 제재가 **9단계**에서 만들어지는데 투표는 **5단계**라, 나중에 찍힌 BAN 이 이미 만들어진 투표보다 앞설 수 있다. **고치려면 탈퇴와 같은 방식**(활동을 먼저 훑고 그 뒤에 제재를 찍는다)이면 된다.

쓰는 쪽에서 할 일: 제재 코호트를 만들 때 `starts_at` 이후 활동을 걸러낸다. 34명이므로 영향은 작다.

4. 세션 — 이번 판본의 핵심

v4 는 `user_session` (앱을 열었다)과 `vote_session` (투표를 시작했다)을 **따로** 만들었다. 서로의 시각을 몰라서 투표 세션의 **3.84%** 만 접속 세션 창 안에 있었고, 접속 1회당 투표 세션 비가 1.01 → 6.45 로 드리프트했다.

v5 의 규칙

규칙	구현
직접 행동은 접속 세션 안에서만	투표 · 힌트 · 글 · 댓글 · 좋아요 · 신고 · 차단 · 공지열람 전부
30분 넘게 비면 새 세션	실서비스 <code>touch_session()</code> 과 같은 정의
아무것도 안 하고 닫는 세션도 있다	<code>browse_only_ratio: 0.35</code>
하루 상한은 시간으로만	투표 6시간 · 체류 10시간. 개수 제한 없음

측정	v4	v5
투표 세션이 접속 세션 안에	3.84%	99.99%
접속 1회당 투표 세션 (평균)	1.01 → 6.45 드리프트	1.41 (0.30~2.14)
접속 세션 수	1,013,890	987,624
유저당 세션 (중앙값)	19	4

유저당 세션 중앙값이 19 → 4 로 줄었다. 세션이 사라진 것이 아니라 합쳐진 것이다 — 저녁에 이어서 한 행동이 v4 에서는 5개 세션, v5 에서는 1개 세션이 된다.

세션 안에서 무엇을 했나



한 번 열어 **1라운드**가 65%로 가장 흔하다. 열어만 보고 닫는 세션이 11.9% 있어 "접속했지만 아무것도 안 함"이라는 상태가 데이터에 존재한다.

세션 길이 히스토그램 — 긴 꼬리가 생겼다



v4 는 2~25분에 **평평하게** 퍼져 있었다(각 구간 20.8%). v5 는 5~10분에 봉우리가 있고 오른쪽으로 길게 끌린다 — **로그정규의 모양**이다.

세션 길이 — 로그정규가 됐다

표	최소	중앙값	평균	p90	p99	최대	균등도
접속 세션 (v4)	2.0	13	13.5	23	25	25	1.042
접속 세션 (v5)	0.9	10.4	20.8	45.5	161.9	717.7	0.154

단위 분. v4 는 2~25분 **완전 균등**이라 p99 가 25분이었다. v5 는 중앙값 10분에 **긴 꼬리**가 붙는다 — 실제 체류시간의 모양이다. 이제 "체류가 길수록 많이 투표한다" 같은 가설을 검증할 수 있다.

로그 노이즈 — 운영 환경 흉내

노이즈	건수	비중	뜻
같은 세션 행 중복	3,944	0.399%	재시도 · 중복 전송. 같은 유저·같은 시각이 두 벌
늦은 종료 기록	설정 0.2%	—	종료가 늦게 도착해 끝이 늘어난다

⚠ 중복 로그가 지표를 부풀린다 — 의도된 것이다


하루 앱 체류 최대가 원시 로그 22.3시간 · 중복 제거 19.0시간이다. 차이 3.3시간이 중복 행 때문이다.
이것이 노이즈를 넣은 목적이다 — 실제 운영 로그에서 중복 제거를 안 하면 체류시간이 부풀려진다는 것을 이 데이터로 연습할 수 있다. `DISTINCT user_id, started_at, ended_at` 으로 걸러내면 된다.

5. 시간 리듬

요일 — 구 서비스 실측을 따라간다

출처는 `raw/legacy-analysis/08_attendance_feature.md` §2 다. 단조 우하향이 아니라 V자다 — 월·화가 높고 **금요일이 최저**, 주말에 회복한다.


요일	월	화	수	목	금	토	일
원본 (ping v1)	1.00	0.97	0.73	0.70	0.66	0.85	0.90
v5 접속	1.00	0.98	0.72	0.69	0.63	0.88	0.94
v5 투표	1.00	0.97	0.63	0.61	0.54	0.81	0.89
v4 (효과 없음)	1.00	1.02	0.96	0.97	0.96	0.97	1.00



접속 세션. 순위 7개가 원본과 정확히 같다(월>화>일>토>수>목>금). 접속은 진폭까지 맞고(오차 최대 0.04), 투표는 **과교정**됐다(금 0.54 vs 목표 0.66).

⚠ 투표가 과교정된 이유 — 요일 가중치가 접속 세션과 투표 세션 양쪽에 각각 걸리는데 투표는 세션 창 안에 들어가야 해서 한 번 더 걸린다. 두 번 곱해진 셈이다. 순위와 모양은 맞으므로 요일 효과 분석에는 지장이 없다.

시간대 24시간 (KST, 접속 세션)



봉우리 셋 — 점심(12~13시) · 하교 후(16~18시) · **밤(19~22시)**. 최고 21시 5.99% ÷ 최저 4시 1.92% = **3.1배**(v4 는 5.3배).

시간대 — 리듬은 있으나 대비가 약해졌다

측정	v4	v5
최고 시각 · 비중	22시	21시
최저 시각	4시	4시
최고 / 최저	5.3배	3.1배
변동계수	0.454	0.308

⚠ 왜 약해졌나 — 세션 병합의 부작용

30분 안에 이어지는 행동을 한 세션으로 묶으면, 저녁에 몰린 활동이 **여러 세션이 아니라 하나의 긴 세션**이 된다. 세션 **시작** 시각을 세는 히트맵에서는 그만큼 봉우리가 낮아진다.

더 현실적인 모양이다 — 실제로 저녁에 앱을 다섯 번 따로 열지 않는다. 다만 **히트맵의 색 대비는 약해진다**. 시간대 분석을 할 때는 세션 수가 아니라 **세션이 덮은 시간**이나 `vote_item.served_at` 으로 세는 편이 낫다.

계절성

구간	접속 일평균	평시 대비
평시	3,557	100%
겨울방학 (12월 말)	1,502	42%
trough 국면 (1~2월)	999	28%

6. 성장 · 코호트 · 수명 · 탈퇴

성장 국면 — 목표 대비

국면	기간	목표	실측
launch_spike	2025-09	35%	34.5%
decline	2025-10~12	15%	14.5%
trough	2026-01~02	5%	5.3%
spring_spike	2026-03	20%	19.9%
slow_fade_1	2026-04~05	15%	15.2%
slow_fade_2	2026-06~07	10%	10.2%

월별 지표 — 신규 · MAU · DAU/MAU

월	신규	MAU	평균 DAU	DAU/MAU	접속 세션	투표 세션	비
2025-09	6,905	6,391	1,269	19.9%	139,179	183,224	1.32
2025-10	957	3,170	946	29.8%	84,491	102,497	1.21
2025-11	950	1,922	725	37.7%	78,829	106,937	1.36
2025-12	985	1,690	484	28.7%	46,252	61,079	1.32
2026-01	524	1,098	371	33.7%	31,638	38,592	1.22
2026-02	539	1,063	352	33.1%	27,277	33,184	1.22
2026-03	3,974	4,514	1,139	25.2%	149,033	239,408	1.61
2026-04	1,480	3,236	1,061	32.8%	122,071	186,765	1.53
2026-05	1,558	2,817	991	35.2%	137,222	235,983	1.72
2026-06	1,169	2,238	772	34.5%	95,094	157,012	1.65
2026-07 (23일)	874	1,799	727	40.4%	76,526	141,664	1.85

MAU 진폭 최고 6,391(9월) → 최저 1,063(2월) → 회복 4,514(3월). 저점 대비 회복 4.2배로 Q4 목표(2.5배)를 넘는다. 맨 오른쪽 비는 접속 1 회당 투표 세션 수 — v4 는 1.01→6.45 로 드리프트했는데 v5 는 1.21~1.85 안에 머문다. 두 표가 같은 사건에서 나오기 때문이다.

코호트 잔존 (%)

가입 월	인원	M0	M1	M2	M3	M4	M5	M6	M9
2025-09	6,976	91.5	34.2	11.5	6.2	3.5	3.8	5.8	2.4
2025-10	961	84.5	33.1	11.6	6.8	4.6	5.8	5.5	2.6
2025-11	945	85.1	32.4	9.9	6.9	7.4	7.5	5.6	—
2025-12	996	84.9	29.1	10.4	9.1	6.4	5.1	3.1	—
2026-01	525	77.5	33.5	17.0	9.9	5.1	5.1	5.0	—
2026-02	497	79.9	35.0	11.5	6.4	2.8	2.4	—	—
2026-03	4,003	90.7	34.4	11.3	6.2	3.8	—	—	—
2026-04	1,477	83.1	34.6	12.0	6.3	—	—	—	—
2026-05	1,562	88.8	33.6	10.4	—	—	—	—	—
2026-06	1,169	83.3	29.0	—	—	—	—	—	—
2026-07	889	90.3	—	—	—	—	—	—	—

M1→M2 낙차 3.0배. M3 이후 3~9%대에서 완만하게 늡는다. 겨울 코호트(1월)가 가장 잘 남는다 — M2 17.0%.

★ 복귀 코호트 — v4 에서 불가능했던 것

측정	v4	v5
user_session 30일+ 공백 유저	0명	748명
user_session 최대 공백	11일 20시간	300일+
월별 복귀자(resurrected) 합	0	733

월	25-11	26-01	26-02	26-03	26-04	26-05	26-06	26-07
복귀자	2	1	61	266	144	123	58	78

v4 의 함정이 사라졌다

v4 에서는 복귀를 vote_session 으로만 잴 수 있었다. user_session 으로 재면 최대 공백이 11일 20시간이라 복귀자가 0명으로 나왔다 — 두 표가 독립이라 생긴 함정이었다.

v5 는 접속 세션이 활동에서 파생되므로 어느 표로 재도 같은 답이 나온다.

유저 수명

평균	중앙값	p90	최대	하루짜리
24.7일	3.2일	70.7일	323.6일	5,979명 (32%)

★ 탈퇴 — 이탈 예측이 가능해졌다

비교	v4 ACTIVE	v4 탈퇴	v5 ACTIVE	v5 탈퇴
투표 세션	115.6	119.4	75.9	59.9
하트 잔액	2,133	1,956	1,944	1,774
평균 친구	37.5	37.3	37.3	38.4

v4 에서는 "탈퇴자가 더 활발"했다

v4 는 탈퇴가 라벨일 뿐이라 활동과 독립이었다. 탈퇴자가 오히려 투표를 더 많이 했고(119.4 vs 115.6), 그래서 어떤 이탈 예측 모델도 학습되지 않았다.

v5 는 탈퇴자의 투표 세션이 21% 적다(59.9 vs 75.9). 방향이 맞으므로 이탈 예측을 연습할 수 있다.

사유	인원	비중	
NO_FRIENDS	593	29.7%	
BORING_CONTENT	537	26.9%	
NOT_USING	390	19.5%	
OTHER	276	13.8%	
TOO_MANY_BUGS	115	5.8%	
PRIVACY	88	4.4%	

탈퇴 1,999명(10.0%). 가입~탈퇴 생존기간 중앙값 137일 (v4 는 7일이었다 — v4 의 탈퇴 시각이 활동과 무관하게 찍혔기 때문이다).

7. 투표

항목	v4	v5	비고
투표 세션	2,320,125	1,486,346	
출제 문항	21,174,376	13,444,558	세션당 9.04
실제 투표	20,391,049	12,946,981	96.3% — 설정 정확
후보 행	105,568,896	67,081,288	
셔플	4,800,272	3,059,259	문항의 22.8%

세션 퍼널

상태	건수	비중	평균 문항	
COMPLETED	1,251,013	84.2%	10.00	
EXPIRED 중도 이탈	228,976	15.4%	3.80	
IN_PROGRESS	6,357	0.4%	10.00	

★ 세션 시간의 일관성 — v4 에서 깨져 있던 것

측정	v4	v5
종료가 마지막 문항보다 앞선 세션	386,769 (19.50%)	3 (0.00%)
세션 길이 ↔ 문항 소요시간 상관	0.0007	0.7005
세션 길이 균등도	1.054	0.471
평균 세션 / 평균 문항 구간	11.00 / 5.22분	6.51 / 4.16분

v4 는 세션 종료를 `started + randint(2,20)분` 으로 문항과 무관하게 뽑았다. 그래서 완료 세션의 19.5%가 마지막 문항보다 먼저 끝났고, 상관이 0.0007 이었다 — "오래 붙잡은 세션"이라는 것이 데이터에 존재하지 않았다. v5 는 마지막 문항 뒤에 꼬리를 붙여 계산하므로 상관이 0.70 이다.

스코프 · 질문

스코프	문항	비중	설정	보충 발생	평균 셔플
SCHOOL	4,668,108	34.7%	35%	17.98%	0.248
CLASS	4,388,632	32.6%	35%	17.98%	0.247
GLOBAL	4,387,818	32.6%	30%	0.00%	0.247

질문 카테고리 8종

카테고리	문항	출제	비중	신고	1천건당	민감
PERSONALITY	40	2,279,169	17.0%	728	0.319	아니오
SCHOOL_LIFE	38	2,112,030	15.7%	723	0.342	아니오
TALENT	32	1,825,147	13.6%	558	0.306	아니오
FUTURE	31	1,791,693	13.3%	576	0.321	아니오
RELATIONSHIP	32	1,764,939	13.1%	582	0.330	아니오
TASTE	26	1,447,373	10.8%	498	0.344	아니오
HUMOR	26	1,412,445	10.5%	493	0.349	아니오
APPEARANCE	15	811,762	6.0%	1,003	1.236	예

비민감 7종이 0.306~0.349 로 촘촘히 모여 있고 민감 1종만 1.236 으로 튀어 있다 — 대조군이 깨끗해서 검정력이 좋다.

민감 질문 신고율 — 3.8배

카테고리	민감	출제	신고	1천건당
APPEARANCE	예	811,762	1,003	1.236
나머지 7개 카테고리	아니오	12,632,796	4,158	0.329

민감 질문이 3.76배 더 신고된다(v4 3.5배). is_sensitive 플래그를 데이터로 검증할 수 있다 — 이 데이터의 가장 확실한 가설검정 소재다. 비민감 7종은 0.306~0.349 로 서로 붙어 있어 대조군이 깨끗하다.

후보 슬롯 · 성별 — 여전히 차이 없음

슬롯	1번	2번	3번	4번
선택률	18.07%	18.18%	18.18%	18.05%

변동계수 0.0039. 위치 편향은 이 데이터에 없다 — 검정하면 반드시 기각된다. 성별 지목도 인구 비중과 같아 동성 선호가 없다. 둘 다 v4 와 같고, 이번 요구사항에 없었다.

8. 투표 활동 분포

v4 리포트 7-2장에서 결함이 나온 자리다. 같은 방식으로 다시 켜다.

분위수 — 투표한 16,562명

판본	p10	p25	중앙값	p75	p90	p99	최대	평균
v4	7	10	29	252	1,511	23,693	545,707	1,224
v5	5	10	22	193	1,117	16,000	133,795	782

최대가 545,707 → 133,795 로 4분의 1이 됐다. 꼬리가 잘린 것이 아니라 사람이 낼 수 있는 시간 안으로 들어왔다.

집중도

상위	0.1%	1%	5%	10%	20%	지니
v4 — 던진 투표	15.85%	48.54%	79.64%	89.51%	96.20%	0.9364
v5 — 던진 투표	9.52%	41.86%	75.97%	87.46%	95.39%	0.9257
v5 — 받은 투표	—	11.9%	—	48.2%	66.5%	0.6622

여전히 집중돼 있다 — "소수가 대부분을 던진다"는 것 자체는 실서비스에서도 참이다. 달라진 것은 그 소수가 사람이라는 점이다. 상위 0.1% (17명)의 점유가 15.85% → 9.52% 로 내려왔다.

히스토그램 — 이중 봉우리는 유지된다

던진 투표	인원	인원%		투표 합	투표%	
0 안 함	3,438	17.2%		0	0.00%	
1~9	3,513	17.6%		19,097	0.15%	
10~49	6,563	32.8%		122,591	0.95%	
50~99	1,211	6.1%		86,314	0.67%	
100~249	1,549	7.7%		251,972	1.95%	
250~499	1,051	5.3%		375,359	2.90%	
500~999	913	4.6%		656,212	5.07%	
1,000~2,499	832	4.2%		1,329,258	10.27%	
2,500~4,999	392	2.0%		1,363,263	10.53%	
5,000~9,999	243	1.2%		1,713,746	13.24%	
10,000+	295	1.5%		7,029,169	54.29%	

인원 투표 수

v4 에서 최상위 구간이 66.52% 였는데 v5 는 54.29% 다. 모양(이중 봉우리)은 그대로 극단만 완화됐다 — 사람은 10~49표에 몰리고 투표 는 상위 구간이 가져간다.

로렌츠 곡선 — 전체 20,000명



막대 = 그 지점까지 누적된 투표 점유율. 완전 균등이면 대각선이 된다. 하위 90%가 10.00%(v4 는 8.35%) — 조금 완만해졌다. 지니 0.9257.

상위 10명 — 이제 사람인가

순위	던진 투표	투표 세션	활동일	일평균 세션	친구	받은 투표
1	133,795	14,421	314일	45.9	87	681
2	113,034	12,579	291일	43.2	22	199
3	106,394	11,114	226일	49.2	59	0
4	96,181	10,493	242일	43.4	51	325
5	83,233	8,899	309일	28.8	46	151
6	82,810	9,438	299일	31.6	9	2
7	78,727	8,797	295일	29.8	52	385
8	76,914	8,462	213일	39.7	29	100
9	69,008	7,305	263일	27.8	9	101
10	61,965	6,974	201일	34.7	56	97

v4 와 비교하면 — 꼬리가 사람이 됐다

1위 유저	v4	v5
던진 투표	545,707	133,795
투표 세션	56,982	14,421
일평균 세션	252회	45.9회
최다 활동일	554세션 · 99.2시간	51세션 · 7.9시간

v4 는 하루에 99.2시간을 투표한 날이 있었다. v5 는 최다 7.9시간이다 — 극단적이지만 하루 안에 들어간다. 여전히 이상한 구석은 있다: 3위·6위는 받은 투표가 0~2건이고 6위·9위는 친구가 9명뿐인데 8만 표를 던졌다. 같은 소수를 반복해서 지목한 것인데, 인기도와 활동이 독립이라 생기는 정상적인 결과다.

이제 절대 수치를 인용할 수 있다

v4 리포트는 "상위 1% 세그먼트를 보지 말 것 · 집중 지표 절대값을 인용하지 말 것" 두 규칙을 걸어야 했다. 그 167 명이 하루 100~2,243세션을 돌아서 사람이 아니었기 때문이다.

v5 는 하루 최대 51세션 · 7.9시간이다. 극단적이지만 사람 범위 안이므로 두 규칙이 모두 해제된다.

9. 하트 경제 · 결제 · 힌트 · 광고

유형	건수	건당	총 증감	뜻
VOTE_REWARD	16,218,177	+3.07	+49,863,550	적립의 67%
HINT_PURCHASE	1,401,449	-20.48	-28,701,860	소비의 81%
VOTE_REPLY	333,566	-20.00	-6,671,320	답장
SIGNUP_GRANT	20,000	+300	+6,000,000	가입 지급
TOPUP	13,499	+1,327	+17,907,132	결제 충전
EVENT_GRANT · ADMIN_ADJUST	1,365	—	+135,450	이벤트 · 운영자 보정

적립 73,906,132 · 소비 35,373,180 — 소비율 47.9%. 일일 적립 상한 100 이 작동한다 — 223만 유저-일 중 7.0% 가 상한에 부딪힌다.

하트 잔액 · 결제

최소	p10	중앙값	p90	p99	최대	평균	잔액 0
0	14	448	3,877	26,545	121,891	1,927	79명

지표	v4	v5	비고
결제 유저	3,556 (17.8%)	3,607 (18.0%)	설정 18%
총 매출	50,819,500원	47,381,100원	
ARPU	2,541원	2,369원	전체 2만 명 기준
ARPPU	14,291원	13,136원	중앙값 3,800원 · 최대 269,300원
상위 10%가 매출의	72.4%	70.4%	고래 구조 유지
실패율	0.12%	0.13%	실서비스보다 훨씬 낮다

결제자와 비결제자는 실제로 다르다

집단	인원	평균 친구	투표 세션	힌트	하트 잔액
결제자	3,607	39.1	125.7	103.7	5,875
비결제자	16,393	37.0	63.0	75.7	1,058
배수	—	1.06×	2.00×	1.37×	5.6×

v4 는 1.55배였는데 v5 는 2.00배로 벌어졌다 — 불가능한 꼬리가 빠지면서 정상 유저 안의 차이가 또렷해졌다. 결제 전환 예측에 더 좋다.

힌트

유형	건수	비중	평균 비용	광고 무료
GENDER	419,951	26.0%	9.79	214,429
FINAL · INITIAL · CLASS · MEDIAL	1,187,516	73.5%	20.00	0
FULL_NAME	8,411	0.5%	100.00	0

힌트 단계별 — 살수록 비싸진다

단계	건수	비중	평균 비용	광고 무료	
1	1,012,737	62.7%	17.68	117,683	
2	373,335	23.1%	16.96	56,673	
3	148,134	9.2%	16.50	25,956	

4	59,874	3.7%	22.09	10,623	
5	20,225	1.3%	26.89	3,494	
6	1,573	0.1%	100.00	0	

구매자 **15,216명(76.1%)**. 단계별로 **2.7배씩** 줄어드는 이탈 곡선. 받은 투표 열람률 **55.2%** · 답장률 **5.1%**. 열람까지 걸린 시간은 중앙값 **4.5시간**(v4 36시간 — 균등분포였다).

⚠️

reveal_status='REVEALED' 는 여전히 0건이다

이름을 산 **8,411건**이 전부 PARTIAL 로 남는다. v4 와 같다 — 이번 요구사항에 없어서 손대지 않았다. 구분이 필요하면 hint_purchase.hint_type = 'FULL_NAME' 으로 조인한다.

광고

지면 · 상태	건수	비중
VOTE_SHUFFLE · COMPLETED	3,059,259	86.4%
VOTE_SHUFFLE · ABANDONED	265,859	7.5%
HINT_UNLOCK · COMPLETED	214,429	6.1%

⚠️ 시청 시간이 아직 균등하다(20~60초, 균등도 1.005). 시간 간격 7곳을 로그정규로 바꾸면서 **여기 한 곳을 빠뜨렸다**. 네트워크는 `admob` 하나뿐이라 네트워크 비교는 여전히 불가.


10. 친구 · 게시판 · 신고 · 학교 정보

친구 그래프

항목	v4	v5
친구 관계 (살아 있는)	374,514	374,157
요청 수락 / 무응답 / 거절	75.1 / 23.0 / 1.9%	75.1 / 23.0 / 1.9%
요청 응답 지연 (중앙값)	24.1시간	3.9시간
끊김률	5.8%	5.9%
해금률	92.7%	92.6%
같은 반 친구 0~3명	14.7%	14.7%

요청 응답 지연이 24.1시간(균등분포의 중앙값) → 3.9시간으로 바뀌었다. 대부분 몇 시간 안에 답하고 일부가 이를 넘게 끄는 현실적인 모양이다.

친구 수 분포



10~19명 구간이 움푹 파여 있다 — 친구 관계가 양방향이라 게이트(5명)를 넘긴 유저가 20명대로 끌려 올라가기 때문이다. 최대 388명.

해금하고도 투표 안 하는 유저 — 의도된 기율기

친구 수	인원	투표 0회	비율
5명 미만 (미해금)	1,465	1,465	100%
정확히 5명	303	154	50.8%
6~9명	1,136	406	35.7%
10~19명	1,043	197	18.9%
20~39명	9,673	958	9.9%
40명 이상	6,380	238	3.7%

친구가 적을수록 안 한다. 다만 40명 이상인데 안 하는 사람도 238명 있다 — 0이 아니어야 "친구 수가 곧 활동"이라는 동어반복을 피한다. v4 와 같은 기율기가 유지됐다.

게시판

참여 단계	v4	v5	활성 대비
좋아요를 누름	19,180 (95.9%)	10,725	59.6%
댓글을 씀	13,482	11,128	61.8%
글을 씀	7,739	7,563	42.0%

요구사항 7번이 적용됐다. v4 는 96%가 좋아요를 눌러 "관망하는 다수"가 없었다. 글 44,010(PUBLISHED 43,986 · DELETED 1,376) · 댓글 40,370 · 글 좋아요 178,167 · 댓글 좋아요 10,035.

카테고리	글	비중	평균 좋아요	평균 댓글	평균 조회
HOBBY	9,120	20.2%	3.98	0.90	66.7

COUNSEL	9,108	20.2%	3.79	0.86	64.5
LOVE	9,073	20.1%	3.73	0.91	63.4
CAREER	9,032	20.0%	4.07	0.88	67.8
FREE	9,029	20.0%	4.06	0.90	68.8

다섯 카테고리가 여전히 **완전** **균등**하다(CV 0.0046) — 이번 요구사항에 없었다. **카테고리별 차이 분석**은 불가능하다.

신고 사유 12종

사유	건수	비중	사유	건수	비중
U_HARASSMENT	3,348	10.8%	P_SPAM	2,467	7.9%
U_SPAM	3,326	10.7%	P_ABUSE	2,429	7.8%
U_IMPERSONATION	3,210	10.3%	P_SEXUAL	2,417	7.8%
U_INAPPROPRIATE	3,202	10.3%	Q_ETC	1,330	4.3%
C_SPAM	2,760	8.9%	Q_APPEARANCE	1,310	4.2%
C_ABUSE	2,748	8.9%	Q_OFFENSIVE	1,281	4.1%

대상 유형 안에서는 **균등**하다(U_* 각 10.3~10.8% · P_* 각 7.8~7.9% · Q_* 각 4.1~4.3%). **Q_APPEARANCE** ('외모 비하 소지')가 실제로 쓰인다.

추천 거절 (실서비스 0행인 표)

거절 사유	SAME_SCHOOL	SAME_CLASS	MUTUAL_FRIEND
건수 · 비중	3,489 (60.3%)	1,456 (25.2%)	844 (14.6%)

신고 · 제재

신고 대상	건수	비중	상태	건수	비중
USER	13,086	42.1%	DISMISSED	15,750	50.7%
POST	7,313	23.5%	PENDING	10,140	32.6%
COMMENT	5,508	17.7%	ACTIONED	5,178	16.7%
QUESTION	5,161	16.6%	신고 31,068 건 · 제재 전환 7.11%		

제재 2,210건 — WARNING 1,301 · SUSPEND 679(현재 유효 25) · BAN 230. 차단 747건. **PENDING 32.6%** 는 실서비스의 병목(신고 처리 화면 없음)을 그대로 재현한다.

학교 정보 — 50개교 전부

급식	급식 메뉴	시간표	학사일정	공지	공지 열람
15,650	82,744	25,020	1,860	1,836	145,095

공지 1건당 평균 79.0회 열람, 열람자 18,228명. 급식·시간표·학사일정·공지 모두 50개교 전부.

11. 분포 형태 점검

v5 의 핵심 개선이다. 변동계수(CV) 와 균등도 두 지표로 전 축을 훑었다.

축별 변동계수 — v4 대비

축	v4	v5		판정
요일별 투표량	0.0246	0.2386		열렸다
요일별 접속량	0.0236	0.1797		열렸다
접속 세션 길이	0.5128	1.5406		열렸다
질문별 출제량	0.0454	0.1137		표본 노이즈 — 설계된 차이 아님
시간대별 접속량	0.4544	0.3077		약해짐 (세션 병합)
받은 투표 수	1.7259	1.6797		유지
한 투표 수	7.2324	5.1267		완화 (꼬리 제거)
게시판 카테고리	0.0051	0.0046		그대로 균등
후보 슬롯별 선택률	0.0008	0.0039		그대로 균등
앱 버전 비중	0.0029	0.0026		그대로 균등
문항 위치별 투표율	0.0001	0.0002		그대로 균등

시간 간격 — 균등도 (1.0 = 완전 균등)

간격	v4	v5	v5 범위	v5 중앙값	판정
접속 세션 길이	1.042	0.154	0.9~717.7분	10.4분	로그정규
친구요청 응답	0.683	0.327	0.04~72시간	3.9시간	로그정규
받은투표 열람 지연	1.014	0.431	0.2~72시간	4.5시간	로그정규
투표 세션 길이	1.054	0.471	2.2~14.5분	6.5분	로그정규
문항 응답	1.045	0.535	2.1~90초	12.5초	로그정규
광고 시청	1.006	1.005	20~60초	39.5초	여전히 균등 — 누락

12. v4 대비 — 무엇이 열렸나

v4 리포트 13장은 "할 수 없다"를 15종 열거했다. 그중 9종이 열렸다.

v4 에서 불가능했던 것	v5	근거
앱 열기 → 투표 퍼널	열림	겹침 3.84% → 99.99% . 세션당 라운드 수를 셀 수 있다
체류시간 · 응답속도 분포	열림	균등도 1.0 → 0.15~0.54 . 분위수·꼬리가 의미를 갖는다
이탈(탈퇴) 예측 모델	열림	탈퇴자 투표 세션이 21% 적다 (v4 는 오히려 많았다)
요일 효과	열림	CV 0.024 → 0.18~0.24 . 원본 순위와 일치
상위 1% 헤비유저 세그먼트	열림	하루 최대 51세션 · 7.9시간 — 사람 범위
활동 집중 지표의 절대값 인용	열림	불가능한 꼬리가 없으므로 지니·상위점유를 그대로 쓸 수 있다
휴면·복귀를 접속 세션으로 측정	열림	v4 는 0명 → v5 748명 . 어느 표로 재도 같다
세션 길이와 활동의 관계	열림	상관 0.0007 → 0.7005
중복 로그 정제 연습	신규	중복 0.399% 를 일부러 넣었다 — 정제 전후 차이 3.3시간
질문별 인기 · A/B	여전히 불가	요구사항에 없었다
후보 슬롯 위치 편향	여전히 불가	CV 0.0039
성별 상호작용	여전히 불가	지목이 인구 비중과 같다
게시판 카테고리별 차이	여전히 불가	CV 0.0046
앱 버전 · 플랫폼 · 기기	여전히 불가	버전 매달 33% 고정 · 기기 1개가 플랫폼 3개
광고 네트워크 비교 · 시청시간 분포	여전히 불가	admob 하나 · 시청시간 균등(누락)
힌트 완전 공개 구분	여전히 불가	REVEALED 0건

13. 이 데이터로 할 수 있는 것 / 주의 / 없는 것

할 수 있다

분석	근거
앱 열기 → 투표 → 완료 퍼널	포함률 99.99% · 세션당 라운드 분포
체류시간 분포 · 분위수	중앙값 10.4분 · p99 161.9분 · 최대 717.7분
요일 × 시간대 히트맵	요일 CV 0.18~0.24 · 시간대 3.1배. KST 변환 필수
계절 효과	평시 대비 방학 42% · trough 28%
코호트 잔존 · 복귀 코호트	11개 코호트 · 복귀 748명(어느 표로 재도 같다)
이탈 예측 · 수명 분석	탈퇴자 활동이 21% 적다 · 수명 중앙값 3.2일
활동 집중 · 지니 (절대값 포함)	지니 0.9257 · 상위 10% 87.5%
결제 전환 · LTV · 고래	18.0% 전환 · 상위 10%가 매출 70.4% · 결제자 활동 2.00배
민감 질문 신고율 검정	3.76배 — 대조군 7종이 0.31~0.35 로 깨끗
힌트 단계 이탈 곡선	단계마다 2.7배씩 감소
로그 정제 연습	중복 0.399% 를 걸러내는 전후 비교
신고 처리 큐 운영 지표	PENDING 32.6%

주의해야 한다

함정	이유
UTC 그대로 시간 집계	봉우리가 9시간 밀린다
중복 로그를 안 걸러낸 체류시간	하루 최대가 19.0 → 22.3시간으로 부풀려진다
시간대 히트맵을 세션 수로만	세션 병합 때문에 대비가 약하다. 덮은 시간이나 <code>served_at</code> 권장
BAN 코호트를 시각으로 안 자름	34명이 제재 후에도 투표한다
결제 실패율 · 게시판 참여 절대 수준	0.13% 는 실서비스보다 낮다
같은 반/학교 비율 인용	설정(42%/80%)과 실측이 다르다. 수로 보면 목표 안
실서비스와 매출 혼용	합성은 실결제, 실서비스는 <code>MVP-STUB-</code>

할 수 없다 (7종 — v4 는 15종이었다)

분석	이유
질문별 인기 · A/B	출제량 차이가 설계된 것이 아니라 표본 노이즈
후보 슬롯 위치 편향	CV 0.0039 — 검정하면 반드시 기각
문항 위치별 응답 품질	CV 0.0002
성별 상호작용 (동성 선호)	지목이 인구 비중과 같다
게시판 카테고리별 차이	CV 0.0046
앱 버전 · 플랫폼 · 기기 단위	버전 고정 · 기기 1개가 플랫폼 3개를 오간다
광고 네트워크 · 시청시간 분포	<code>admob</code> 하나 · 시청시간이 균등(이번에 누락)

14. 무엇을 바꿨나 — 재현 정보

seed 20260803 으로 그대로 재현된다. v4 와 같은 seed 이므로 차이는 전부 아래 변경에서 나온다.

생성기 (generator/generate.py)

무엇	어떻게
<code>lognormal_span()</code> 신규	구간 안에서 짧은 쪽이 두껍고 긴 꼬리가 붙는 값을 뽑는다. ⚠ 상한을 넘으면 자르지 않고 다시 뽑는다 — 자르면 상한에 값이 뭉쳐 벽이 생긴다
시간 간격 7곳 교체	문항 간격 · 응답 · 열람 지연 · 답장 · 힌트 2곳 · 친구요청 응답. 광고 시청 1곳을 빠뜨렸다
<code>DOW_WEIGHTS</code> 신규	구 서비스 실측을 코드 옆 상수로 둔다. 설정으로는 켜고 끄기만 — 값이 설정에만 있으면 또 조용히 죽는다(그 함정을 아홉 번 밟았다)
<code>_build_app_sessions()</code> 신규	투표 구간을 30분 규칙으로 묶어 접속 세션을 만든다. ⚠ 하루 상한이 투표를 품은 창은 못 자른다 — 자르면 그 투표가 세션 밖으로 나간다
<code>_act_at()</code> 신규	모든 직접 행동의 시각을 세션 안 + 탈퇴 전으로 강제한다. 자리가 없으면 그 행동을 만들지 않는다
세션 종료를 문항에서 유도	<code>started + randint(2,20) → 마지막 문항 + 꼬리</code>
탈퇴를 마지막 활동 뒤로	세션 투표 원장을 전부 훑어 가장 늦은 시각 뒤에 찍는다. ⚠ <code>u.ledger</code> 만 보면 안 된다 — 충전 지급은 거기 없다

설정 (generator/config/synthetic-v2.yaml)

키	v4	v5	왜
<code>popularity.zipf_alpha</code>	0.45	1.05	쓸림의 바닥이 내려갔다. 이제 활동이 아니라 매력도로 만든다
<code>sessions.max_vote_hours_per_day</code>	없음	6.0	물리적 상한. 개수가 아니라 시간
<code>sessions.max_active_hours_per_day</code>	없음	10.0	
<code>sessions.idle_gap_minutes</code>	없음	30	실서비스 <code>touch_session()</code> 과 같은 값
<code>sessions.browse_only_ratio</code>	없음	0.35	열어만 보고 닫는 세션
<code>sessions.dow_gamma</code>	없음	1.6	요일 진폭 보정. 그대로 쓰면 놀린다
<code>sessions.noise.*</code>	없음	0.4% / 0.2%	중복 행 · 늦은 종료
<code>board.liker_ratio</code>	없음	0.60	없어서 활성 전원이 후보가 됐다(95.9%)
<code>sessions.weekend_multiplier</code>	0.55	삭제	코드가 안 읽었다. 지워서 죽은 값을 남기지 않는다
<code>sessions.hour_weights</code>	있음	삭제	같은 이유. 시간대는 <code>behavior.hourly</code> 가 담당한다

⚠ 이번에도 죽은 설정을 하나 만들었다

`sessions.votes_per_app_session` 을 설정에 넣어 놓고 구현은 30분 공백 규칙으로 갔다. 그래서 아무도 안 읽는 키가 됐다 — v4 에서 아홉 번 밟은 그 함정을 같은 작업 안에서 또 밟았다.

같은 성격으로 죽어 있는 키가 더 있다 — `voting.gender_homophily` · `voting.stop_voting_at_cap` ·

`questions.sensitive_ratio` · `received.reply_report_rate` · `board.author_pareto_top5_share` · `anomalies.*` · `incremental_batch.*` · `gates.*`. 정리 대상이다.

다시 만들려면

단계	명령 · 소요
생성	<code>python generator/generate.py --config synthetic-v2.yaml</code> · 약 20분 · 11GB
적재	<code>python generator/load.py --truncate</code> · 약 1시간

정합성	qa/checks/integrity.sql 을 그대로 실행 · 17종 0 이어야 한다
인기도 보정	4,000명·10학교 프로브로 zipf_alpha 를 잡는다. 곡선 — 0.45→43.7% · 0.95→47.9% · 1.30→50.9%

15. 남은 미이행

항목	출처	상태
2차 증분 배치	Q28	미실시. 증분 적재의 합정 4개를 실제로 재현해 볼 유일한 방법. 이제 가장 큰 미이행이다
앱을 생성기에 맞추기	—	투표 보상(앱 5~15 vs 생성기 2~10) · 일일 적립 상한(앱 없음). 생성이 확정된 지금이 그 시점이다
BigQuery 적재	P4	합성 미적재. 1억 2,370만 행이면 v4 추정(13.9 GiB)의 65% 수준
광고 시청시간 로그정규	v5 누락	시간 간격 7곳 중 한 곳을 빠뜨렸다. 생성기 1줄
BAN 이후 활동 차단	범위 밖	2,693건 · 34명. 탈퇴와 같은 방식으로 고칠 수 있다
시간대 대비 회복	v5 부작용	5.3배 → 3.1배. 세션 병합의 결과라 고치려면 세션 정의를 바꿔야 한다

ping-v2 · 12개월 v5 (확정) · 2026-08-05 · 로컬 pgtest 실측 · seed 20260803 으로 재현 가능 · 요구사항 7가지 · 정합성 17종 · 이상치 9종 · v4 대비 9종 해금