

합성 데이터 샘플 EDA

유저 500명 · 1개월 · 학교 6곳 — 생성기 검증용 샘플

생성 명령 `python generator/generate.py --config synthetic-v2.yaml --users 500 --months 1 --schools 6`

적재 로컬 Postgres `pgtest` (포트 5433) · 총 757,699 행

설정 `generator/config/synthetic-v2.yaml` — 팀 결정 Q1~Q30 반영본

날짜 2026-08-03

한 줄 결론

구조는 맞고, 볼륨과 분포가 틀렸다. 40개 표가 서로 제대로 연결돼 있고 정합성 검사 17종이 전부 통과한다. 문제는 전부 “몇 번 일어나는가” 쪽에 몰려 있다.

1. 규모

항목	값	비고
유저	500명	여 58.0% / 남 42.0% (목표 58.6%)
학교 / 학급	6개교 / 81학급	샘플 축소 규모
지역	40개 시군구	10개 시·도
기간	2025-07-28 ~ 2025-08-26	29일. Q3 규칙(웹앱 로그 1년 전) 시작점
학교당 평균 유저	166.7명	
학급당 평균 유저	17.9명	목표 14~22 안에 들어옴
총 행수	757,699	40개 표 전부 1행 이상

2. 전환 퍼널

단계	인원	전체 대비	판정
1. 가입	500	100.0%	—
2. 세션 1회 이상	346	69.2%	리텐션 설정과 부합
3. 친구 5명 해금	500	100.0%	문제 ①
4. 투표 1회 이상	334	66.8%	—
5. 힌트 구매	499	99.8%	문제 ②의 결과
6. 결제	75	15.0%	목표 18%. 다만 문제 ③ 참조

3단계와 5단계가 100%에 붙어 있다. 퍼널이 퍼널 모양이 아니다 — 걸러지는 곳이 없다는 뜻이다.

3. 깨진 것 네 가지

① 고립 유저가 0명 — 친구 게이트 퍼널이 통째로 없다

친구 수	값
최소	11명
중앙값	36명
평균	35.9명
최대	65명
5명 미만 (게이트 미달)	0명

설정에 `locked_user_ratio: 0.08` 이 있고 코드도 그 값을 읽는다. 그런데 친구 관계가 양방향이라 “친구를 2명만 만들 사람”으로 정해도 남들이 그를 골라 친구가 계속 붙는다. 목표치는 본인이 먼저 거는 횟수만 제한한다.

왜 중요한가

Q31에서 정한 핵심 분석 질문 다섯 중 하나가 “친구 수가 몇 명일 때 서비스가 살아나는가”다. 게이트를 못 넘은 사람이 0명이면 그 질문에 답할 데이터가 아예 없다.

② 활동량이 약 12배 과다 — 세션 수가 기간과 무관하다

유저 1인당 (29일간)	실제	환산
투표 문항	224.6개	하루 7.5개
받은 투표	144.5개	하루 5.0개
투표 세션	22.5회	이틀에 1.5회
하트 거래	342.5건	하루 11.8건

`sessions_per_active_user: [1, 40]` 이 전체 기간에 대해 적용된다. 12개월이든 1개월이든 똑같이 최대 40 세션이다. 그래서 1개월 샘플이 12개월치 활동을 압축해 담고 있다.

이 때문에 힌트 구매자가 99.8%로 나온다 — 받은 투표가 145개나 되니 그중 하나라도 힌트를 살 확률이 사실상 1이 된다.

③ 하트가 남아돈다 — 결제할 이유가 데이터에 없다

구분	하트	비고
적립 총합	2,243,809	VOTE_REWARD 가 144만
소비 총합	287,420	적립의 12.8%
기말 잔액 합	1,956,389	
잔액 중앙값	2,377	힌트 118개를 살 수 있는 액수

잔액 100 미만 유저	0명	Q25 목표 60%
--------------	----	------------

투표 보상이 144만 하트를 뿌리는데(문제 ②의 직접 결과) 힌트값은 20하트라 소비가 못 따라간다. 이 상태에서는 **결제 전환 15%가 데이터로 설명되지 않는다** — 하트가 넘치는데 왜 사는지 근거가 없다.

④ 인기도 먹법칙이 없다

받은 투표 기준 상위 10%가 전체 지목의 18.4%를 가져간다. Q21 목표는 45%다. 사실상 균등 분포에 가깝다.

후보를 무작위로 뽑기만 하고 인기도 가중치를 넣지 않았다 — 아직 미구현 항목이며, 이 EDA가 그것을 수치로 확인한 셈이다.

4. 정상인 것

항목	실측	목표	판정
스코프 배분 (CLASS/SCHOOL/GLOBAL)	33.8 / 34.8 / 31.4	35 / 35 / 30	일치
받은 투표 열람률	44.8%	55.5%	근접
서플 발생률	16.4%	18%	일치
padded 문항 비율	12.4%	18%	근접
답장률 (열람 대비)	5.6%	4~20%	범위 내
세션 완료율	99.4%	96.3%	중도 이탈 미구현
플랫폼 WEB 비중	81.6%	82%	일치
성비 (여)	58.0%	58.6%	일치
탈퇴율	12.0%	10.5%	일치
무댓글 게시글 비율	30.5%	30%	일치
최다 좋아요 게시글	159	떡상 글 존재	존재
매출	733,200원	—	결제 75명

분모 주의 — 게시판 참여율

게시글 작성자는 전체 500명 기준 22%지만 활성 334명 기준으로는 33%다(목표 40%). 댓글은 전체 46% / 활성 69%(목표 70%). 생성기는 “가입 당일만 쓴 유저”(28%)를 비활성으로 치기 때문에 분모가 달라진다. **지표를 볼 때 분모를 먼저 확인해야 한다**는 사례다.

신고 PENDING 74.7%

Q15 목표는 30%다. 원인은 1개월 창이다 — 기간 끝 무렵 신고는 검토 시각이 창을 넘어가 PENDING으로 되돌아간다. “최근 신고는 아직 처리 안 됨”이라는 현실적 효과이며, 12개월로 돌리면 검토 지연(최대 10일)이 전체 기간의 3%라 30%대로 수렴할 것으로 본다. **전체 규모 생성 후 재확인 항목.**

5. 검증 통과 항목

검사	결과
정합성 검사 (qa/checks/integrity.sql)	17종 전부 위반 0
표 커버리지	40 / 40 — 빈 표 없음
컬럼 커버리지	338 / 342 가 1% 이상 채워짐
하트 원장 정합성	누적합 ≠ 잔액 0건 · 음수 잔액 0건
힌트 자격 규칙 (W14)	기본 3개 미만 이름 구매 0건

채우지 못한 컬럼 4개는 사유가 각각 다르다.

- `app_user.auth_user_id` — 채우면 안 된다. 합성 유저는 Supabase 계정이 없고, 이 NULL 자체가 실유저와 합성을 가르는 신호다.
- `heart_transaction.purchase_id` (228건) · `admin_id` (13건) — 값은 있으나 17만 거래 대비 비율이 1% 미만일 뿐이다.
- `heart_purchase.failure_reason` — 실측 결제 실패율 0.17% × 결제 228건 = 기대값 0.4건. **규모 문제**이며 2만 명 규모에서는 약 24건이 나온다.

6. 정리와 다음 단계

문제 ①과 ②는 뿌리가 같다

생성기가 **시간과 개인차를 모른다**. 모든 유저를 같은 확률 분포로 찍어내고, 활동량을 기간과 무관하게 배분한다. Q4(3국면 성장 곡선)와 Q36(유저 페르소나)이 아직 미구현이라는 사실을 이 EDA가 수치로 드러낸 것이다.

수정 순서 — 뒤로 갈수록 앞의 결과에 의존한다.

순서	작업	고쳐지는 문제
1	시간 엔진 교체 (기간에 비례한 세션 배분 + 3국면 곡선)	② 볼륨 과다 · ⑤ 세션 완료율
2	친구 그래프 — 양방향 유입에도 고립이 유지되도록	① 게이트 퍼널
3	후보 선정에 인기도 가중치	④ 먹법칙
4	하트 보상·소비 재조정	③ 하트 과잉 (①②를 고친 뒤에 값을 다시 잡는다)

수정 후 같은 EDA를 다시 돌려 비교하면, 이 문서가 그대로 **기준선**이 된다.