

합성 데이터 샘플 EDA v2

유저 500명 · 1개월 · 학교 6곳 — v1에서 지적된 결함을 고친 뒤 재생성

생성 명령

python generator/generate.py --config synthetic-v2.yaml --users 500 --months 1 --schools 6

적재 로컬 Postgres pgtest (포트 5433) · 총 127,495 행 (v1: 757,699)

비교 대상 docs/EDA-sample-1m-v1.pdf

날짜 2026-08-03

한 줄 결론

v1에서 지적한 문제 다섯 가지가 모두 목표 범위에 들어왔다. 퍼널이 퍼널 모양을 갖췄고, 활동량이 현실적인 수준으로 내려왔으며, 인기도 먹법칙이 생겼다. 남은 것은 하트 경제 하나이고, 그 성격도 v1과는 정반대로 바뀌었다.

1. v1 대비 — 지적 사항 처리 결과

항목	v1	v2	목표	판정
친구 5명 해금	100%	92.4%	90~95%	해결
힌트 구매 유저	99.8%	70.8%	70~80%	해결
받은 투표 0건 유저	0명	43명 (8.6%)	소수 존재	해결
상위 10% 지목 점유율	18.4%	45.8%	45%	해결
세션 1회 이상	69.2%	96.6%	~96%	해결
유저당 투표 문항 / 월	224.6	15.3	하루 0.5개	해결
친구 수 최대	65	445	500+	규모 제약
하트 소비 / 적립	12.8%	7.5%	—	남음

친구 수 최대 445 — 결함이 아니라 샘플 규모의 천장

유저가 500명뿐이라 물리적 상한이 499명이다. 설정은 hub_per_user: [200, 700] 이므로 2만 명 규모에서는 700까지 나온다. 지금도 친구 150명 이상인 허브 유저가 17명 있다.

2. 규모

항목	값	비고
유저	500명	여 58.0% (목표 58.6%)
학교 / 학급	6개교 / 81학급	학급당 17.9명 — 목표 14~22 안

기간	2025-07-28 ~ 2025-08-26	29일
총 행수	127,495	v1 대비 83% 감소
테이블 / 컬럼	40 / 342	빈 표 0개

3. 전환 퍼널

단계	인원	전체 대비	비고
1. 가입	500	100.0%	—
2. 세션 1회 이상	483	96.6%	미접속 4.1%만 제외 — 설정과 일치
3. 친구 5명 해금	462	92.4%	게이트가 실제로 작동
4. 받은 투표 1건 이상	457	91.4%	43명은 한 번도 못 받음
5. 힌트 구매	354	70.8%	—
6. 결제	90	18.0%	목표 18% 정확히 일치

단계마다 사람이 걸러진다. v1에서는 3·5단계가 100%에 붙어 있어 퍼널이라 부를 수 없었다.

4. 하트 경제 — 문제의 성격이 뒤집혔다

유형	건수	1인당 건수	하트 합	1인당
TOPUP (결제)	357	0.7	515,714	+1,031
SIGNUP_GRANT	500	1.0	150,000	+300
VOTE_REWARD	14,402	28.8	44,390	+89
HINT_PURCHASE	2,347	4.7	-48,860	-98
VOTE_REPLY	251	0.5	-5,020	-10
EVENT_GRANT / ADMIN_ADJUST	37	0.1	3,750	+8

보상 확률표가 정확히 재현됐다

보상 하트	2	3	4	5	6	7	8	9	10
설정	40%	30%	20%	5%	3%	1%	0.5%	0.3%	0.2%
실측	39.8%	30.5%	19.7%	5.0%	3.0%	1.0%	0.4%	0.4%	0.2%

※ 1하트 지급이 12건 있다. 하루 적립 상한 100하트에 걸려 잘린 건이며, 상한이 실제로 작동한다는 증거다.

남은 문제 — 소비 비율이 오히려 나빠졌다

항목	v1	v2
적립 총합	2,243,809	713,854
소비 총합	287,420	53,880
소비 / 적립	12.8%	7.5%
잔액 중앙값	2,377	325
잔액 100 미만 유저	0%	6.4%
잔액 부족으로 무산된 힌트	336건	1,490건

같은 숫자가 v1과 정반대를 뜻한다

v1의 낮은 소비 비율은 하트가 남아돌아서였다(잔액 중앙값 2,377). v2의 낮은 소비 비율은 하트가 모자라서다 — 힌트 구매 시도의 37%가 잔액 부족으로 무산됐다(성사 2,580 / 무산 1,490).

적립 단가를 낮춘 것은 먹혔다(적립 총액 68% 감소). 그런데 받은 투표가 144→14.8로 줄면서 소비 기회가 그보다 더 많이 줄었다. 두 조정이 같은 방향으로 겹쳤다.

⚠️ **정정 (2026-08-03) — 아래 진단은 틀렸다**

이 절은 “가입 지급 300하트를 낮추자”로 끝나는데, **가입 지급은 순수 공급이라 줄이면 하트 부족이 악화된다**. 그 제안은 “소비/적립 비율을 올리자”는 생각에서 나왔고, 그건 분모를 깎아 지표를 좋게 보이게 하는 것이지 문제 해결이 아니었다.

v3에서 받은 투표 수로 구간을 갈라 보니 **유저의 72%는 하트가 남아돌고 상위 18%만 쪼들리며, 결제율도 그 구간에서만 올라간다**. 애초에 고칠 문제가 아니었다. 자세한 것은 EDA-sample-1m-v3.pdf 4장.

아래 내용은 당시 판단의 기록으로 남겨둔다.

진단 — 가입 지급 300하트가 이제 과하다 (틀린 진단)

적립의 구성이 완전히 바뀌었다.

유입원	비중	v1에서는
결제 (TOPUP)	72.2%	12.2%
가입 지급	21.0%	6.7%
투표 보상	6.2%	64.4%
광고 보상	0%	16.4%

잔액 중앙값 325는 사실상 **가입 지급 300 그 자체**다. 중앙값 유저는 벌지도 쓰지도 않고, 헤비 유저는 사고 싶은데 하트가 없다. 가입 지급 300하트는 힌트 15개 값이라 **초반 소비를 통째로 흡수한 뒤 그대로 잠긴다**.

다음 조정 후보는 **가입 지급을 100 안팎으로 낮추는 것**이다. 다만 이는 v1 실측(point 최빈값 300)을 버리는 결정이므로 팀 판단이 필요하다.

5. 그 밖의 지표

항목	v2 실측	목표	판정
세션 완료율	98.9%	78%	중도이탈 199세션 생성됨. 비율은 미달
받은 투표 열람률	46.5%	55.5%	근접
서플 발생률	16.6%	18%	일치
padded 문항 비율	11.8%	18%	근접
답장률 (열람 대비)	11.0%	4~20%	범위 내
WEB 세션 비중	81.2%	82%	일치
탈퇴율	10.6%	10.5%	일치
글 쓴 유저 (활성 대비)	39.1%	40%	일치
댓글 단 유저 (활성 대비)	67.7%	70%	일치
무댓글 게시글	31.7%	30%	일치
최다 좋아요 게시글	219	떡상 글	존재
신고 PENDING	66.7%	30%	1개월 창 artifact (신고 30건)

게시판 참여율이 목표에 맞았다. v1에서 어긋나 보였던 것은 “활성”의 정의가 잘못돼 있었기 때문이다 — 가입 당일만 쓴 유저 28%가 비활성으로 분류돼 분모가 틀어졌다. 그 정의를 고치자 39.1% / 67.7%로 목표 (40% / 70%)에 들어왔다.

힌트 유형 분포

유형	GENDER	INITIAL	CLASS	FINAL	MEDIAL	FULL_NAME
건수	585	500	496	491	484	24
비중	22.7%	19.4%	19.2%	19.0%	18.8%	0.9%

GENDER가 조금 많은 것은 광고로 여는 경로(233건)가 따로 있기 때문이다. FULL_NAME이 0.9%로 적은 것은 100하트인 데다 기본 3개 이상을 먼저 열어야 하는 제약 때문이며, 설계 의도대로다.

6. 검증 통과 항목

검사	결과
정합성 검사 (qa/checks/integrity.sql)	17종 전부 위반 0
표 커버리지	40 / 40 — 빈 표 없음
컬럼 커버리지	338 / 342 가 1% 이상
하트 원장 정합성	누적합 ≠ 잔액 0건 · 음수 잔액 0건
친구 끊기 이력	458건 — 행을 지우지 않고 ended_at 기록

커버리지에 새 구멍 하나

`heart_transaction.ad_impression_id` 가 전부 **NULL**이 됐다. 광고 보상을 0으로 만들면서 `AD_REWARD` 거래 자체가 사라졌기 때문이다. **의도한 변경의 부작용**이며, 광고 시청 기록은 `ad_impression` 표(1,595건)에 그대로 남아 있다. 화이트리스트에 추가할지 판단이 필요하다.

7. 다음 단계

1. 하트 경제 재조정 — 가입 지급 300 → 100 검토 → **철회**. 위 정정 참조. 공급을 줄이면 부족이 악화된다
2. 세션 중도 이탈 비율 — 199세션이 생성되긴 했으나 완료율 98.9%로 목표(78%)에 못 미친다
3. 3국면 성장 곡선 (Q4) — 1개월 샘플에서는 확인 불가. 12개월 생성 시 검증
4. 유저 페르소나 — 미구현. 지금은 `is_power` 하나로만 갈린다
5. 전체 규모 생성 — 2만 명 × 12개월. Q6 가드레일(4,000만 행) 초과 여부 확인

이 문서는 **v1과 같은 항목·같은 순서**로 작성했다. 다음 수정 뒤에도 같은 형식으로 뽑으면 세 판본을 나란히 비교할 수 있다.