

합성 데이터 샘플 EDA v3

유저 500명 · 1개월 · 학교 6곳 — 활동 강도 재설계 + 페르소나 도입

생성 명령 `python generator/generate.py --config synthetic-v2.yaml --users 500 --months 1 --schools 6`

적재 로컬 Postgres `pgtest` · 총 **1,149,566** 행

이전 판본 `EDA-sample-1m-v1.pdf` (757,699행) · `EDA-sample-1m-v2.pdf` (127,495행)

날짜 2026-08-03

한 줄 결론

행동 트레잇이 서로 묶였다. 이전까지는 글쓰기·투표·힌트·결제가 전부 독립 추첨이라 “글도 쓰고 투표도 많이 하는 사람”이 우연으로만 생겼다. 이제 유저마다 성향이 있고, 그 성향을 벗어나는 사람도 함께 있다. 검증 6개 지표 전부 통과.

1. 세 판본 비교

항목	v1	v2	v3	목표
총 행수	757,699	127,495	1,149,566	—
유저당 투표세션 / 월	22.5	2.1	32.4	활성 100~200
유저당 받은 투표	144.5	14.8	251.3	—
친구 5명 해금	100%	92.4%	93.6%	90~95%
힌트 구매 유저	99.8%	70.8%	73.4%	70~80%
상위 10% 지목 점유율	18.4%	45.8%	47.9%	45%
글 쓴 유저 (활성)	33%	39.1%	40.6%	40%
댓글 유저 (활성)	—	67.7%	69.8%	70%
하트 소비 / 적립	12.8%	25.1%	33.8%	높을수록 건강
잔액 100 미만	0%	18.6%	22.6%	—
정합성 17종	0	0	0	위반 0

v2에서 활동량을 지나치게 늘렸던 것을 잔존 구간별 강도로 다시 잡았다. 활성 유저(30일+ 잔존)는 월 100~200세션, 당일 이탈자는 1~4세션이다. 1개월 샘플에서는 “30일+ 잔존”이 물리적으로 나올 수 없어 최상위 구간이 월 100회 안팎에 걸린다.

2. 페르소나 — 분류가 아니라 생성 편의

6개 유형을 두되 결과 데이터에 6덩어리가 또렷하게 남으면 실패로 본다. 분석자가 클러스터링해서 우리가 넣은 유형을 그대로 되찾는 데이터에는 발견할 것이 없다.

배정을 흐리는 세 장치

장치	인원	내용
단일 유형	359	한 유형을 그대로
혼합	86	두 유형을 6:4로 섞는다 — 경계가 사라진다
트레잇 교차	37	트레잇 하나를 다른 유형에서 가져온다 — “관망형인데 댓글만 게시판형”
무배정	18	유형 없이 전 트레잇 독립 무작위

여기에 더해 **트레잇마다 따로** 개인 편차(로그정규)를 곱한다. 한 배수로 전부 흔들면 유형 내부 순서가 그대로 클러스터가 살아남는다.

유형별 평균 행동 — 경향은 있되 절대적이지 않다

유형	명	세션	글	댓글	힌트	피신고	결제
관망형	148	1.9	0.4	2.3	14.0	0.2	0.2
투표형	131	20.8	0.6	3.2	21.3	0.4	0.8
소셜형	74	12.6	1.4	3.5	22.7	0.2	0.8
고관여형	71	114.8	3.6	4.1	37.9	0.6	1.8
게시판형	47	8.1	9.4	4.0	25.1	0.6	0.2
악성형	11	9.7	3.1	3.6	38.8	2.2	0.6

검증 — “깔끔하지 않음”을 직접 잼다

핵심 검사는 각 행동 지표의 상위 10%에 여러 유형이 섞여 있는가다. 한 유형이 독점하면 그 유형이 곧 그 행동이라는 뜻이라 발견할 것이 없다.

지표	상위 10%의 유형 구성	유형 수
세션	고관여 24 · 투표 17 · 소셜 4 · 게시판 2 · 무배정 2 · 악성 1	6
글	게시판 20 · 고관여 17 · 소셜 5 · 투표 4 · 무배정 2 · 관망 1 · 악성 1	7
댓글	투표 20 · 고관여 9 · 소셜 7 · 관망 10 · 게시판 3 · 무배정 1	6
힌트	고관여 13 · 투표 13 · 관망 8 · 게시판 6 · 소셜 5 · 무배정 4 · 악성 1	7
피신고	투표 13 · 관망 9 · 게시판 9 · 고관여 9 · 악성 7 · 소셜 3	6
결제	투표 19 · 고관여 14 · 소셜 7 · 관망 4 · 무배정 3 · 게시판 2 · 악성 1	7

규칙을 벗어난 유저가 실제로 있다

댓글 상위 10%의 4분의 1이 관망형이다. 반대로 게시판형 2명이 세션 상위 10%에 있다. 힌트를 가장 많이 사는 사람 중에도 관망형이 8명 있다. **유형을 알아도 그 사람의 행동을 단정할 수 없다**는 뜻이며, 이것이 설계 목표였다.

검증 항목	기준	결과
트레잇 모집단 평균	1.000	10개 전부 1.0000
규칙 이탈자 존재	지표당 5개 유형+	6/6 통과
유형 내 분산 / 유형 간 분산	0.7 이상	1.74 ~ 5.28
정합성 검사	위반 0	17종 통과
표 커버리지	40 / 40	빈 표 0
컬럼 커버리지	342	338 채워짐

3. 이번에 고친 구조적 결함 두 가지

① 확률에 배수를 걸면 모집단 평균이 샌다

트레잇 평균이 정확히 1.0이어도, 확률에 곱해 1을 넘지 않게 오즈비로 변환하면 **변환이 블록해서 평균이 아래로 당겨진다**. 실제로 열람률이 55.5% → 39.2%로 섰고, 글쓰기·댓글·결제도 함께 내려갔다.

설정값을 손으로 올려 맞추는 것은 답이 아니다 — 트레잇 분포가 바뀔 때마다 다시 들어진다. **보정 계수를 이분법으로 풀어 캐시하도록 고쳤다**(Generator.pchance). 그 결과 글쓰기 40.6%(목표 40%) · 댓글 69.8% (70%)로 정확히 복귀했다.

② 열람률 41.8%는 모델 오류가 아니라 우측 절단이다

구간	받은 투표	열람률
----	-------	-----

2025-07-28 주	2,506	56.8%
2025-08-04 주	8,939	54.8%
2025-08-11 주	17,956	54.8%
2025-08-18 주	52,299	52.9%
2025-08-25 주 (마지막)	43,970	19.7%
마지막 3일 제외	77,546	53.9%

이건 결함이 아니라 실데이터에도 있는 현상이다

받은 투표는 1~72시간 뒤에 열람된다. 기간 끝 3일치는 열람 시각이 관측 창을 넘어가 **미열람으로 기록된다**. 실서비스 데이터에서도 똑같이 생긴다.

분석 시 주의 — 열람률·답장률처럼 “나중에 일어나는 행동”의 비율을 낼 때는 **관측 창 끝 3일을 제외**해야 한다. 안 그러면 지표가 실제보다 낮게 나온다. 이 데이터에서는 마지막 주에 전체 받은 투표의 35%가 몰려 있어 왜곡이 특히 크다.

4. 하트 경제

항목	v1	v2	v3
적립 총합	2,243,809	713,854	795,019
소비 총합	287,420	53,880	268,800
소비 / 적립	12.8%	7.5%	33.8%
잔액 중앙값	2,377	325	385
잔액 100 미만	0%	6.4%	22.6%
유저당 힛트	25.3	17.3	25.7
결제자	18.6%	18.0%	15.4%
매출	1,419,900원	—	871,200원

v1은 하트가 남아돌아 소비 비율이 낮았고(잔액 중앙값 2,377), v2는 모자라서 낮았다. v3은 33.8%다.

⚠ 소비/적립은 하나의 값으로 볼 지표가 아니다

33.8%는 안 쓰는 다수와 다 쓰는 소수를 평균 낸 값이라 그 자체로는 아무것도 말해주지 않는다. 받은 투표수로 갈라 보면 완전히 다른 그림이 나온다.

받은 투표	명	평균 적립	평균 소비	평균 잔액	소비율	결제율
20건 미만	76	647	24	623	6%	14.5%
20-99	154	847	214	633	32%	14.3%
100-399	179	2,372	526	1,845	46%	14.0%
400건+	91	2,098	1,537	561	75%	20.9%

하트 부족은 전체 문제가 아니라 상위 18%의 이야기이고, 그것이 결제를 만든다

유저의 72%는 하트가 남아돈다(잔액 623~1,845). 찌들리는 것은 받은 투표 400건 이상인 91명(18%) 뿐이고, 무산 20,552건도 대부분 이들에게 몰려 있다.

그리고 결제율이 이 구간에서만 올라간다(14% → 20.9%). 하트가 모자란 사람이 결제한다는 구조가 데이터로 설명되는 상태다. 프리미엄 경제가 원래 이렇게 생겼다 — 대다수는 재화를 모으기만 하고 소수만 다 쓴다.

따라서 하트 파라미터는 손대지 않는다. 무산율 61%는 고칠 결함이 아니라 헤비 유저의 미충족 수요이고, 그것이 결제 동기다.

정정 — v2 문서의 “가입 지급 300을 낮추자”는 제안은 틀렸다

가입 지급은 **순수 공급**이다. 줄이면 하트 부족이 완화되는 것이 아니라 **악화**된다.

그 제안은 “소비/적립 비율을 올리자”는 생각에서 나왔는데, 그건 **분모를 깎아 지표를 좋게 보이게 하는 것**이지 문제 해결이 아니었다. 위 구간별 표가 보여주듯 애초에 고칠 문제가 아니었다.

5. 그 밖의 지표

항목	v3	목표	판정
친구 수 최대	457	500+	샘플 500명이라 상한 499
받은 투표 0건 유저	29명	소수	존재
서플 발생률	20.5%	18%	근접
padded 문항	12.2%	18%	근접
답장률 (열람 대비)	8.2%	4~20%	범위 내
탈퇴율	10.2%	10.5%	일치
무댓글 게시글	29.4%	30%	일치
세션 완료율	98.6%	78%	중도이탈 비율 미달
신고 PENDING	74.9%	30%	1개월 창 artifact

채우지 못한 컬럼은 4개다. `app_user.auth_user_id` (설계상 NULL) · `heart_purchase.failure_reason` (실패율 0.17%라 규모 문제) · `sanction.ends_at` (SUSPEND 미발생) · `heart_transaction.ad_impression_id` (광고 보상 0으로 바꾸며 거래 자체가 사라짐).

6. 다음 단계

1. **전체 규모 — 측정 결과 문제 없음**. 규모를 두 방향으로 늘려 재보니 **기간은 행수를 거의 안 늘린다**(유저 4배 × 기간 3배 = 12배인데 실제 5.2배). 유저의 95.8%가 활동 기간 29일 이하로 고정돼 있기 때문이다. 2만 명·12개월 추정은 **8,500만 행 · BigQuery 3.5~5GB**로 무료 한도(10GB) 안이다. **Q6 가드레일을 4,000만 → 1억으로 올렸다**. 다만 쿼리량은 여전히 위험하다 — Looker 를 raw 에 직접 붙이지 말고 P6 mart 를 먼저 만들 것
2. **세션 중도 이탈** — 완료율 98.6%로 목표(78%)에 못 미친다
3. **3국면 성장 곡선 (Q4)** — 1개월 샘플에서는 확인 불가. 12개월 생성 시 검증
4. **무산된 힌트가 데이터에 안 남는다** — “사고 싶었는데 하트가 없었다”는 결제 전환 분석의 핵심 신호인데 지금은 볼 수 없다. 남기려면 표가 하나 필요하고, **스키마 변경을 안 하기로 확정**했으므로 지금은 못 남긴다 (실험 테이블 · 통합 event_log 를 포기한 것과 같은 종류의 제약)

※ 하트 파라미터 조정은 목록에서 뺐다. 4장의 구간별 분석대로 고칠 문제가 아닌 것으로 판단했다.

ping-v2 · 합성 데이터 샘플 EDA v3 · 2026-08-03 · 데이터 `data/sample-1m/` · 설정 `generator/config/synthetic-v2.yaml`
· 페르소나 정답지 `data/personas.json` (분석자에게 주지 않는다)