

스키마 설계부터 주간 보고 자동화까지

28일간의 데이터 파이프라인 구축 결과

기간	2026년 7월 29일 ~ 8월 25일 (28일 · 작업일 15일)	작성일	2026년 8월 25일
범위	스키마 · 웹앱 · 합성 데이터 · 파이프라인 · 대시보드 · 주간 보고 · 문서 체계	커밋	160건
구성	Supabase(PostgreSQL) · BigQuery · Airflow · GitHub Actions · Next.js/Vercel · Looker Studio · NEIS 개방포털		

1. 요약

1. **계획한 28개 단계 중 27개를 완료했다.** 웹앱 20단계(W0~W19)와 파이프라인 8단계(P0~P7)이며, 미완은 P3의 DAG 전환 1건이다.
2. **실데이터가 원천에서 대시보드까지 흐른다.** Supabase에 쌓인 실유저 데이터가 BigQuery raw(1억 2,373만 행)를 거쳐 stg 뷰 10개, mart 테이블 8개로 가공되고, Looker Studio 5개 페이지가 mart만 조회한다.
3. **주간 보고가 무인 자동화되었다.** 매주 월요일 지난주 실적을 3페이지 PDF로 생성해 공유 드라이브에 적재한다. 적재부터 배송까지 7단계를 GitHub Actions에서 실행하므로 로컬 환경 가동 여부와 무관하다.
4. **검증 항목 662개를 층별로 구축했다.** 이 프로젝트의 장애는 대부분 오류를 발생시키지 않고 수치만 틀리는 유형이었다(7절).
5. **결정 91건과 그 근거를 문서로 남겼다.** 문서 검사 9종이 문서 내용과 운영 DB를 대조한다.

1	요약	6	검증 체계
2	배경과 목표	7	주요 장애 사례
3	시스템 구성	8	정량 결과
4	진행 경과	9	교훈
5	산출물	10	잔여 과제
		A	부록 · 재현 절차

2. 배경과 목표

선행 서비스의 운영 데이터로는 답할 수 없는 질문이 있었다. 투표자와 결제자를 동일 식별자로 연결할 수 없었고(결제자 59,192명 중 99.3%가 투표 불가 학교 소속), 탈퇴 기록 70,764건에는 유저 식별자가 없었다. 데이터를 추가로 수집해도 해소되지 않는 스키마 구조의 문제였다.


이에 다음 순서로 진행했다.

- 구조적 결함을 제거한 스키마를 설계한다
- 그 위에 웹앱을 배포해 실데이터를 발생시킨다
- 규모 검증용 합성 데이터를 별도로 생성한다
- 파이프라인으로 분석 DW까지 적재한다
- 대시보드와 정기 보고까지 연결한다

제약 조건

개인정보를 수집하지 않는다(익명 인증 · 초대 코드 · 닉네임). 상용 출시가 아닌 지인 대상 클로즈드 테스트를 전제한다. 인프라 비용은 무료 한도 내에서 해결한다.

3. 시스템 구성



주) 실선 화살표는 데이터 흐름. 하단 막대는 각 실행 주체가 담당하는 구간.

그림 1. 전체 시스템 구성과 데이터 흐름. 원천 3종이 운영 DB 2종으로 모이고, 증분 적재를 거쳐 분석 DW에서 3개 층으로 가공된 뒤 대시보드와 주간 보고서로 소비된다.

영역	도구	선정 사유
운영 DB	Supabase (PostgreSQL)	인증 내장, RLS 지원, 무료 한도. 익명 인증이 개인정보 미수집 제약과 부합
분석 DW	BigQuery	1억 행 규모 처리. 저장 10 GiB · 조회 1 TiB 무료 한도 내에서 운영
오케스트레이션	Airflow (로컬 Docker)	Cloud Composer는 월 40만원대로 제외. 일 단위 배치에는 로컬로 충분
	GitHub Actions	주간 보고는 로컬 가동에 의존하면 안 되므로 분리. 무료 실행 시간 내
웹앱	Next.js · Vercel	main 푸시 시 자동 배포
대시보드	Looker Studio	mart 전용 연결. raw 연결 시 조회 한도 소진
보고서 생성	Playwright (Chromium)	HTML → PDF. 컨테이너 내 실행이 필요해 브라우저 번들 방식 채택
외부 데이터	NEIS 교육정보 개방포털	학교·급식·학사일정 실데이터
문서	Markdown · Obsidian	노드 단위 문서, 링크 그래프 관찰

표 1. 기술 선정 결과

4. 진행 경과




그림 2. 28일간의 진행 경과. 커밋의 절반(76건)이 첫 3일에 집중되어 있다.

국면	기간	커밋	내용
①	07-29 ~ 07-31	76	스키마 40표 · RLS 보안 게이트 · 익명 인증 · 온보딩 · 투표 · 힌트 · Vercel 배포. 이어 게시판 · 친구 추천 · 프로필 · 충전 · 선택형 힌트 · 학사일정 · 친구 해제까지 완료. 동일 기간에 BigQuery 첫 적재와 문서 위키 재편을 병행했다.
②	08-03 ~ 08-06	41	합성 데이터 5개 판본 재작성. v1(결함 8건) → v2(결함 3건) → v3(중단) → v4(정밀 검수에서 결함 1건·경계 5건) → v5 확정. BigQuery 전량 적재 및 40개 표 대조 일치.
③	08-11 ~ 08-13	8	AARR 분석 실행(가입·활성화·리텐션·매출). 이 과정에서 노후 DDL 주석 발견 및 수정.
④	08-18 ~ 08-20	15	품질 검증 430항목 구축 · stg 뷰 10개 · mart 테이블 8개. 마트 빌드를 DAG로 이관하고 품질 검증을 일 증분/주 전수로 분리했다.
⑤	08-21 ~ 08-24	2	Looker Studio 5개 페이지 연결. mart만 조회하도록 구성.
⑥	08-25	18	주간 보고 자동화 구축(신규) · 문서 체계 효과 재측정 · 완료 보고 작성.

표 2. 국면별 진행 내역

진행 순서에 관한 판단

일반적인 순서와 달리 웹앱을 먼저 구축하고 파이프라인을 후행했다. 실데이터가 흐르는 구조가 성립해야 파이프라인이 의미를 갖는다고 판단했기 때문이다. 지인 20~50명 규모의 데이터는 작지만 유일한 실제 원천이었다.

5. 산출물

5.1 스키마 — 40개 테이블

선행 서비스의 구조적 결함 3건을 제거했다. 결제와 투표의 식별자 분리, 탈퇴 기록의 식별자 누락, 순환 외래키다. 테이블 수는 42 → 41 → 40으로 축소했다.

5.2 웹앱 — 개인정보 미수집 MVP

수집하지 않는 항목	대체 방식
이메일 · 비밀번호	Supabase 익명 인증 (접속 시 자동 생성)
전화번호	초대 코드 기반 친구 추가
실명	사용자 지정 닉네임

표 3. 개인정보 미수집 설계

보안 원칙은 W1에서 확정하고 종료까지 유지했다. 쓰기 권한은 RPC로만 제공하며, 클라이언트에 `heart_transaction` INSERT나 `heart_balance` UPDATE 권한을 부여하지 않는다. 사용자 식별자로 타인을 지목할 수 있는 경로를 만들지 않는다.

5.3 합성 데이터 — 9개 판본

최종 v5는 유저 20,000명 · 12개월 · 1억 2,370만 행이다. 정합성 17종과 이상치 9종에서 위반 0건이며, 목표 지표를 모두 충족한다. v4 대비 행 수가 35% 감소했는데, 이는 데이터가 줄어든 것이 아니라 비정상 레코드가 제거된 결과다(v4에는 1일 406.8시간 활동한 유저-일이 존재했다).

5.4 파이프라인 — 3개 층

층	형태	규모	역할
raw	테이블 (파티션)	1억 2,373만 행 8.74 GiB	원본 보존. 제약 없음
stg	뷰 10개	저장 0	정규화·플래그 부여. 저장 비용 회피를 위해 뷰로 구성
mart	테이블 8개	495 MiB	지표 사전 집계. 대시보드 조회 대상

표 4. 분석 DW 3개 층

5.5 대시보드 — Looker Studio 5개 페이지

KPI·시계열 / 유저·코호트 / 퍼널·분포 / 하트 / 신고·적체 5개 페이지가 mart 8개 테이블만 조회한다. raw를 연결하면 화면 갱신마다 1억 2천만 행을 조회하여 무료 한도를 소진한다.

5.6 주간 보고 자동화 (2026-08-25 신규)

매주 월요일 05:30(KST)에 지난주 실적을 3페이지 PDF로 생성해 공유 드라이브에 적재한다. 실행 주체는 GitHub Actions이며, 적재부터 배송까지 7단계를 단일 워크플로에서 처리한다.

순서	단계	내용
1	적재	Supabase → BigQuery raw 증분 적재

2	대조	행 수 비교. 증분 적재는 오류 없이 누락될 수 있다
3	품질 검증	최근 9일분 필수값·시각 검증. 위반 시 중단
4	마트 빌드	mart 8개 테이블 재생성
5	수집	mart → JSON. SQL 9개 · 조회량 0.17 GiB
6	렌더	JSON → HTML → PDF (Playwright)
7	배송	공유 드라이브 적재. 동일 파일명은 새 버전으로 갱신

표 5. 주간 보고 처리 단계

구조는 3개 층으로 분리했다. 수치가 부정확할 때 원인 구간을 특정하기 위해서다.

- **수치 층** — `report/queries/*.sql`, `collect.py`. mart만 조회하며 실행 전 조회량을 예측해 상한 초과 시 중단한다.
- **표현 층** — 템플릿·차트·렌더러. 수치 층 산출물(JSON)만 입력받는다.
- **배송 층** — 드라이브 업로드. OAuth 토큰 기반이며 서비스 계정으로는 개인 드라이브 업로드가 불가능하다.

소표본 처리 규칙

실유저는 23명 규모이므로 분모가 한 자릿수인 지표가 발생한다. 분모 10 미만인 경우 비율을 산출하지 않고 실수로 표기하며(예: 0/2), 분모가 없는 구간은 그래프에서 0%로 표시하지 않고 선을 단절한다. 사용자 증가 시 동일 코드가 자동으로 비율 표기로 전환된다.

실행 주체를 분리한 사유

로컬 Airflow는 PC와 Docker 가동을 전제한다. 착수 시점 확인 결과 Docker가 정지 상태였고 적재가 5일 지연되어 있었다. 무인 운영이 요구되는 작업은 실행 주체가 로컬 환경 외부에 있어야 한다.

5.7 문서 체계

결정 91건을 노드 단위로 관리하며, 테이블 페이지 40건과 운영 문서 10건은 스크립트로 생성한다. 결정 1건 조회 비용은 1,268 토큰으로, 동일 내용을 단일 파일로 유지할 경우의 4,484 토큰 대비 약 3.5배 낮다. 상세는 별도 보고서를 참조한다.

6. 검증 체계




그림 3. 검증 항목 구성 (총 662개). 항목 수는 대상 범위에 비례한다 — 품질 검증은 테이블 40개에 대해 자동 생성된다.

검증의 설계 기준은 "실행되었는가"가 아니라 "결과가 정확한가"다. 7절의 장애 대부분이 정상 종료 상태에서 발생했기 때문이다.

7. 주요 장애 사례

기록된 장애는 모두 예외를 발생시키지 않았다. 파이프라인은 정상 종료되었고 수치만 부정확했다.

유형	내용	대응
규모에서만 발생	파티션 테이블은 일 4,000회의 파티션 수정 한도가 있으며, 적재 1건이 N개 파티션에 걸치면 N회로 계산된다. 2,620만 행 적재 중 중단되었다.	파티션 컬럼 순서로 추출하도록 변경
중분 적재의 누락	원천 구분 없는 조인, 컬럼 추가 후 워터마크 정지, 삭제 행의 잔존, 과거 시각 백필 등 4개 경로에서 누락이 발생했다.	적재 후 행 수 대조를 필수화
기본값에 의한 시각 왜곡	워터마크 컬럼의 기본값이 now()여서 일괄 적재 시 786만 행의 시각이 적재 시점으로 통일되었다. 3개월분이 하루로 압축되어 파티션이 무의미해졌다.	원래 시각으로 복원하는 스크립트 추가
문서와 코드의 불일치	DDL 주석을 근거로 힌트 요금을 설명했으나, 해당 요금제는 마이그레이션으로 이미 폐기된 상태였다. DDL은 현재 스키마가 아니라 시작 상태다.	주석에 경고 삽입, 문서 검사 항목 추가
설정 미반영	설정 파일에 값이 존재하나 코드가 읽지 않는 사례가 9건 발생했다. 오류 없이 데이터가 생성되어 분석 단계에서야 확인되었다.	설정 로딩 방식을 구조적으로 변경

표 6. 주요 장애 사례 5종

8. 정량 결과

구분	값	비고
기간	28일	작업일 15일 · 커밋 160건
완료 단계	27 / 28	웹앱 20 + 파이프라인 8 (P3 DAG 전환 미완)
스키마	40표 · 342컬럼	42 → 41 → 40으로 축소
Python	11,720줄	생성기 · 적재 · 검증 · 보고서
SQL	7,120줄	DDL · 마이그레이션 · RLS · stg · mart · 보고서 쿼리
TypeScript	4,834줄	웹앱 화면 및 도메인 모듈
BigQuery raw	1억 2,373만 행	8.74 GiB · 무료 한도의 87%
stg / mart	뷰 10 / 표 8	저장 0 / 495 MiB
대시보드	5쪽	mart 전용 연결
주간 보고	3쪽 · 주 1회	조회량 0.17 GiB/회 · 실행 11분
검증 항목	662	품질 430 · RLS 201 · 정합성 17 · 문서 9 · 게이트 5
결정 노드	91	대체됨 4 · 운영 문서 10 · 테이블 페이지 40
PDF 보고서	19	EDA 8 · 프로젝트 5 · 설명서 6
합성 데이터 판본	9	1개월 샘플 3 + 12개월 6 (v5 확정)
인프라 비용	0원	전 구간 무료 한도 내

표 7. 정량 결과

9. 교훈

1. **데이터 파이프라인의 결함은 예외로 나타나지 않는다.** 웹 애플리케이션은 화면이 표시되지 않아 즉시 인지되지만, 파이프라인은 정상 종료 상태로 부정확한 수치를 산출한다. 검증 662항목은 이 성질에 대응하기 위한 것이다.
2. **규모를 키우면 다른 종류의 문제가 발생한다.** 786만 행에서 확인되지 않던 파티션 한도와 시각 왜곡이 1억 행에서 나타났다. 합성 데이터를 별도로 구축한 이유가 여기에 있다.
3. **설정에 값이 있어도 코드가 참조하지 않으면 존재하지 않는 것과 같다.** 9회 반복된 사례이며, 모두 오류 없이 진행되어 분석 단계에서 확인되었다.
4. **규율은 검사로 전환해야 유지된다.** 개인의 주의에 의존한 항목은 예외 없이 이탈했고, 검사로 정의한 항목만 유지되었다.
5. **무인 운영은 실행 주체의 위치가 결정한다.** 로컬 스케줄러는 로컬 환경 가동을 전제하므로, 그 전제가 성립하지 않는 작업은 외부로 분리해야 한다.

10. 잔여 과제

항목	내용	우선순위
----	----	------

신고 처리 화면	sanction 테이블에 처리 경로가 없어 신고가 미처리 상태로 누적된다. 주간 보고서가 매주 이 수치를 표시한다(현재 7일 이상 미처리 3건).	높음
P3 NEIS DAG 전환	학교·학급·급식·학사일정 수집은 완료했으나 DAG로 전환하지 않았다. 계획 대비 유일한 미완 단계다.	중간
규약 파일 정리	매 세션 적재되는 규약 파일에 노드와 중복된 요약이 포함되어 있다.	중간
시간표·공지 화면	W8 학교 정보 중 미구현 항목이다.	낮음

표 8. 잔여 과제

부록 A · 재현 절차

```
# 스키마
python db/apply.py --target supabase          # DDL + 마이그레이션 적용
python db/rls/verify.py                      # 권한 검증 201항목
python db/replay_check.py                    # 재생성 동일성 확인

# 합성 데이터
python generator/generate.py --config synthetic-v2.yaml
python generator/load.py --in <폴더> --truncate

# 파이프라인
python pipeline/extract_load.py --source supabase
python pipeline/verify_load.py --source supabase
python qa/quality_check.py --source supabase
python bigquery/build.py --layer mart

# 주간 보고
python report/collect.py                     # mart → JSON
python report/render.py                      # JSON → PDF
python report/deliver.py                     # PDF → Drive

# 문서
python db/doc_lint.py                        # 문서 검사 9종
python db/token_bench.py                     # 문서 구조 효과 측정
```

PING-V2 프로젝트 완료 보고 · 2026-08-25 · 원본 [docs/PROJECT-CLOSING.html](#)

관련 문서: 위키 리포트(문서 체계) · 주간 보고서 구축 기록 · 스테이징·마트 안내서 · 합성 데이터 결정 이력