

합성 데이터를 만들기 전까지 무엇을 했고 무엇을 확인했나

구 서비스의 분석 불가 지점을 찾아 스키마를 다시 설계하고, 그 스키마를 실제로 돌려본 뒤, 파이프라인을 붙이기까지의 경과.

기준일	2026년 7월 31일
범위	합성 데이터 생성 직전까지. 생성 계획은 별도 문서
산출물	스키마 40테이블 342컬럼 · 웹앱 배포본 · BigQuery 적재 파이프라인
커밋	61개

01 왜 데이터를 새로 만들기로 했나

받은 데이터로는 답할 수 없는 질문이 많았다. 데이터가 부족해서가 아니라 구조가 답을 막고 있어서였다.

기존 학교 소셜 투표 서비스의 DB(가입자 67.7만 명, 14개월치)를 분석하면서 분석을 가로막는 결함이 반복해서 나왔다. 세 가지가 특히 컸다.

발견한 구조적 결함

무엇이	어떻게 막았나
탈퇴 기록에 유저 식별자 없음	탈퇴 70,764건(가입자의 10.5%)이 쌓였지만 누가 나갔는지 알 수 없었다. 이탈 분석이 원천적으로 불가능했고, 사유는 "기타 57%"라는 블랙박스로 남았다.
하트 원장이 잔액을 설명 못 함	원장의 순합계는 201만인데 유저 잔액 총합은 20억이었다. 가입 지급과 결제가 원장을 거치지 않았기 때문이다. 잔액을 원장으로 재구성할 수 없었고, 누락을 탐지할 방법조차 없었다.
FK 39개 중 17개만 선언	관계가 코드에만 있고 DB에 없었다. 고아 행이 생겨도 막히지 않았고, 조인 결과를 신뢰할 근거가 없었다.

핵심 인식 — 이 결함들의 공통점은 오류를 내지 않는다는 것이다. 서비스는 정상 동작했고, 로그도 쌓였다. 다만 나중에 물어볼 수 없게 되어 있었을 뿐이다. 이후 프로젝트 전체의 판단 기준이 여기서 나왔다 — "조용히 틀리는 것"을 찾아 코드로 막는다.

그래서 데이터를 새로 만들되, 같은 결함을 반복하지 않는 스키마를 먼저 설계하기로 했다.

02 전체 흐름

스키마 설계 → 실제 서비스로 검증 → 파이프라인 → 데이터 생성. 가운데 단계가 이 프로젝트의 특징이다.

STEP 1	스키마 재설계 구 서비스의 결함을 하나씩 닫는 방향으로 새로 설계. 탈퇴에 <code>user_id NOT NULL</code> , 모든 하트 증감이 원장을 거치도록, 관계는 전부 FK로 선언.
STEP 2	합성 데이터로 1차 검증 786만 행을 만들어 제약이 실제로 작동하는지 확인. 제약 위반 16종이 차단되는 것을 검증.
STEP 3 ★	MVP 서비스를 실제로 구동 스키마 위에 웹앱을 올려 지인에게 열고 실제 쓰기 를 받았다. 설계만으로는 알 수 없는 것들이 여기서 드러났다.
STEP 4	파이프라인 연결 Airflow + BigQuery. 증분 적재, 삭제 감지, 행 수 대조까지.
STEP 5	스키마 확정 · 옛 합성 데이터 폐기 MVP 운영 중 스키마가 계속 바뀌어 786만 행이 낡았다. 전부 지웠다.
다음	합성 데이터 생성 → 분석 · 시각화 확정된 40테이블 342컬럼 위에서 처음부터 다시 만든다.

STEP 3 이 왜 중요한가 — 보통은 스키마를 설계하고 곧바로 합성 데이터를 뽑는다. 그러면 **그 스키마가 실제 쓰기를 견디는지 아무도 모른 채** 수천만 행을 만들게 된다. 제약이 너무 빡빡한지, 권한 설계가 감당되는지, 정합성이 유지되는지가 전부 미검증으로 남는다. MVP를 먼저 돌린 덕에 그것들이 증명됐고, **지금 만드는 합성 데이터는 구조적으로 신뢰할 수 있다.**

03 MVP 서비스 — 무엇을 만들었나

데이터를 만들기 위한 수단이지만, 실제로 접속해서 쓸 수 있는 서비스다.

서비스 개요

학교 기반 익명 투표. 친구를 5명 맺으면 투표가 열리고, 질문마다 친구 4명이 후보로 나온다. 지목당한 사람은 누가 자기를 뽑았는지를 하트로 사서 알아낸다. 그 하트가 이 서비스의 통화다.

개인정보를 받지 않는다 — 설계 제약

받지 않는 것	대신
이메일 · 비밀번호	익명 계정 (접속 즉시 자동 생성)
전화번호	친구 추가는 초대 코드 로만
실명	유저가 정하는 닉네임

유저가 입력하는 것은 **닉네임 · 성별 · 소속(학교·반)** 셋뿐이다. 이메일·전화번호·실명 컬럼이 스키마에 **아예 없다**. 누락이 아니라 설계다.

구현한 기능 20단계

단계	기능
W0-W2	익명 인증 · 권한 설계 · 앱 뼈대
W3-W5	온보딩 · 친구 맺기 · 투표
W6-W7	받은 투표 · 배포 (개인정보처리방침, 초대 링크)
W8	급식표 (NEIS 연동)
W9-W10	자유게시판 · 친구 추천
W11-W13	프로필 수정 · 계정 삭제 · 하트 충전
W14-W15	선택형 힌트 · 1회성 답장
W16-W19	학사일정 · 스키마 정리 · 친구 끊기

실제 이용 실적 (2026-07-31)

23 유저	670 투표	1,316 하트 거래	110 힌트 구매
-----------------	------------------	-----------------------	---------------------

성인 지인 대상 클로즈드 테스트. 상용 출시가 목적이 아니라 **실제 쓰기가 발생하는 환경**을 만드는 것이 목적이었다.

04 실제로 돌려봐서 잡은 것들

설계 검토나 합성 데이터만으로는 **하나도 나오지 않았을** 문제들이다. 이 장이 STEP 3의 값어치다.

운영 중 드러난 결함

무엇이	어떻게 드러났나
프로덕션 투표가 죽었다	WHERE 없는 <code>DELETE</code> 한 줄. 운영 환경은 브라우저 접속 역할에 안전장치가 걸려 있어 임시 테이블에서도 막는다. 시험 128항목이 전부 통과하는데도 앱이 죽었다 — 시험은 다른 역할로 접속해 그 설정이 적용되지 않았기 때문. 이후 소스를 직접 훑는 검사 를 추가했다.
돈 낸 사람이 빈 화면을 봤다	힌트 구조를 바꾸면서 옛 구매 19건에 필요한 값이 비어 있었다. 오류는 없고 화면만 비어 있었다 . 300하트를 낸 사람이 아무것도 못 보는 상태.
정합성 검사 3종이 낡았다	친구 끊기를 열자 검사 세 개가 한꺼번에 틀리기 시작했다. 셋 다 데이터가 아니라 검사가 틀린 경우였다. 검사는 쓰인 시점의 세계를 알고 있고, 그 세계는 기능이 늘 때마다 바뀐다.
지운 계정이 오늘 활동했다	BigQuery는 원천의 삭제를 모른다. 지운 계정과 그 활동이 계속 집계에 남아 "오늘 들어온 사람"이 실제로보다 부풀었다. 삭제를 표시로 남기는 방식으로 해결.
786만 행이 전부 NULL이었다	컬럼을 추가해도 갱신 시각이 움직이지 않아 증분 적재가 아무것도 잡지 못했다 . 새 컬럼이 조용히 비어 있었다.
옛 마이그레이션이 새 스키마에서 깨졌다	표를 지우거나 이름을 바꾸자 옛 마이그레이션이 실행 불가가 됐다. 운영 DB에서는 멀쩡했다 — 거기엔 옛 표가 실제로 있었으므로. 새로 받은 사람만 막혔을 문제.

여섯 건의 공통점 — 전부 **오류를 내지 않았다**. 1장에서 구 서비스를 보며 찾아낸 결함과 정확히 같은 성질이다. 그래서 발견할 때마다 문서 경고로 남기지 않고 **실행되는 검사로 바꿨다**.

05 검증 체계

위 문제들을 겪으면서 만든 **자동 검사 4종**. 배포 전에 전부 통과해야 한다.

검사	항목	무엇을 막나
db/rls/verify.py 권한 침투·정상동작	201	남의 데이터가 보이는지, 그리고 열려 있어야 할 것이 막히지 않았는지 . 전부 차단해도 침투 시험은 통과하므로 양방향일 필요하다.
qa/checks/integrity.sql 정합성	17	하트 원장이 잔액을 설명하는가, 후보가 전부 친구인가 등. 제약으로 표현할 수 없는 규칙만 본다 .
db/replay_check.py 재현성	-	처음부터 다시 만들어도 같은 스키마가 나오는가. 임시 DB에 전부 다시 돌려 운영 DB와 대조한다.
pipeline/verify_load.py 적재 대조	40표	원천과 BigQuery의 행 수 대조. 증분 적재는 조용히 틀린다 .


설계 원칙 — 검사는 **실패를 재현할 수 있을 때만** 의미가 있다. 권한 시험이 128항목을 통과하고도 프로덕션을 못 지킨 경험 이후, "이 검사가 정말 그 실패를 잡는가"를 항상 되묻는다. 잡지 못하는 종류(세션 설정에 딸린 동작)는 **소스를 직접 훑는 방식**으로 따로 막았다.

보안 설계의 뼈대

- 읽기는 필요한 것만, 쓰기는 거의 **열지 않는다**. 하트·투표 조작은 전부 서버 함수로. 클라이언트가 원장에 직접 쓸 수 있으면 하트를 무한정 만들 수 있다.
- **id로 남을 지목할 수 있는 경로를 만들지 않는다**. 유저 id는 1부터 이어지는 정수다. 친구 요청을 직접 열었더니 코드 없이 전체 가입자를 지목할 수 있었다.
- **컬럼을 가려야 하면 뷰를 쓴다**. 행 단위 보안으로는 컬럼을 숨기지 못한다. "누가 나를 뺐었나"는 하트를 받고 파는 유료 정보라 뷰로만 노출한다.

06 파이프라인

운영 DB → BigQuery. 증분 적재가 **조용히 틀리지 않게** 하는 데 대부분의 노력이 들어갔다.



증분 적재에서 실제로 걸린 함정

함정	어떻게 막았나
적재 중 커밋된 건이 영영 누락	기준 시각을 5분 뒤로 물려 저장한다. 스냅샷 시각 그대로 쓰면 그 사이에 커밋된 트랜잭션이 다음 회차에도 안 잡힌다.
지운 행이 영원히 남음	원천의 삭제를 표시로 기록 한다. 원본 층은 이력을 잃지 않되, 분석 쿼리는 그 표시를 반드시 걸 러야 한다.
컬럼을 추가해도 증분이 못 잡음	스키마 변경은 갱신 시각을 건드리지 않는다. 컬럼 추가 후에는 그 표를 통째로 다시 적재한다.
두 원천의 id가 실제로 겹침	실유저와 합성이 같은 표에 들어가고 둘 다 id가 1부터다. 원천 구분 없이 조인하면 조용히 섞인 다.

현재 적재 상태

40 테이블	35,976 행 (실유저)	2.9 MB	0 누락
------------------	--------------------------	------------------	----------------

07 확정된 스키마

구 서비스의 결함을 닫고, MVP 운영으로 검증된 상태. 40테이블 342컬럼 FK 76개.

구 서비스 대비 무엇이 달라졌나

영역	구 서비스	새 스키마
이탈	탈퇴에 유저 식별자 없음	탈퇴에 user_id NOT NULL + 사유 코드 + 자유 서술
하트	원장이 잔액을 설명 못 함	모든 증감이 원장 하나를 거친다. 거래마다 직후 잔액을 남겨 즉시 대조 가능
관계	FK 39개 중 17개만 선언	FK 76개 전부 선언. 신고와 제재도 FK로 연결
질문	카테고리 없음 — 사후 수동 분류	카테고리 + 민감 표시를 사전에
제재	임계값이 코드에만. 253회 신고받은 유저도 정상 상태	임계값을 데이터로 정의 — 감사 가능
관계 종료	—	친구를 끊어도 행을 지우지 않고 종료 시각을 남긴다. 관계 이탈 신호를 잃지 않는다

규모

구분	표	컬럼	비고
마스터 (선택지·코드표)	7	—	시드 SQL이 채운다
활동 데이터	19	—	생성기가 채운다
게시판 · 신고 · 제재 · 학교정보	14	131	아직 생성기 없음
합계	40	342	FK 76

합성 데이터를 지운 이유 — MVP를 운영하는 동안 스키마가 계속 바뀌었다. 힌트 구조가 통째로 교체됐고, 컬럼이 여럿 늘었고, 표 하나가 사라졌다. 7월 29일에 만든 786만 행은 이제 존재하지 않는 서비스를 그리고 있었다. 보관 가치가 0이 아니라 마이너스라 전부 지웠다. 만드는 코드는 그대로 남아 있다.

08 지금 상태와 다음 단계

스키마 확정 · 서비스 가동 중 · 파이프라인 연결 완료 · 합성 데이터 없음.

완료

- 스키마 40테이블 342컬럼 확정
- 웹앱 배포 · 지인 23명 이용 중
- 권한 시험 201항목 통과
- 정합성 검사 17종 위반 0
- Airflow + BigQuery 적재 가동
- NEIS 연동 (학교·학급·급식·학사일정)
- 재현성 검사 통과
- 옛 합성 데이터 정리 완료

다음 — 합성 데이터 생성

확정된 스키마 위에서 **처음부터 다시** 만든다. 실데이터와는 **완전히 별개의 가상 세계**이며, "이 서비스가 활성화 되었다면 어떤 데이터가 쌓였을까"를 통째로 지어낸다. BigQuery에는 원천 구분자로 갈라져 함께 올라간다.

결정된 방향

구분	내용
실제를 쓰는 것	학교 · 지역 · 학급 편성 · 급식 · 시간표 · 학사일정 — 전부 NEIS 공개 데이터. 개인 정보가 없는 것만 실제를 쓴다
지어내는 것	유저 · 친구 · 투표 · 힌트 · 하트 · 게시판 · 신고 · 제재 — 전부
기간	한 학년도를 통째로. 학사 주기(학기·방학·시험)가 한 바퀴 돌아야 계절성이 보이고, 그 경계를 NEIS가 진짜 날짜로 알려준다

발표에서 미리 밝힐 것 — 합성 데이터로 하는 분석은 근본적으로 **"심어놓은 것을 다시 찾는"** 성격을 벗어나기 어렵다. 실제 학사일정을 축으로 쓰면 심는 자리가 진짜 달력이 되고 분석 파이프라인이 실전과 같은 모양이 되지만, 그것이 **이 서비스에 대한 발견은 아니다**. 이 데이터가 증명하는 것은 **파이프라인과 분석 기법**이며, 그 점을 스스로 먼저 밝히는 편이 훨씬 강하다.

남은 작업

- 생성기가 **옛 힌트 모델**로 데이터를 만든다 — 요금이 10배 다르다. 교체 필요
- 게시판 · 신고 · 제재 등 **14개 표는 생성기가 아직 없다**
- 생성 후 정합성 17종 통과 확인 → BigQuery 적재 → 행 수 대조