

합성 데이터를 만들기까지

30개 질문 · 9개 판본 · 뒤집힌 결정 12건 — 무엇을 정했고, 무엇이 틀렸고, 왜 바꿨는가

기간 2026-07-29 (v1 생성) ~ 2026-08-04 (v3 확정 직전)

원본 docs/synthetic-v2-decisions.md (30문답) · EDA-sample-1m-v{1,2,3} · EDA-final-12m-v{1,2} · docs/decisions/ 결정 노드 · 커밋 이력

이 문서의 쓰임 "왜 이 값인가"를 나중에 되짚기 위한 것이다. 설정 파일은 값만 남기고 기각한 대안은 남기지 않는다

0. 한 장 요약 — 아홉 번 만들고 세 번 버렸다

판본	규모	행	무슨 일이 있었나
v1 7/29	20,000명·3개월	786만	폐기
스키마가 마이그레이션 004~010 을 못 따라갔다. admin_user 5행이 남아 있고 힌트 구조가 옛것이였다. 보관 가치가 0이 아니라 마이너스라 지웠다			
1m v1 8/3	500명·1개월	75.8만	구조는 맞고 볼륨과 분포가 틀렸다 — 깨진 것 4가지
1m v2 8/3	500명·1개월	12.7만	5가지 해결. 하트 문제의 성격이 정반대로 뒤집혔다
1m v3 8/3	500명·1개월	114.9만	페르소나 도입 · 확률 보정 · 우측 절단 발견
12m v1 8/4	20,000명·12개월	1억 4,126만	성장 곡선 첫 구현. 8개 결함 발견
12m v2 8/4	20,000명·12개월	1억 8,826만	8건 중 7건 해결. 전면 감사에서 새 결함 3건
12m v3 8/4	20,000명·12개월	1억 8,918만	감사 3건 해결 — 하루 리듬 · 비투표 유저 · 같은 반 친구. 접속 세션 결함으로 폐기
12m v4 8/5	20,000명·12개월	1억 8,922만	접속 세션에도 리듬. 확정했다가 정밀 EDA 에서 결함 1건 · 경계 5건 발견
12m v5 8/5	20,000명·12개월	1억 2,370만	확정. 요구사항 7가지 구현 · v4 의 "할 수 없다" 15종 중 9종 해금

⚠ v4 는 "확정"했다가 같은 날 뒤집혔다

정합성 17종·이상치 9종이 전부 0이고 목표 지표도 전부 통과해서 확정했다. 그 직후 정밀 EDA 를 돌렸더니 하루에 406.8시간 투표한 유저-일이 나왔다 (하루는 24시간이다). 검사 26종 어디에도 "하루에 몇 번까지가 사람인가"를 묻는 항목이 없었다.

교훈은 검사가 아니라 순서다. 확정 전에 정밀 EDA 를 돌렸어야 했다 — 검사를 통과하는 것과 그럴듯한 것은 다르다.

이 이력에서 가장 자주 반복된 실패

"설정에 값은 있는데 코드가 안 읽는다." 열 번 나왔다 — growth · schools.tiers · schools.adoption · retention.reactivation_rate · popularity.top10_share · Q23 시간대 리듬 · behavior · sessions.weekend_multiplier · sessions.hour_weights · sessions.votes_per_app_session.

⚠ 마지막 것은 v5 를 만들면서 새로 만든 것이다. 앞의 아홉을 찾아내 고치는 그 작업 안에서 같은 함정을 다시 밟았다 — 설정에 키를 넣고 구현은 다른 방식으로 갔다.

전부 오류가 나지 않는다. 설정 파일을 읽으면 그 기능이 있는 것처럼 보이고, 데이터를 다 만들어 분석해 봐야 없다는 것이 드러난다.

1. 출발점 — 왜 합성 데이터인가

실유저가 23명이다. 이 규모로는 답할 수 없는 질문이 대부분이다.

물고 싶은 것	실유저 23명으로 가능한가
가입 후 1년간 얼마나 남는가 (잔존)	불가능 — 서비스가 시작된 지 며칠이다
방학·시험기간에 활동이 어떻게 변하나	불가능 — 12개월을 관측해야 한다
하트를 사는 사람과 안 사는 사람이 어떻게 갈리나	불가능 — 표본이 너무 작다
민감한 질문이 실제로 더 신고되나	불가능 — 신고 자체가 거의 없다
파이프라인이 대량 데이터에서 도는가	합성으로만 확인 가능

다만 합성 데이터는 정답이 아니다. 내가 정한 분포대로 나오게 만든 것이므로, "합성에서 이런 결과가 나왔다"는 내가 그렇게 설정했다는 뜻 이상이 아닐 수 있다. 합성으로는 분석 방법과 파이프라인을 검증하고, 사실 판단은 실 데이터로 한다.

2. 30개 질문 — 무엇을 물었고 무엇을 답했나

v1 을 버린 뒤, 생성기를 고치기 전에 먼저 정해야 할 것을 30개 질문으로 정리했다. 각 질문에는 추천안과 기각 사유가 붙어 있고, 팀이 답을 채웠다.

A. 규모와 시간 (Q1~Q6)

번호	질문	답	근거 / 나중에 어떻게 됐나
Q1	학교를 몇 개로?	활성 50개 (마스터는 NEIS 실제 5,724개)	균등 분산하면 학급당 1명이 되어 친구 그래프가 성립하지 않는다
Q2	총 이용자	20,000명 (무료티어 위험 시 축소 가능)	끝까지 유지됐다. 비용 걱정은 기우로 판명(월 135원)
Q3	기간	12개월 — 웹앱 로그가 쌓이기 정확히 1년 전부터 전날까지	합성 구간과 실유저 구간이 겹치지 않고 맞닿는다
Q4	우상향인가 우하향인가	실패 → 저점 → 회복(추천 C)	→ 8/4 에 불확기형으로 교체. 아래 6장
Q5	학교가 동시에? 순차로?	순차 확산	→ 2026-08-04 까지 구현 안 됐다. 12m v2 에서야 붙었다
Q6	행수 상한	4,000만 → 1억	→ 폐기. 상한 자체가 잘못된 도구였다. 아래 7장

B. v1 결함을 어디까지 손대나 (Q7~Q10)

번호	질문	답	의미
Q7	하트-원장 불일치를 재현할까	전면 교정. 재현하지 않는다	구 서비스의 버그까지 베끼면 "버그인지 설계인지" 구분이 안 된다
Q8	v1의 다른 결함들	추천대로	
Q9	탐지 연습용 이상치를 심을까	심되 플래그 없이, 목록은 봉인	플래그를 남기면 정답을 주는 것과 같다
Q10	실유저와 어떻게 섞나	추천대로	BigQuery 에서만 만나고 <code>_source</code> 로 가른다

C. "342컬럼을 채운다"의 정의 (Q11~Q13)

번호	질문	답	의미
Q11	NULL 허용 66개 컬럼	비-NULL 1% 이상이면 "채웠다"	최종 실측 342개 중 340개
Q12	자유 텍스트를 어떻게	문장 풀에서 조합	
Q13	무엇을 놓지 않을까	별명은 본명처럼 (예: 김형민) · 학교명은 NEIS 실명 · 전화번호·이메일 문자열 금지 · 신고 사유의 실제 욕설은 허용	욕설을 허용한 이유는 신고·제재 분석이 성립하려면 실제 표현이 필요해서다

D. 생성기가 없던 14개 표 (Q14~Q18)

번호	표	답	비고
Q14	게시판 4표	활성의 40%가 글, 70%가 댓글. 글당 댓글 2~3개, 좋아요 4개. 좋아요가 압도적인 "떡상" 글 존재	추천(12%)보다 크게 올랐다 — 게시판이 얇으면 분석할 것이 없다
Q15	신고·제재·차단 3표	투표 1,000건당 신고 4건, 70%만 검토	PENDING 30%는 버그가 아니라 운영 현실
Q16	학교 정보 6표	이미 받아온 20개 학교 데이터로 50개를 합성 (API 재호출 없음)	NEIS 호출량을 아끼는 판단
Q17	"안 볼래"	일정 비율로 존재	실서비스는 0행인 표를 채운다
Q18	1회성 답장	힌트 없이도 답장 가능. 힌트 없이 4%, 힌트 사고 20%, 신고 2%	추천안(힌트 구매자의 8%)을 뒤집었다 — 힌트가 답장의 전제가 아니다

E. 질문과 투표 — 서비스의 심장 (Q19~Q23)

번호	질문	답	나중에 어떻게 됐나
Q19	질문 몇 개, 어떻게	240개. 외모·신체 질문 포함 — 신고율을 확인하기 위해. "이를 위해 원칙을 수정해도 됨"	→ 마이그레이션 012 로 실서비스 카테고리까지 열었다. 12m v2 에서 3.4배 신고율 확인
Q20	스코프 배분과 padded	CLASS 35 / SCHOOL 35 / GLOBAL 30. 후보가 모자라면 친구 전체에서 채움	최종 실측 30.6 / 35.0 / 34.4 — CLASS 가 4.4%p 미달
Q21	누가 표를 받나 (인기도)	상위 10%가 지목의 45%	→ 도달 불가로 판명. 목표를 49%로 고쳤다. 아래 8장
Q22	이성인가 동성인가	연애 계열 이성 78%, 우정·성격은 동성 65%	성별 힌트를 파는 구조의 근거
Q23	언제 투표하나 (시간대)	점심 12~13시 최대 봉우리, 등교 전·하교 후·심야 봉우리. 주말은 평일의 55%	→ 2026-08-04 에 구현하면서 모양을 뒤집었다. 최대 봉우리가 밤 22~23시다. 아래 9장

F. 하트 경제 (Q24~Q26)

번호	질문	답	의미
Q24	힌트 요금	현행 앱 구조(20하트 균일)로 변경. 이유: 기존 누진(200~1,000)은 BM 허들이 높아, 콜드스타트 이론대로 적은 비용으로 시작하는 서비스로 전환	설정 파일이 스키마와 어긋나 있던 것을 발견해 고친 사례
Q25	하트가 남는가 모자라는가	서비스가 활성화되면 부족, 인기 없으면 남음	추천안("완만한 부족")보다 조건부로 답했다. 1m v3 에서 이 구조가 실제로 나타났다 — 유저의 72%는 남고 상위 18%만 쏘들린다
Q26	결제	18%, 해비과금러 존재. 합성은 실결제(스텝 아님)	합성의 목적이 매출 분석이라 스텝을 쓰지 않는다. 최종 실측 결제자 18.2%

G. 파이프라인과 재현성 (Q27~Q30)

번호	질문	답	의미
Q27	시간대 저장	UTC 저장, 행동은 KST 기준	안 정하면 "점심에 몰린다"가 새벽 3시로 보인다
Q28	증분 실증용 2차 배치	추천대로 ("무슨 말인지 모르겠음")	→ 아직 안 함. 증분 적재의 함정 4개를 실제로 재현해 볼 유일한 방법
Q29	재현성	시드 20260803 고정 + manifest	같은 시드 + 같은 config = 같은 데이터
Q30	무엇이 "완료"인가	게이트 5개 — 정합성 17종 · 컬럼 342 · 표 40 · 적재 대조 · 분포는 사람이 눈으로	앞의 넷은 기계가 통과시켜도 곡선이 이상한 데이터를 막지 못한다

3. 1개월 샘플 세 판본 — 값을 맞춰 나간 과정

전체 규모는 한 번 돌리는 데 몇 시간이다. 분포가 틀린 걸 나중에 발견하면 그만큼 날아간다. 그래서 500명 · 1개월로 세 번 돌리며 값을 잡았다.

항목	v1	v2	v3	목표
총 행수	757,699	127,495	1,149,566	—
유저당 투표세션/월	22.5	2.1	32.4	활성 100~200
친구 5명 해금	100%	92.4%	93.6%	90~95%
힌트 구매 유저	99.8%	70.8%	73.4%	70~80%
상위 10% 지목 점유	18.4%	45.8%	47.9%	45%
글 쓴 유저(활성)	33%	39.1%	40.6%	40%
하트 소비/적립	12.8%	7.5%	33.8%	높을수록 건강
잔액 100 미만	0%	18.6%	22.6%	—

1m v1 — 구조는 맞고 볼륨과 분포가 틀렸다

- ① 고립 유저가 0명 — 게이트 퍼널이 통째로 없다

설정에 `locked_user_ratio: 0.08` 이 있고 코드도 읽는다. 그런데 친구 관계가 양방향이라, "친구를 2명만 만들 사람"으로 정해도 남들이 그를 골라 친구가 계속 붙는다. 목표치는 **본인이 먼저 거는 횟수만** 제한했다.

고친 방법 — 고립 유저를 남의 후보 풀에서도 뺀다(`locked_hard`).
- ② 활동량이 약 12배 과다 — 세션 수가 기간과 무관하다

`sessions_per_active_user: [1, 40]` 이 전체 기간에 적용됐다. 12개월이든 1개월이든 최대 40세션이라, 1개월 샘플이 12개월치 활동을 압축해 담았다.

그 결과 힌트 구매자가 99.8% 가 됐다 — 받은 투표가 145개나 되니 그중 하나라도 힌트를 살 확률이 사실상 1이 된다.

고친 방법 — 세션 수를 활동 기간에 비례시키고, 잔존 구간마다 다른 빈도를 준다.
- ③ 하트가 남아돌아 결제할 이유가 없다

적립 224만 vs 소비 28만(12.8%). 잔액 중앙값 2,377 — 힌트 118개를 살 수 있는 액수다. 이 상태로는 결제 전환 15%가 데이터로 설명되지 않는다.
- ④ 인기도 먹법칙이 없다 (18.4%, 목표 45%)

후보를 무작위로 뽑기만 하고 인기도 가중치를 안 넣었다. 미구현 항목이었고 EDA 가 그것을 수치로 확인했다.

1m v2 — 다섯 개가 해결되고, 하트 문제의 성격이 뒤집혔다

같은 숫자가 정반대를 뜻한다

	v1	v2
소비 / 적립	12.8%	7.5%
잔액 중앙값	2,377	325
잔액 부족 무산	336건	1,490건

v1 의 낮은 소비율은 남아돌아서였고, v2 의 낮은 소비율은 모자라서다 — 힌트 구매 시도의 37%가 잔액 부족으로 무산됐다.

지표 하나만 보면 정반대 상황을 구분할 수 없다. 이 이력에서 가장 값진 발견 중 하나다.

⚠ v2 의 진단은 틀렸고, v3 에서 정정됐다

v2 리포트는 "가입 지급 300하트를 낮추자"로 끝났다. 틀렸다 — 가입 지급은 순수 공급이라 줄이면 부족이 악화된다.

그 제안은 "소비/적립 비율을 올리자"는 생각에서 나왔는데, 그건 분모를 깎아 지표를 좋게 보이게 하는 것이지 문제 해결이 아니었다.

v3 에서 받은 투표 수로 구간을 갈라 보니 유저의 72%는 남아돌고 상위 18%만 쪼들리며, 결제율도 그 구간에서만 올라간다. 애초에 평균으로 볼 문제가 아니었다.

1m v3 — 페르소나, 확률 보정, 우측 절단

페르소나 — 분류가 아니라 생성 편의

6개 유형을 두되 결과 데이터에 6덩어리가 또렷하게 남으면 실패로 봤다. 분석자가 클러스터링해서 우리가 넣은 유형을 그대로 되찾는 데이터에는 발견할 것이 없다.

배정을 흐리는 장치	인원	내용
단일 유형	359	한 유형을 그대로
혼합	86	두 유형을 6:4로 섞는다 — 경계가 사라진다
트레잇 교차	37	"관망형인데 댓글만 게시판형"
무배정	18	유형 없이 전 트레잇 독립 무작위

검증 방법 — 각 행동 지표의 상위 10%에 5개 이상 유형이 섞여 있는가. 6개 지표 전부 6~7개 유형이 섞였다. 댓글 상위 10%의 4분의 1이 관망형이고, 게시판형 2명이 세션 상위 10%에 있다.

구조적 결함 ① — 확률에 배수를 걸면 모집단 평균이 샌다

트레잇 평균이 정확히 1.0이어도, 확률에 곱해 1을 넘지 않게 오즈비로 변환하면 변환이 불룩해서 평균이 아
래로 당겨진다. 열람률이 55.5% → 39.2%로 섰다.

설정값을 손으로 올려 맞추는 것은 답이 아니다 — 트레잇 분포가 바뀔 때마다 다시 들어진다. 보정 계수를 이
분법으로 풀어 캐시하도록 고쳤다 (Generator.pchance).

구조적 결함 ② — 열람률 41.8%는 모델 오류가 아니라 우측 절단이다

받은 투표는 1~72시간 뒤에 열람된다. 기간 끝 3일치는 열람 시각이 관측 창을 넘어가 미열람으로 기록된다.
마지막 3일을 빼면 41.8% → 53.9% 다.

이건 결함이 아니라 실데이터에도 있는 현상이다. 열람률·답장률처럼 "나중에 일어나는 행동"의 비율을 낼 때
는 창 끝 3일을 제외해야 한다.

12개월 판본에서는 이 효과가 1.6%p로 줄었다 — 관측 창이 길수록 절단의 영향이 작아진다는 것이 수치로
확인됐다.

4. 12개월 v1 — 성장 곡선이 처음 그려졌다

1개월 샘플로는 원리상 검증할 수 없는 것이 있다. 3국면 성장 곡선, 코호트 잔존, 계절성이 그렇다. 12개월을 돌려
야 처음 보인다.

설정은 있는데 읽는 쪽이 없었다

growth 블록은 v2 설정부터 있었지만, 생성기는 첫 국면의 `signup_share` 하나만 옛 `signup_spike_ratio` 자리에 꽂고 나머지 네 국면을 버렸다. 12개월을 돌려도 3국면이 안 나오던 이유다.

고친 방법 — 곡선을 두 갈래로 건다.

갈래	무엇으로	어디에
가입	<code>signup_share</code>	국면마다 몇 %가 들어오는지
활동	<code>activity_multiplier</code> × 시즌 배수	세션이 그 날짜에 놓일 확률

가입만 나누면 9월에 몰려 들어온 사람들이 1월에도 그대로 활동한다 — 저점이 가입자 수에만 생기고 MAU에는 안 생긴다. 국면은 개인의 나이가 아니라 달력에 걸린 현상이다.

12m v1 이 드러낸 8개 결함

결함	실측	목표	성격
인기도 집중 과다	64.2%	45%	파라미터 미조정
민감 질문 신고율 구분 없음	1.16배	2배+	기능 미구현
완료율 두 측정 불일치	98.6 vs 84.6	일치	기록 결함
학교 순차 진입 없음	전부 첫날	순차	설정 미반영
복귀 코호트 없음	0명	9%	설정 미반영
코호트 M1→M2 절벽	26 → 4%	완만	구간 설계
계절성 약함	0.66배	0.30	구조적
성장 곡선 모양	저점→회복→성장	—	재설계 결정

5. 12개월 v2 — 8건 중 7건 해결, 새 결함 3건

항목	12m v1	12m v2	목표	판정
인기도 상위 10%	64.2%	48.1%	49%	해결
민감 질문 신고 배수	1.16배	3.4배	2배+	해결
완료율 두 측정 차	14.0%p	0.4%p	일치	해결
학교 순차 진입	전부 첫날	계층별	순차	해결
복귀 코호트	0명	636명	3월 중심	해결
코호트 M1→M2 낙차	6.8배	2.8배	완만	해결
성장 곡선	저점→회복→성장	봄학기형	봄학기형	해결
계절성 (겨울방학)	0.66배	0.58배	0.30~0.45	부분

새로 발견한 결함 3건

결함	규모	원인
시간대·요일 패턴 없음	0~23시 전부 4.2%	Q23 이 애초에 구현된 적이 없다. 세션 시각을 균등 추첨한다
해금했는데 투표 0회	2,704명 (14.6%)	계절성 물량 모드의 부작용. 세션이 1개뿐인 유저는 그 하나가 숨이면 0이 된다
같은 반 친구 미달	14.1% (설정 25%)	학급을 정원에서 유도하며 636 → 1,208개가 됐다. 잘게 쪼개진 만큼 확률이 떨어졌다

6. 뒤집힌 결정들

항목	처음	나중	왜 바꿨나
성장 곡선	저점 → 회복 → 성장 (Q4)	1~2월 저점 → 3월 봄학기 스파이크 → 서서히 감소	학교 기반 서비스는 신학기에 확 들어왔다가 학기가 끝나가며 식는다
행수 상한	4,000만 → 1억 (Q6)	폐기. 쿼리 하드캡으로 교체	코드가 안 읽어 아무것도 못 막았고, 값 자체가 틀렸다(8,500만 추정 → 1억 4천만 실측). 진짜 위험은 행수가 아니라 쿼리량이었다
인기도 목표	상위 10% = 45% (Q21)	49%	45%는 도달 불가로 판명. 아래 8장
잔존 구간	v1 실측 그대로 (4.1/28.4/35.5/27.8/4.2)	within_quarter(30~89일) 신설, 나머지 재배포	실측대로 두면 한 달과 장기 사이가 비어 M1→M2가 절벽이 된다. 의도적으로 실측에서 벗어난 유일한 항목
힌트 요금	누진 200~1,000 (v1 구조)	20하트 균일 + 이름 100	BM 허들이 높았다. 콜드스타트 이론대로 적은 비용으로 시작 (Q24)
외모 질문	실서비스 제외	실서비스에서도 켜다 (마이그레이션 012)	신고율을 재려면 민감 질문이 실제로 출제돼야 한다. "이를 위해 원칙을 수정해도 됨" (Q19 답)

답장 조건	힌트 구매자의 8% (추천안)	힌트 없이도 4%, 힌트 사면 20%	힌트가 답장의 전제가 아니다 (Q18 답)
하트 진단	"가입 지급 300을 낮추자" (1m v2)	틀렸다. 구간별로 갈라 봐야 한다	가입 지급은 순수 공급이라 줄이면 부족이 악화된다. 분모를 깎아 지표를 좋게 보이게 하는 것이었다
v4 확정 v5	"한계 5건을 고치지 않고 문서화한다"	같은 날 고쳤다	확정 직후 나온 것이 경계가 아니라 결함 이었다 — 하루 406.8 시간은 "이 속으로는 답을 못 한다"가 아니라 "답이 틀리게 나온다" 이다
하루 상한 v5	하루 12세션으로 자른다	시간 예산(투표 6시간/일)	개수로 자르니 헤비유저가 통째로 사라져 행이 반토막(9,509만) 나고 지목 쓸림이 49%→ 39% 로 주저앉았다. 막아야 하는 것은 "많이 한다"가 아니라 하루에 낼 수 없는 시간뿐 이었다
요일 패턴 v5	월 → 일 우하향 (지시)	V 자 — 금요일 최저, 주말 회복	원본(구 서비스 출석 로그)을 열어 보니 그 모양이 아니었다. 우하향으로 넣으면 일요일이 최저 가 되어 원본과 반대가 된다
인기도 alpha v5	0.45 (그 아래는 효과 없음)	1.05	쓸림의 바닥이 내려갔다 . v4 의 48.8%는 인기도가 아니라 불가능한 활동 꼬리 가 떠받치고 있었다. 꼬리를 자르니 43.7% — 이제 매력도 로 만들어야 한다

7. 행수 가드레일 — 상한이라는 도구 자체가 틀렸다

시점	상한	추정	실측	판단
초기	4,000만	—	—	근거 없이 잡은 값
8/3	1억	8,500만	—	개월^0.25 규칙으로 추정
8/4	폐기	—	1억 4,126만	추정이 60% 빗나갔다
8/4	—	—	1억 8,826만	within_quarter 추가로 또 33% 증가

왜 추정이 틀렸나

개월^0.25 규칙은 500명·1개월과 2,000명·3개월 두 점으로 맞춘 것이라 유저 수와 기간이 같이 움직였다. 기간만 12배로 늘리자 규칙이 깨졌다.

진짜 원인은 sessions_per_month_by_tier 다. long_term 유저의 활동일이 1개월 샘플에서는 최대 30일인데 12개월에서는 360일이 된다. 1개월 샘플로는 원리상 검증할 수 없는 파라미터였다.

그리고 비용 걱정은 기우였다

항목	값	비고
BigQuery 논리 바이트	13.85 GiB	무료 한도 10 GiB
초과분 저장 비용	월 \$0.096	약 135원
적재 비용	\$0	배치 로드 잡은 무료
쿼리 비용	\$0	일일 상한 30 GiB → 월 900 GiB < 무료 1 TiB

1억 8,826만 행을 만들어도 월 135원이다. 행수를 걱정하며 규모를 줄일 이유가 없었다. 대신 쿼리 하드캡을 걸어 사고를 구조적으로 막았다.

8. 인기도 45% — 도달할 수 없는 목표였다

Q21 은 "상위 10%가 지목의 45%"를 정했다. 12m v1 실측이 64.2% 로 나와 zipf_alpha 를 낮춰가며 맞추려 했다.

zipf_alpha	1.35	0.80	0.45	0.20
상위 10% 점유	64.2%	52.6%	48.8%	48.9%

0.45 아래로는 아무 효과가 없다. 바닥에 닿았다는 뜻이다.

바닥은 인기도 가중치가 아니라 활동 불균형이다

투표를 하는 쪽의 상위 10%가 전체 투표의 91.2%를 만든다. 그 불균형이 친구 그래프를 통해 퍼진 결과가 48% 다.

중간에 허브 축소(친구 200~700 → 80~240)로 44.3%까지 내려간 적이 있으나, 학교 계층을 제대로 구현하자 다시 올라갔다 — 학급이 커지면 학급 안 순위의 스프레드가 커지기 때문이다(정원 975명인 학교의 한 반이 77명이 됐다).

더 내리려면 "소수가 활동 대부분을 만든다"(v1 실측)를 깨야 한다. 인기도 집중과 활동 집중은 같은 현상의 두 얼굴이라, 목표치를 49%로 고쳤다.

⚠️ v5 후기 — 그 "바닥"은 고정된 것이 아니었다

8장의 결론은 "썰림의 바닥은 인기도가 아니라 활동 불균형이 정한다"였다. 맞는 진단이었지만 절반만 맞았다.

v5 가 하루 시간 예산으로 불가능한 활동 꼬리를 잘라내자 같은 `zipf_alpha 0.45` 에서 48.8% → **43.7%** 로 떨어졌다. 바닥을 떠받치던 것이 사람이 아닌 유저들이었기 때문이다 — 하루 2,243세션 · 406.8시간을 투표하던 그 꼬리다.

그래서 v5 는 `zipf_alpha` 를 **1.05** 로 올려 49.8% 를 만든다. 같은 49% 라도 출처가 다르다 — v4 는 활동 불균형이, v5 는 매력도가 만든다. 후자가 원래 의도한 것이다.

교훈 하나가 더 붙는다 — "도달 불가"라고 판정한 목표가 다른 결함 때문에 그렇게 보였을 수 있다. 바닥을 만드는 것이 무엇인지 먼저 묻고, 그것이 정상인지도 물어야 한다.

9. Q23 — 잊혀 있다가, 구현하면서 뒤집혔다

먼저 — 정해 놓고 구현하지 않았다

Q23 답 (2026-08-03) — "등교 전(07~08시) 작은 봉우리, 점심(12~13시) 최대 봉우리, 하교 후(17~19시) 두 번째, 심야(23~01시) 세 번째. 주말은 평일의 55%."

Q27 답 — "전부 UTC 저장, 행동 패턴은 KST 기준으로 만든다. 이걸 안 정하면 Looker에서 '점심에 투표가 몰린다'가 새벽 3시로 보인다."

2026-08-04 12m v2 실측 — 0시부터 23시까지 전부 4.1~4.2% (완전 균등 4.17%). 요일도 전부 14.1~14.4%. Q23 을 정할 때 적은 이유가 이랬다 — "Looker 대시보드의 시간대 히트맵이 밋밋하면 시각화할 게 없다." 그 데이터로 히트맵을 그리면 정확히 그렇게 됐다.

구현하면서 모양을 뒤집었다 — 봉우리는 점심이 아니라 밤이다

막상 붙이려고 보니 Q23 의 점심 최대 봉우리가 이 서비스에 안 맞았다. 한국 학생은 점심시간에 폰을 오래 못 쓰고, 소셜 투표는 하교 후~취침 전에 몰린다. Q23 의 곡선은 "일반적인 앱"의 패턴을 가져온 것으로 보인다.

구간	평일	주말
00~06시	0.08~0.18	0.09~0.22
07~11시	0.32~0.38	0.30~0.45
12~13시	0.58~0.62	0.60~0.62
14~16시	0.28~0.32	0.60~0.62
17~21시	0.85~0.95	0.65~0.88
22~23시	0.98~1.00	0.85~0.90

실측 — 평일 최고 22시 7.2% · 최저 4시 1.5% (5배 차이). 주말은 낮(14~16시)이 살아나고 밤 봉우리가 완만해진다.

⚠️ 전원이 같은 곡선을 따르면 안 된다. 페르소나와 같은 이유다 — 모두가 22시에 몰리면 "심야형 유저"라는 분석 대상이 사라진다. 유형 4종 (일반 65% · 야행성 15% · 아침형 10% · 종일형 10%)에 혼합 12% · 무배정 4% · 봉우리 ±1.5시간 개인 편차를 곱쳤다.

이것이 이 이력의 여섯 번째 "설정은 있는데 코드가 안 읽는다" 사례였다. 앞의 다섯은 growth · schools.tiers · schools.adoption · retention.reactivation_rate · popularity.top10_share 였고, 이것을 고치는 과정에서 일곱 번째(behavior 절)가 또 나왔다.

그래서 목록을 나열하는 방식 자체를 버렸다

load_config() 는 v2 설정에서 옮길 절 이름을 손으로 나열했다. 새 절을 만들 때마다 여기 추가하는 것을 잊었고, 그 기능이 조용히 사라졌다.

2026-08-04 에 목록을 뒤집었다 — 위에서 개별 처리한 절만 빼고 나머지는 전부 옮긴다. 새 절을 만들면 아무것도 안 해도 넘어온다. 일곱 번 같은 실수를 하고서야 구조를 바꿨다.

10. 이 이력이 남긴 교훈

교훈	어디서 배웠나
설정에 값이 있어도 코드가 안 읽으면 없는 것이다	10번 반복됐다. 마지막 하나는 앞의 아홉을 고치는 작업 안에서 새로 만들었다. 전부 오류가 안 나고, 데이터를 다 만들어 분석해야 드러난다. → 생성 끝에 목표 대비 실측을 바로 출력하게 고쳤고, 결국 절 목록을 나열하는 방식 자체를 버렸다 (9장)
고치다가 옆을 부순다	behavior 절을 넣다가 seasonality 가 growth 밖으로 밀려나 시험기간 배수가 통째로 무시됐다. 겨울방학이 28%로 나온 건 국면 배수 덕이지 그 설정 덕이 아니었다 — 맞는 숫자가 맞는 이유로 나온 게 아닐 수 있다
재시도는 확률을 무력화한다	시간대 판정에 12번 재시도를 넣었더니 수용률이 50% → 97% 가 되어 계절성 속 아내기가 사라지고 세션이 56% 붙었다. 속아낼 거면 미리 부풀리고 한 번만 판정한다
배수는 곱해진다	겨울방학(0.30)이 trough 국면(0.18)과 겹쳐 0.054가 됐다 — 평시의 9%. 같은 현상을 두 곳에서 표현하면 이중으로 늘린다
같은 숫자가 정반대를 뜻할 수 있다	소비/적립 12.8%(남아돌아서) vs 7.5%(모자라서). 지표 하나로는 구분 불가
평균 하나로 보면 안 된다	하트는 72%가 남고 18%만 쪼들린다. 잔액 평균 2,132 vs 중앙값 462
작은 샘플로는 원리상 검증 못 하는 것이 있다	3국면 곡선 · 코호트 잔존 · 계절성 · long_term 활동량. 1개월 샘플에서 zipf_alpha 0.80 이 45.0% 였는데 12개월에선 52.6%
목표치가 도달 불가일 수 있다	인기도 45%. 구조가 정하는 바닥이 48%였다. 파라미터를 계속 돌리기 전에 바닥이 있는지 물어야 한다
지표를 좋게 만드는 것과 문제를 푸는 것은 다르다	"가입 지급을 낮추자"는 분모를 깎는 제안이었다
확률에 배수를 걸면 모집단 평균이 샌다	오즈비 변환이 불록해서 평균이 당겨진다. 설정값을 손으로 올리면 트레잇 분포가 바뀔 때마다 다시 들어진다
관측 창 끝은 잘려 있다 (우측 절단)	열람률 41.8% vs 53.9%. 실데이터에도 똑같이 생긴다
한 곳을 고치면 다른 곳이 움직인다	학급 수를 정원에서 유도 → 학급 636→1,208개 → 같은 반 친구 25%→14% → CLASS 스코프 35%→30.6%
분포는 사람이 눈으로 봐야 한다	Q30 게이트 5번. 정합성·커버리지·행수는 기계가 통과시켜도 곡선이 이상한 데이터를 막지 못한다
검사를 통과하는 것과 그럴듯한 것은 다르다 v5	v4 는 정합성 17종·이상치 9종·목표 지표를 전부 통과하고 확정됐다. 그 직후 정밀 EDA 에서 하루 406.8시간 투표가 나왔다. "하루에 몇 번까지가 사람인가"는 스키마 제약으로 표현되지 않는다 — 검사에 없는 질문은 영원히 안 물어진다
균등분포는 오류가 아니라 침묵이다 v5	시간 간격 6종이 균등도 1.0 이었다. 오류도 안 나고 검사도 통과한다. 가설검정 자체가 안 되는 것이 뒤늦게 드러난다. → 변동계수와 균등도로 전 측을 훑는 습관이 생겼다
상한을 개수로 걸면 분포를 죽인다 v5	하루 12세션으로 잘랐더니 행이 반토막 나고 쓸림이 39%로 무너졌다. 막아야 할 것을 정확히 정의해야 한다 — "많이 한다"가 아니라 "하루에 낼 수 없는 시간을 쓴다"였다
두 표가 독립이면 같은 질문에 다른 답이 나온다 v5	v4 에서 복귀 코호트가 vote_session 으로는 736명, user_session 으로는 0명이었다. 어느 표로 재도 같은 답이 나와야 지표를 믿을 수 있다
라벨과 활동이 독립이면 모델이 안 만들어진다 v5	v4 는 탈퇴자가 오히려 투표를 더 많이 했다(119.4 vs 115.6). 탈퇴가 활동 생성과 무관하게 찍혔기 때문이다. 합성 데이터에서 "라벨"을 만들 때는 그 라벨이 피쳐와 어떻게 얹히는지를 같이 설계해야 한다
원본을 열어 보고 지시를 확인한다 v5	요일 패턴을 "월→일 우하향"으로 지시받았으나 원본은 V자였다 (금요일 최저 · 주말 회복). 원본이 명시적으로 반대를 적고 있었다

11. v4 → v5 — 무엇을 고쳤나

v4 를 확정한 직후 돌린 정밀 EDA 가 **결함 1건 · 경계 5건**을 찾았고, 작업자가 **요구사항 7가지**를 지정해 v5 를 만들었다.

#	요구	v4	v5	측정
1	시간 간격 비균등	1.01~1.05	0.15~0.54	균등도(1.0 = 완전 균등) · 5종
2	요일 패턴	CV 0.024	CV 0.18~0.24	구 서비스와 순위 7개 일치
3	행동은 세션 안에서만	3.84%	99.99%	투표 세션이 접속 세션 창 안에
4	세션 로그 노이즈	없음	0.399%	중복 행 3,944건
5	탈퇴 후 로그 금지	9종 발생	9종 0	v4 는 하트 거래만 128만 건
6	투표 시간 일관성	19.50%	0.00%	상관 0.0007 → 0.7005
7	좋아요 유저 60%	95.9%	59.6%	활성 유저 기준

v4 에서 "할 수 없다"였던 15종 중 9종이 열렸다

열린 것	근거
앱 열기 → 투표 퍼널	겹침 3.84% → 99.99%
체류시간 · 응답속도 분포	균등도 1.0 → 0.15~0.54
이탈(탈퇴) 예측	탈퇴자 활동이 21% 적다 (v4 는 오히려 많았다)
요일 효과	CV 0.024 → 0.18~0.24
상위 1% 세그먼트	하루 최대 51세션 · 7.9시간 — 사람 범위
집중 지표 절대값 인용	불가능한 꼬리가 없다
접속 세션 기준 휴면·복귀	0명 → 748명
세션 길이와 활동의 관계	상관 0.0007 → 0.7005
중복 로그 정제 연습	노이즈를 일부러 넣었다

11-2. 아직 안 한 것

항목	출처	상태
2차 증분 배치	Q28	미실시. 증분 적재의 함정 4개를 실제로 재현해 볼 유일한 방법. 이제 가장 큰 미이행 항목이다
앱을 생성기에 맞추기	—	투표 보상(앱 5~15 vs 생성기 2~10) · 일일 적립 상한(앱 없음). 생성이 확정된 지금이 그 시점이다
광고 시청시간 로그정규	v5 누락	시간 간격 7곳 중 한 곳을 빠뜨렸다(균등도 1.005). 생성기 1줄
BAN 이후 활동 차단	범위 밖	2,693건 · 34명. 요구는 탈퇴였고 제재는 손대지 않았다 — 구조가 같으므로 같은 방식으로 고칠 수 있다
시간대 대비 회복	v5 부작용	5.3배 → 3.1배. 세션을 30분 규칙으로 묶은 결과다 — 더 현실적이지만 히트맵 색 대비는 줄었다
죽은 설정 정리	—	<code>votes_per_app_session</code> · <code>gender_homophily</code> · <code>stop_voting_at_cap</code> · <code>anomalies.*</code> · <code>gates.*</code> 등 — 코드가 안 읽는다
시간대·요일 리듬	Q23 · Q27	해소 (v5) — 시간대 3.1배 · 요일 순위 원본과 일치
계절성의 크기	Q4	해소 (v5) — 평시 대비 방학 42% · trough 28%
3국면 MAU 진폭	Q4	해소 (v5) — 저점 1,063 → 회복 4,514 = 4.2배(목표 2.5배)
같은 반 친구	Q20	해소 — 0~3명 14.7%

12. 부록 — 결정이 어디에 살아 있나

결정	설정값	코드 / 문서
규모 (Q1·Q2·Q3)	<code>scale.users</code> · <code>schools.active_count</code> · <code>period</code>	<code>synthetic-v2.yaml</code>
성장 곡선 (Q4)	<code>growth.phases</code> 6국면	<code>GrowthCurve</code> 클래스 · <code>growth-curve-two-channels.md</code>
학교 순차 진입 (Q5)	<code>schools.tiers</code> · <code>schools.adoption</code>	<code>_plan_schools()</code> · <code>_pick_school()</code>
행수 상한 (Q6)	참고 수치로만 남김	<code>row-cap-to-query-cap.md</code> (superseded: <code>row-guardrail-measured.md</code>)
페르소나	<code>personas</code> 6유형	<code>user-personas.md</code> · 정답지는 <code>data/personas.json</code> (분석자에게 주지 않는다)
활동 강도	<code>voting.sessions_per_month_by_tier</code>	<code>activity-by-retention-tier.md</code>
하트 경제 (Q24~Q26)	<code>hearts</code> · <code>voting.reward</code>	<code>heart-economy-rebalance.md</code>
인기도 (Q21)	<code>voting.popularity</code>	실측 4점이 설정 주석에 남아 있다
스키마 불변 (Q10)	—	<code>no-schema-change-for-synthetic.md</code>
외모 질문 (Q19)	<code>questions.include_appearance</code>	마이그레이션 <code>012_activate_appearance_category.sql</code>
세션 포함관계 v5	<code>sessions.idle_gap_minutes</code> · <code>browse_only_ratio</code> · <code>max_vote_hours_per_day</code>	<code>_build_app_sessions()</code> · <code>_act_at()</code> · <code>session-bounded-actions.md</code>
시간 간격 분포 v5	코드 안 (peak · sigma)	<code>lognormal_span()</code> · <code>lognormal-not-uniform.md</code>
요일 패턴 v5	<code>sessions.use_dow_weights</code> · <code>dow_gamma</code>	<code>DOW_WEIGHTS</code> 상수(코드 옆에 둔다) · <code>dow-from-legacy-attendance.md</code>

탈퇴 중점 v5	—	u.last_activity_at · u.ledger_last_at · withdrawal-is-terminal.md
----------	---	---

⚠️ 값을 설정에만 두지 않는다

요일 가중치를 코드 옆 상수(DOW_WEIGHTS)로 둔 것은 의도적이다. 설정으로는 **켜고 끄기만** 한다.

이 이력에서 열 번 반복된 실패가 "설정에 값은 있는데 코드가 안 읽는다"였고, v5 를 만들면서도 또 한 번 만 들었다(votes_per_app_session). 값이 설정에만 있으면 언젠가 조용히 죽는다.

이 문서를 어떻게 쓰나

설정 파일은 값만 남긴다. "왜 20,000명인가", "45%를 왜 49%로 바꿨나", "잔존 비율이 왜 실측과 다른가"는 값에 안 적힌다.

파라미터를 바꾸려는 사람은 먼저 이 문서에서 그 값이 왜 그렇게 됐는지를 본다. 특히 6장(뒤집힌 결정)과 8 장(도달 불가 목표)은 같은 실수를 반복하지 않기 위한 것이다.