

문서를 LLM 위키로 바꿨다

왜 바꿨고, 무엇이 달라졌으며, 4주 뒤에도 그 판단이 유효한가

기준일 2026년 8월 25일 · 개편은 2026년 7월 31일 (4주 경과)

규모 위키 노드 163개 (결정 91 · 표 40 · 색인/규약 13 · 운영 10 · 원본 9) · 링크 663개

결정 하나를 찾는 비용 1,268 토큰 — 같은 내용을 한 파일로 두었을 때는 4,484

매 세션 고정비 16,982 토큰 — 위키가 없었어도 비슷했을 값

근거 Andrej Karpathy, *LLM Wiki: A Pattern for Persistent Knowledge Bases*

도구 Obsidian 볼트로 열림 · 생성·검사 스크립트 8종

- 1 LLM 위키란 무엇인가 — 처음 듣는 사람을 위해
 - 2 왜 도입했나 — 2026년 7월 31일의 상태
 - 3 지금의 구조 — 세 개의 층
 - 4 그래프로 본 위키
 - 5 효과 — 숫자로
 - 6 이득 — 여덟 가지
 - 7 어떻게 쓰나 — 세 가지 연산
 - 8 4주 뒤 — 구조가 견뎌나
 - 9 되돌리는 기준과 남은 비용
- 부록 측정 방법 — 경로 정의 · 민감도 · 반사실 계산

1. LLM 위키란 무엇인가

사람이 읽는 위키와 목적이 다르다. 독자가 에이전트다.

출발점: LLM 은 매번 처음부터 시작한다

사람과 달리 LLM 에이전트는 어제 한 일을 기억하지 못한다. 새 대화를 열면 **이 프로젝트가 무엇인지, 왜 그렇게 정했는지를 다시 알려줘야 한다**. 그 "다시 알려주는 비용"이 이 문서가 다루는 전부다.

흔히 쓰는 대응이 둘 있고, 둘 다 값을 치른다.

대응	어떻게 되나
① 큰 문서 하나를 매번 읽힌다	"우리 프로젝트 문서" 한 파일을 통째로 읽힌다. 확실하지만 질문과 무관한 내용까지 전부 값을 낸다 . 문서가 자랄수록 매 세션의 고정비가 커진다
② 대화 세션을 길게 유지한다	한 번 설명한 맥락을 잃지 않으려고 세션을 안 끊는다. 그런데 대화가 길어질수록 이후의 모든 요청이 그 누적 대화를 다시 읽는다 . 작은 수정 하나에도 앞선 맥락 전체의 값을 낸다

LLM 위키의 답

지식을 작은 노드로 쪼개고, 링크로 잇고, 필요한 것만 골라 읽게 한다. 핵심은 파일을 잘게 나누는 것이 아니라 **경계를 의미와 일치시키는 것**이다 — 노드 하나가 "결정 하나"이면, 그 결정이 궁금할 때 딱 그만큼만

읽으면 된다.

원칙	이 저장소에서의 모습
원본은 고치지 않는다	<code>raw/</code> — 회의록·구 서비스 분석·외부 스펙. 나중에 생각이 바뀌어도 원본은 그대로 두고 새 결정 을 따로 적는다
파생 문서는 재생성한다	색인·표 페이지는 스크립트가 만든다. 손으로 고치지 않는다 — 고쳐도 다음 생성 때 날아간다
노드 = 의미 단위	결정 하나 = 파일 하나. 제목·날짜·갈래·상태를 frontmatter 에 단다
링크로 잇는다	<code>[[위키링크]]</code> . 뒤집힌 결정은 <code>superseded_by</code> 로 후속 결정을 가리킨다
찾는 규율이 이득을 만든다	<code>grep</code> 으로 파일명만 받고, 이름을 보고 골라, 그 노드만 읽는다. 매칭된 것을 전부 읽으면 쪼개기 전보다 나빠진다(5장)

사람 위키와 결정적으로 다른 점

사람은 긴 문서를 **훑어보고 필요한 곳만 눈으로 건너뛴다**. 비용이 거의 안 든다. 에이전트는 읽은 만큼 값을 낸다. 그래서 **"찾기 쉬움"이 곧 "쌈"**이고, 그것이 문서를 노드로 쪼갤 이유가 된다.

또 하나 — 사람 위키는 사람이 낚음을 눈치챈다. 여기서는 **코드도 진실이고 코드는 매 커밋 바뀐다**. 문서가 조용히 낚는다. 그래서 **lint 연산**이 따로 있다(7장).

2. 왜 도입했나 — 2026년 7월 31일의 상태

문서가 늘면서, 한 번 볼 때마다 전부를 읽어야 하는 구조가 됐다.

무엇이	왜 문제였나
DECISIONS.md 33,792 토큰	결정 56개가 한 파일에 시간순으로 쌓였다. 결정 하나는 중앙값 680토큰인데 실제로는 파일을 통째로 읽었다 — 작업 중 시스템이 "내용이 너무 커서 포함할 수 없다"며 잘라낼 정도였다
CLAUDE.md 13,518 토큰	에이전트가 매 세션 무조건 읽는 파일. BigQuery 설정처럼 특정 작업에만 필요한 내용이 항상 따라왔다
뒤집힌 결정이 그대로 살아 있었다	힌트 요금을 순차 4단계에서 선택형으로 바꿨는데 옛 결정이 같은 파일에 남아 있었다. 제목만 보면 서로 모순되는 항목도 있었다
표 하나를 알려면 네 군대를 열어야	<code>heart_transaction</code> 은 DDL 주석 · 결정 6개 · 정합성 검사 5종 · 정책 7파일에 흩어져 있었다
손으로 만든 목록이 조용히 낡았다	"비어 있는 테이블" 목록이 실제와 어긋나 있었다 — 20행짜리 표를 비었다고 적어두고, 정작 빈 표는 빠져 있었다

그리고 여섯 번째 — 세션을 끊지 못했다

이것이 문서만 봐서는 안 보이는, 실제 작업 방식의 문제였다.

맥락을 다시 설명하는 것이 비싸니까 세션을 일부러 유지했다. 스키마 컬럼 하나를 고치는 작은 일도, 새 대화를 열어 "이 프로젝트는 이런 거고 저 표는 이래서 저렇게 만들었고..."를 다시 말하느니 **어제 쓰던 대화창을 이어 쓰는 편이 싸 보였기 때문이다.**

그런데 그 선택은 정반대의 값을 치른다. 대화가 길어질수록 그 뒤의 모든 요청이 누적된 대화 전체를 다시 실는다. 작은 수정 하나가 앞선 두 시간치 맥락의 값을 낸다. 게다가 길어진 세션에는 이미 끝난 작업의 시행착오·실패한 시도·중간 출력이 그대로 남아 있어서, **정작 필요한 정보의 밀도는 계속 떨어진다.**

진짜 문제는 토큰이 아니라 의존이었다

세션에만 있는 맥락은 **저장소에 없는 맥락**이다. 그 대화창을 닫는 순간 사라지고, 팀원은 처음부터 볼 수 없으며, 몇 주 뒤의 나도 못 찾는다. "왜 그렇게 정했나"가 **대화 기록에만 있는 상태였다.**

위키로 바꾼 뒤에는 세션을 짧게 끊을 수 있게 됐다. 새 대화를 열고 필요한 노드 하나(평균 1,268 토큰)만 읽으면 그 작업에 필요한 맥락이 선다. 작은 작업일수록 이득이 크다 — 작은 작업에 긴 세션을 물고 있는 것이 가장 비쌌기 때문이다.

다섯 문제의 공통점

전부 **오류를 내지 않는다**. 문서는 잘 읽히고 링크도 멀쩡하다. 다만 낡았거나, 필요 없는 것까지 딸려올 뿐이다. 이 프로젝트가 스키마에서 계속 상대해 온 **"조용히 틀리는 것"**이 문서에서도 똑같이 나타난 것이다.

3. 지금의 구조 — 세 개의 층


원본은 사람만 고치고, 위키는 에이전트가 소유하고, 규약이 그 일을 정의한다.

1층 · 원본 raw/ 회의록 · 구 서비스 분석 · 외부 스펙 사람만 고친다. 에이전트는 읽기만 9개 노드	2층 · 위키 docs/ 원본과 코드에서 뽑아 만든 것 에이전트가 소유한다 결정 91 · 표 40 · 운영 10 · 색인	3층 · 규약 CLAUDE.md 그 일을 어떻게 하는지 사람과 에이전트가 함께 다듬는다 매 세션 자동으로 읽힌다
--	--	---

갈래	개수	무엇이 들어 있나
결정 docs/decisions/	91	결정 하나 = 파일 하나. 결정 / 이유 / 대안 / 영향. 갈래는 검증 21 · 파이프라인 18 · 투표 8 · 보안 7 · 하트 6 순. 뒤집힌 것 4건 은 취소선과 화살표로 후속 결정을 가리킨다
표 docs/tables/	40	생성물 . 표 하나의 DDL·결정·검사·정책을 한 장에 모은다
운영 docs/ops/	10	"이 작업 어떻게 하지"에 답하는 절차 문서
색인·규약	13	index (생성물) · DECISIONS · CLAUDE · log · README · TEAM-PLAN · ONBOARDING 등
원본 raw/	9	불변. 바뀐 것은 새 결정 노드로 적는다

4. 그래프로 본 위키

노드와 링크를 그림으로 보면 문서로는 안 보이는 것이 보인다.



같은 데이터를 **재현 가능한 형태로** 다시 그린 것 — `python db/wiki_graph.py` (노드 153 · 링크 505). 스크린샷은 찍은 순간의 것이고 배치가 매번 달라지지만, 이쪽은 씨앗이 고정돼 **같은 그림이 다시 나온다**. 위키 노드만 남기고 SQL·스크립트는 뺐으며, 생성 색인(`index`)도 뺐다 — 모든 노드를 가리켜서 그리면 그래프가 통째로 별 모양이 되고 결정끼리의 구조가 안 보인다.

이 그림에서 읽는 것

보이는 것	뜻
가운데 큰 회색 — <code>DECISIONS</code>	결정 색인. 모든 결정이 여기로 모인다
오른쪽 청록 뭉치 — <code>app_user</code> · <code>heart_transaction</code> · <code>vote_item</code>	표 페이지들. 결정이 많이 얹힌 표일수록 크다. 이 표를 건드리면 무엇이 달려 오는지가 그대로 보인다
파란 점들의 그물	결정 91개. 서로 이어져 있으면 <code>link_decisions.py</code> 가 '이어지는 결정'을 붙인 것이다
바깥의 외톨이들	링크가 하나뿐인 노드. 나쁜 신호는 아니지만 볼 값은 있다 — 아무도 안 가리키는 결정은 잊힌 결정이 되기 쉽다

옵시디언으로 실제로 잡은 것 셋

이 저장소의 `docs/` 는 옵시디언 볼트로 그대로 열린다. 링크가 그래프가 되고 frontmatter 가 속성이 된다. 별도 도구를 붙이지 않았다.

#	그래프를 보다가 발견한 것
1	결정 56개가 통째로 사라져 있었다 . 루트 색인 하나만 그래프에서 빠려고 <code>-path:"DECISIONS"</code> 필터를 걸었는데, 옵시디언의 <code>path:</code> 는 대소문자를 구분하지 않아 <code>docs/decisions/</code> 전체가 걸러졌다. 그래프가 텅 비어서 알았다 — 파일 목록으로는 못 봤을 사고다
2	별 모양이 되는 것을 막았다 . 모든 노드가 색인만 가리키면 그래프가 바퀴살이 된다. 그래서 참조는 되도록 개별 노드를 가리킨다 는 규칙을 규약에 박고, <code>link_decisions.py</code> 로 결정끼리 잇게 했다

3	색인에서 빠진 노드가 보였다. group: 웹앱 인 노드 3개가 그 갈래 자체가 색인에 없어서 통째로 빠져 있었다. 파일은 멀쩡한데 아무도 못 찾는 상태다 — 색인에 없는 노드는 없는 노드다. 이걸 결국 lint 검사로 옮겼다
---	--


그림은 문서가 아니라 구조를 보여준다

세 사고 모두 "문서를 읽어서" 발견한 것이 아니다. 모양이 이상해서 발견했다. 한 파일 시절에는 볼 모양 자체가 없었다.

5. 효과 — 숫자로

같은 토큰라이저로 세 시점을 잴다. 측정 방법은 부록에 있다.

결정 하나를 알려면 몇 토큰을 읽어야 하나



같은 내용을 두 방식으로 찾을 때의 비용을, 두 시점에서. 위키 규모가 커지면 **한 파일 방식만 같이 비싸진다** — 검색에 걸리는 줄이 늘기 때문이다. 위키 방식은 노드 하나 크기가 위키 전체와 무관해서 거의 그대로다. 회색 막대의 **구간을 몇 줄 읽느냐에 따른 폭**이다. 본문을 한 줄도 안 읽어도 지금 규모에서 3,206 인데, 검색 결과 자체가 그만큼이기 때문이다. 자세한 것은 부록.

3.5배 같은 질문이 싸졌다 4,484 → 1,268 읽는 방식에 따라 2.5~4.0배	2.6배 그동안 위키는 이만큼 커졌다	+30% 그런데 질문 비용은 이만큼만 늘었다	0건 끊어진 링크 노드 163개 기준
--	-----------------------------------	---------------------------------------	-----------------------------------

핵심은 기울기다. 위키가 2.6배로 자라는 동안 질문 하나의 비용은 972 에서 1,268 로 30% 늘었을 뿐이다. 노드 하나의 크기는 위키 전체 크기와 무관하기 때문이다. 반면 한 파일 방식은 파일이 두꺼워질수록 같이 비싸진다.

매 세션 붙는 고정비

에이전트가 **무조건 읽는 파일**(CLAUDE.md)의 크기다.

	개편 전	개편 직후	지금	지금 · 위키가 없었다면
매 세션 고정비	13,518	10,745	16,982	약 16,700

개편으로 21% 떨어냈지만, 그 뒤 4주 동안 **위키 사용법 자체**(+3,078)와 **새로 늘어난 작업**(+3,079)이 그 자리를 채웠다. 위키가 없어도 비슷한 값이 됐을 것이므로 **이 항목은 본전이다**. 이득은 질문당 비용에서 났다.

다만 방향은 다르다

지식이 늘 때 결정은 노드로 흩어지고 규약은 한곳에 쌓인다. 결정 노드 전체 대비 규약의 비중은 28% → 17% 로 떨어졌지만, 절대값은 계속 는다. 노드에 담을 수 있는 것을 규약에 두지 않는 것이 이 구조를 유지하는 일이다.

6. 이득 — 여덟 가지

토큰이 가장 크지만, 나머지가 실제로 더 자주 쓰인다.

#	이득	측정값 · 근거
1	질문 하나가 3.5배 싸졌다 그리고 위키가 커져도 거의 안 느다	1,268 토큰 (같은 내용을 한 파일로 두었을 때 4,484). 위키가 2.6배 커지는 동안 +30%
2	세션을 짧게 끊을 수 있다 맥락을 대화에 켜여둘 필요가 없다	작은 작업마다 새 세션을 열고 노드 하나(1,268)만 읽는다. 예전에는 맥락 재설명이 아까워 세션을 이어 썼고, 그 대화가 이후 모든 요청에 계속 실행 다
3	맥락이 저장소에 남는다 대화창이 아니라	결정 91개 · 운영 문서 10개. 대화에만 있던 "왜 그렇게 정했나"가 파일이 됐다 — 팀원도 보고, 몇 주 뒤의 나도 찾는다
4	뒤집힌 결정이 드러난다	4건. <code>superseded_by</code> 로 후속 결정을 가리키고 색인에 취소선이 그어진다. 한 파일 시절에는 옛 결정이 그대로 살아 있었다
5	낱음을 기계가 잡는다	<code>doc_lint.py</code> 9종. 끊어진 링크 0건 유지 (노드가 63% 느는 동안). 검사 셋은 실제로 당한 뒤 추가됐다 — 없는 질문 번호 · 결정 없이 쌓인 코드 · 색인에서 빠진 노드
6	표 하나를 한 장에서 본다	484 토큰. 예전에는 DDL 주석 · 결정 · 정합성 검사 · 정책 네 곳을 열어 조합해야 했다
7	팀이 같은 문서를 본다	<code>ONBOARDING</code> 이 계정 없이 되는 길과 계정이 필요한 길을 나눠 적는다. 스키마를 건드릴 때 표 페이지 한 장이 영향 범위 가 된다. 결정 하나 = 파일 하나라 커밋 diff 에 그 결정만 뜬다. 마크다운이라 새 도구를 깔라고 할 필요도 없다
8	구조를 눈으로 본다	옵시디언 그래프(4장). 문서를 읽어서가 아니라 모양이 이상해서 잡은 사고가 셋이다 — 필터 대소문자로 결정 56개가 사라진 것 · 별 모양이 되던 것 · 색인에서 빠진 노드

이득이 공짜는 아니다 — 규율이 조건이다

`grep` 에 걸린 노드를 **전부** 읽으면 31,655 토큰이다. 같은 내용을 한 파일로 두고 읽는 것(4,484)보다 **7배 나쁘다**. "합성"이라는 낱말 하나가 이제 91개 중 47개에 걸린다.

구조가 아니라 규율이 이득을 만든다 — 이름을 보고 골라 그 노드만 읽는 것. 그래서 결정의 제목과 파일명을 짓는 일이 실제 작업이다.

7. 어떻게 쓰나 — 세 가지 연산

연산	언제	무엇을 하나
ingest	원본을 넣었을 때	무엇이 결정이고 무엇이 논의인지 가른다 → 결정 노드를 만들고 → 영향받는 문서를 고치고 → 생성물을 다시 뽑고 → 이력에 한 줄 남긴다
query	물어볼 때	grep 으로 파일명만 받고, 이름을 보고 골라, 그 노드만 읽는다. 색인까지 읽을 필요도 보통 없다. 답이 길고 다시 쓰일 것 같으면 그 답 자체를 새 노드로 남긴다
lint	문서·스키마를 손댄 뒤	문서의 주장을 살아 있는 DB·파일시스템과 대조한다. 9종

`doc_lint.py` 가 보는 아홉 가지 — 숫자 · 사라진 이름 · 끊어진 링크 · 없는 스크립트 · 낡은 생성물 · 미반영 회의록 · 없는 질문 번호 · 결정 없이 쌓인 코드 · 색인에서 빠진 결정 노드. 뒤의 셋은 처음엔 없었다 — 전부 실제로 당하고 나서 붙였다.

★ 는 고쳐야 하고, · 는 사람이 판단한다

숫자와 이름은 이력 서술과 기계적으로 구별되지 않는다. "그때는 30개였다"는 틀린 게 아니다. 그래서 알리기만 한다. 전부 실패로 두면 늘 빨간불이 되고, 그러면 검사 자체를 안 보게 된다.

8. 4주 뒤 — 구조가 견뎠나

결정이 56 → 91 개가 됐다. 늘어난 35건이 구조를 시험했다.

항목	결과
끊어진 링크 0	지켜졌다. 노드가 63% 늘었는데도 0 이다 — lint 가 실패로 잡기 때문이지 조심해서가 아니다
토큰 이득	커졌다. 61.6% → 71.7% (5장)
뒤집힌 결정이 드러난다	4건. 한 파일 시절이었다면 옛 결정이 살아남아 누군가 그것을 근거로 삼았을 것이다
결정을 노드로 적기	⚠ 아홉 번 어겼다. 그래서 검사를 붙였다 — 사람의 규율에 기대는 항목은 결국 어긋난다
회의록 ingest	⚠ 0회. 회의가 없었다
CLAUDE.md 를 얹게	⚠ 개편 때는 지켰다(13,518 → 10,745). 지금은 16,982 로 다시 늘었다 — 위키가 없었어도 비슷했을 값이지만(5장), 노드에 이미 있는 내용의 중복 요약이 섞여 있다. 그것을 밀어내는 일이 남았다

9. 되돌리는 기준과 남은 비용

판단 기준은 둘이다 — 같은 질문에 토큰을 더 쓰거나, 관련 결정을 놓쳐 답이 나빠지거나. 4주 뒤 기준으로 둘 다 발생하지 않았다. 그래도 되돌리는 스크립트(`db/wiki_merge.py`)는 유지한다 — 지금 있는 노드 전부를 읽어 합치므로 개편 이후에 쓴 결정도 살아남는다. `git revert` 로 하면 그것들이 함께 사라진다.

남은 비용 — 정직하게

무엇	지금 값
규약 파일이 매 세션 붙는다	16,982 토큰. 중복 요약을 덜어내면 줄어든다
색인 자체가 무겁다	10,545 토큰. 전체 탐색 때는 이 값을 낸다(보통은 안 읽는다)
규율이 무너지면 더 나쁘다	매칭된 노드를 전부 읽으면 31,655 토큰 — 한 파일로 두는 것보다 7배 나쁘다
파일 목록이 커지고 있다	골라 읽기 비용 중 파일 목록 비중이 13% → 24%. 노드 180~200개 근처에서 다시 볼 값이다
검사를 늘리는 일은 안 끝난다	lint 6종 → 9종. 셋 다 당하고 나서 붙였다

부록 · 측정 방법

본문의 숫자를 어떻게 얻었는지. `python db/token_bench.py` 로 재현된다.

무엇을 잴나

질문 다섯(하트 경제 · 친구 끊기 · 합성 데이터 · 증분 함정 · 힌트 요금)에 답하기 위해 읽어야 하는 토큰의 평균이다. 토큰나이저는 `tiktoken/cl100k_base`, 옛 시점은 git 에서 꺼내 **같은 자로** 잤다(`pre-wiki · 9a10db0`).

경로	방법	지금 규모
A	파일을 통째로 읽는다 — 개편 전의 실제 습관	92,384
B	한 파일에서 grep 하고 그 구간만 읽는다 — 위키가 없었다면 가능한 최선	3,206 ~ 5,131
D	grep 으로 파일명만 받고 노드 하나만 읽는다 — 지금 하는 것	1,268
E	grep 에 걸린 노드를 전부 읽는다 — 규율이 무너졌을 때	31,655

본문의 비교는 B 대 D 다. A 대 D 로 건주면 "한 파일이어도 전부 읽지는 않는다"는 반론에 답할 수 없다. 실제로 이 프로젝트가 처음에 A 를 기준으로 "91% 절감"이라 적었다가 취소한 적이 있다.

B 를 유리하게 잡아도

B 의 값은 "구간을 몇 줄 읽느냐"에 달렸다. 창이 0 이면 **본문을 한 줄도 읽지 않는다**는 뜻이다.

읽기 창	B 합계	└ grep 출력	└ 본문 읽기	D 대비
±0줄	3,206	3,180	26	2.5배
±15줄	3,930	3,180	750	3.1배
±25줄	4,484	3,180	1,304	3.5배
±40줄	5,131	3,180	1,951	4.0배

한 파일 경로의 비용은 본문이 아니라 검색 결과 자체다. 한 파일에서 grep 하면 결과가 줄로 돌아오고("친구" → 4,843 토큰), 노드로 쪼개면 **파일 이름**으로 돌아온다(27개 파일명 = 303 토큰). 그래서 아무것도 읽지 않아도 2.5배 차이가 난다.

"위키가 없었다면 지금"을 어떻게 구했나

질문당 비용은 추정이 아니다 — 지금의 노드 91개를 한 파일로 합쳐 놓고 B 경로를 그대로 돌린 값이다.

고정비는 추정이다.

지금 실제	16,982
- 위키 사용법 3절 (위키가 없었으면 쓸 일 없던 글)	-3,078
+ 개편 때 노드로 덜어낸 분량 (그대로 남았을 것)	+2,773
위키가 없었다면 (추정)	≈ 16,677

"위키가 없었다면 4주간의 새 내용이 어디에 쓰였을까"는 알 수 없다. 결정은 세션마다 읽지 않는 파일로 갔을 테니 고정비에 안 붙지만, 규약성 글은 어차피 `CLAUDE.md` 에 붙었을 것으로 봤다. **이 가정이 틀리면 추정치는 낮아진다** — 위키에 불리해지는 방향은 아니다.

D 쪽의 가정

D 는 **파일명만 보고 한 번에 맞는 노드를 고른다고** 가정한 값이다. 잘못 고르면 노드를 하나 더 읽어야 하고 (약 +1,000), 두 번 틀리면 B 와 비슷해진다. **이 경로의 이득은 이름을 보고 고르는 판단이 맞을 때만 성립한다.**

재현

```
python db/token_bench.py           # 두 시점 · 경로별
python db/token_bench.py --stages  # 개편 전 · 직후 · 현재
python db/token_bench.py --window 0,15,25,40 # 창 민감도
python db/wiki_graph.py           # 4장의 그래프
python db/docLint.py              # 문서가 실제와 맞는가
```

ping-v2 · 문서 체계 보고서 · 2026-08-25 기준 (개편 2026-07-31)

이 보고서는 `docs/WIKI-REPORT.html` 에서 만든다 · 토큰 수치는 `db/token_bench.py` (tiktoken/cl100k_base) 실측